

Automatiser l'identification du *qui* et du *où* ?

Reconnaissance et liaison d'entités nommées :
enjeux méthodologiques et épistémologiques à
partir du corpus des *Documents diplomatiques*
suisses

par

Xavier Baume

Sous la codirection de Mme Sandra Bott et M. Michael
Piotrowski

UNIVERSITÉ DE LAUSANNE
FACULTÉ DES LETTRES

Mémoire de Maîtrise universitaire ès lettres en humanités numériques,
discipline histoire
Session d'août 2025

Dodis **Unil.**

Remerciements

Je souhaite adresser mes remerciements à Madame Sandra Bott et Monsieur Michael Piotrowski pour leur co-direction attentive et stimulante tout au long de l'élaboration de ce mémoire de master. À Monsieur Sacha Zala, j'adresse également ma reconnaissance pour avoir accepté d'assumer la tâche d'expert. Ma gratitude va au groupe de recherche des Documents diplomatiques suisses, au sein duquel j'ai eu la possibilité d'effectuer un stage en ce début d'année 2025. Une pensée particulière va à Madame Lena Heizmann et Monsieur Tobias Steiner pour la qualité de leur supervision et leur grande disponibilité. La poursuite du présent travail m'a offert l'opportunité d'entrer en dialogue avec la communauté académique. Je tiens donc à remercier Madame Sarah Oberbichler, ainsi que Messieurs Philippe Rygiel, Frédéric Clavert, Dominic Weber et Ismail Prada Ziegler pour la richesse de nos échanges et les perspectives qu'ils m'ont apportées. Par ailleurs, je tiens à souligner les apports précieux de Madame Cécile Armand et Messieurs Baptiste Blouin et Christian Henriot, membres du projet Hist-Text, dont les conseils ont contribué à éclairer les différentes considérations liées au traitement de mon objet d'étude. De même, je remercie la division Calcul et soutien à la recherche de l'Université de Lausanne, dont la mise à disposition de leur infrastructure de calcul et de stockage et leur aide ont été précieuses dans le cadre de mes activités de programmation. Enfin, ce message s'adresse à ma famille et à mes proches pour leur soutien au cours de ces derniers mois.

Table des matières

1 Médiations algorithmiques dans l'édition historique numérique	1
2 De l'édition savante à l'objet de données : repenser l'inscription numérique du texte historique	16
2.1 Définir l'édition savante à l'ère numérique : entre tradition critique et <i>paradigme numérique</i>	16
2.2 L'apport des humanités numériques : modéliser la connaissance éditoriale à partir de standards	19
2.3 Automatiser l'annotation de textes historiques : vers une perspective centrée sur les entités nommées	22
2.4 Entre tropisme de la performance et invisibilisation historiographique	26
3 Un cadre pour penser la transformation des données historiques	30
3.1 Du texte-source au texte-données : vers une herméneutique numérique	30
3.2 Renforcer la transparence : le cadre des <i>digital scopes</i>	34
3.3 Lecture distante et lecture proche : pour une dialectique critique . . .	37
4 Éditer les sources, modéliser le corpus : Les <i>Documents diplomatiques suisses</i> comme terrain d'expérimentation	40
4.1 Entre contribution historiographique et innovation numérique	40
4.2 Définition et modélisation du corpus	43
4.3 Déterminer les zones de vigilance du corpus	49
5 Implémenter une lecture algorithmique : conception et déploiement d'une chaîne de traitement pour les entités nommées	56
5.1 Une chaîne de traitement à partir de l'outil spaCy	56
5.2 Les réseaux neuronaux face au texte : entre performance computationnelle et lisibilité interprétative	58
5.3 Reconnaître et catégoriser les entités d'intérêt dans le texte	62
5.4 Réconcilier les ambivalences pour enrichir le texte	68
6 Observer les effets d'un traitement automatique	73
6.1 Évaluer un modèle à partir de ses métriques	73

6.2	Tension entre prédiction et modèle éditorial : étude de cas à partir des entités organisationnelles	79
6.3	Les conditions de l'interdisciplinarité <i>ou</i> un équilibre qui reste à construire	84
7	Modélisation, incertitude et factualité : pour une lecture critique des représentations numériques	89
7.1	Sur la modélisation du sens dans les modèles neuronaux	89
7.2	Formaliser l'incertitude?	92
7.3	Les entités nommées comme factoides	94
8	Conclusion : ce que les traitements automatisés font aux documents édités	97
9	Lexique	99
10	Bibliographie	101
11	Annexes	124
11.1	Tables statistiques complémentaires	124
11.2	Indications méthodologiques concernant le dépôt des scripts de programmation	125

Table des figures

1	Modélisation simplifiée d'un document TEI-HTML édité par Dodis	46
2	Distribution linguistique du corpus, par phrase	51
3	Chaîne de traitement d'une entité nommée à partir du texte d'entrée	57
4	Distribution des entités nommées selon la langue du paragraphe et leur type	60
5	Représentation de la phrase « la démocratie, c'est la discussion » sous la forme de <i>tokens</i>	63
6	Extrait du document <code>dodis.ch/57905</code> : comparaison entre le balisage TEI-HTML et le fichier JSON prétraité	66
7	Évolution du nombre d'entités nommées uniques et de leur mentions par catégorie entre les fichiers HTML initiaux et le corpus prétraité au format JSON	67
8	Entités dans un texte et références provenant d'une base de connaissances, basé ici sur l'indexation de Dodis	68
9	Statistiques comparatives des entités nommées selon (a) les occurrences par type d'entité, (b) le nombre d'entités uniques, (c) le taux de recouvrement entre jeux d'entraînement (<i>train</i>) et de validation (<i>dev</i>), (d) la proportion d'entités n'apparaissant qu'une seule fois.	76

Liste des tableaux

1	Répartition des entités nommées par catégorie dans le contenu du texte encodé, hors notes de bas de pages	50
2	Références associées à « Washington », par type d'entité et lien . . .	52
3	Nombre d'entités nommées uniques par catégories, extraites du contenu principal et des métadonnées	54
4	Résumé des entités nommées totales dédoublées, disposant d'au moins un lien d'équivalence à des ressources externes	70
5	Matrice de confusion	74
6	Mesures d'évaluation classiques pour la classification binaire	75
7	Scores des tâches de reconnaissance et de catégorisation d'entités par type	75
8	Scores pour la tâche de liaison des entités nommées	77
9	Résumé des entités par URI	78
11	Distribution des entités nommées selon la langue du paragraphe, leur type et leur pondération globale	124
12	Statistiques comparatives des entités nommées dans les jeux d'entraî- nement et de validation	124

Liste des abréviations

ASSH	Académie suisse des sciences humaines et sociales
BERT	Bidirectional Encoder Representations from Transformer
DDS	Publications éditées des Documents diplomatiques suisse
FAIR	Findable, Accessible, Interoperable, Reusable
IA	Intelligence artificielle
TALN	Traitement automatique du langage naturel
TEI	Text Encoding Initiative

1 Médiations algorithmiques dans l'édition historique numérique

« L'intelligence artificielle est partout, y compris dans la plupart des recherches historiques »¹. Un tel énoncé ne saurait occulter un constat : son omniprésence ne garantit pas une prise de conscience de ses implications. À l'image du passage de la *poussière* des archives à la lumière bleue de l'écran des ordinateurs personnels², les pratiques de recherche soutenues par l'utilisation de l'intelligence artificielle (*IA ci-après*)³ semblent en effet s'être déroulées de manière discrète au sein de la communauté historienne⁴. Au risque de sombrer dans une forme de « banalisation de la recherche »⁵, où le caractère quotidien de l'utilisation des outils numériques intégrés aux systèmes d'information échappe à un questionnement critique, le rôle joué par les algorithmes*⁶ demande à être problématisé⁷. La reconfiguration de l'environnement de recherche en histoire peut dès lors s'articuler au moins autour de deux implications, à savoir la recherche et l'exploration de textes⁸.

En 2003, Roy Rosenzweig postulait le passage d'un « âge de la pénurie » à un « âge de l'abondance » dans le domaine de la science historique, qui se caractérisait par une offre sans précédent de témoignages accessibles en ligne sur le passé proche et

1. TILTON Lauren, « Relating to Historical Sources », *The American Historical Review*, vol. 128, n° 3, 2023, p. 1354. *trad.* Les citations en langues étrangères ont été traduites à l'aide du logiciel *DeepL* et de dictionnaires spécialisés. Toutes les traductions seront signalées par la mention « *trad.* », à la suite des publications auxquelles elles se réfèrent.

2. MULLER Caroline et CLAVERT Frédéric, « De la poussière à la lumière bleue : Émotions, récits, gestes de l'archive à l'ère numérique », *Signata*, n° 12, 2021.

3. L'intelligence artificielle (IA) sera ici principalement considérée sous l'angle de l'apprentissage automatique et de l'apprentissage profond. L'apprentissage automatique consiste à concevoir des programmes capables d'identifier des régularités dans les données et de s'améliorer de manière autonome en reproduisant le raisonnement humain logique. L'apprentissage profond se rapporte à une famille de l'apprentissage machine qui repose sur des réseaux de « neurones » artificiels et interconnectés. CLAVERT Frédéric et MULLER Caroline, « L'histoire au temps des algorithmes : Une réflexion prospective sur l'introduction de l'intelligence artificielle en histoire au 21^e siècle », *20 & 21. Revue d'histoire*, vol. N° 162, n° 2, 2024, p. 14. Ces approches s'étendent à divers domaines d'application tels que le traitement automatique du langage naturel (*défini ci-après*), la vision par ordinateur ou la robotique. L'usage du terme d'IA permet par ailleurs de dépasser la seule dimension technologique, puisqu'il intègre également les répercussions professionnelles, culturelles et sociétales liées à l'automatisation des processus et aux systèmes intelligents. COLAVIZZA Giovanni et alii, « Archives and AI : An Overview of Current Debates and Future Perspectives », *Journal on Computing and Cultural Heritage*, vol. 15, n° 1, 2022, p. 4.

4. CLAVERT et MULLER, « L'histoire au temps des algorithmes », *art. cit.*, p. 14.

5. PUTNAM Lara, « The Transnational and the Text-Searchable : Digitized Sources and the Shadows They Cast », *The American Historical Review*, vol. 121, n° 2, 2016, p. 378-379.

6. Les éléments du texte signalés par un astérisque « * » renvoient à un lexique explicatif figurant à la fin du mémoire. Afin de ne pas alourdir la lecture, seule la première occurrence est marquée de cet indicateur.

7. SCHMIDT Benjamin, « Do Digital Humanists Need to Understand Algorithms? », in GOLD Matthew K. et KLEIN Lauren F. (dir.), *Debates in the Digital Humanities 2016*, Minneapolis : University of Minnesota Press, 2016, vol. 2.

8. TILTON, « Relating to Historical Sources », *art. cit.*, p. 1354.

lointain⁹. Si sa prédiction concernant l'accessibilité ne peut aujourd'hui être niée¹⁰, la tendance des historien-ne-s à considérer le déluge des sources numérisées comme un acquis a limité l'attention aux seules opportunités offertes par cette abondance¹¹. Alors que la communauté historique s'est volontiers engagée dans le « virage numérique »¹² en s'appuyant sur des technologies intégrant des algorithmes, telles que les moteurs de recherche, une réflexion concomitante sur la transformation des pratiques de recherche et sur ses implications n'a pas entraîné l'ouverture d'un espace de discussions explicites¹³. Notons néanmoins qu'une telle observation n'implique pas nécessairement que les historien-nes ignorent et négligent les limites inhérentes aux sources numériques. Dans une étude récente sur les utilisateurs de collections d'archives numériques, Coburn offre un correctif empirique à ce propos, documentant la conscience préalable des historien-nes à l'égard de ce qu'il désigne par la « sélectivité numérique », à savoir les biais introduits par la numérisation, qu'ils soient de nature techniques, économiques ou relatif à la perte de contexte archivistique¹⁴.

Il existe toutefois un écart entre, d'une part, la prise de conscience des historien-ne-s quant à l'usage des ressources numériques, et d'autre part, la problématique préalable du mode de constitution et de sélection de leurs corpus*, de même que de l'influence que les ressources numériques sont susceptibles d'exercer sur l'orientation et la configuration de la recherche historique. Comme le suggère Zaagsma, « [...] il semble y avoir un décalage entre l'adoption des ressources numériques par les historien-ne-s et leur appréciation et compréhension de la manière dont elles sont créées et, plus généralement, de la manière dont notre base de preuves en ligne est constituée et façonne la recherche historique »¹⁵. Qu'il s'agisse de la recherche par mot-clé¹⁶ ou de la re-

9. ROSENZWEIG Roy, « Scarcity or Abundance? Preserving the Past in a Digital Era », *The American Historical Review*, 2003, p. 735-762.

10. GRAHAM Shawn *et alii*, « The Joys of Big Data for Historians », in *Exploring Big Historical Data*, WORLD SCIENTIFIC, 2022, p. 4-19.

11. CRYMBLE Adam, *Technology and the Historian : Transformations in the Digital Age*, University of Illinois Press, 2021 ; FICKERS Andreas, « Towards a New Digital Historicism?: Doing History in the Age of Abundance », *VIEW Journal of European Television History and Culture*, vol. 1, n° 1, 2012, p. 19 ; ROMEIN C. Annemieke *et alii*, « State of the Field : Digital History », *History*, vol. 105, n° 365, 2020, p. 291-312.

12. PUTNAM, « The Transnational and the Text-Searchable », *art. cit.*, p. 380.

13. HITCHCOCK Tim, « Confronting the Digital : Or How Academic History Writing Lost the Plot », *Cultural and Social History*, vol. 10, n° 1, 2013, p. 9-23 ; MILLIGAN Ian, *The Transformation of Historical Research in the Digital Age*, Cambridge : Cambridge University Press, 2022¹.

14. COBURN Jon, « Defending the digital : Awareness of digital selectivity in historical research practice », *Journal of Librarianship and Information Science*, vol. 53, n° 3, 2021, p. 398-410.

15. ZAAGSMA Gerben, « Digital History and the Politics of Digitization », *Digital Scholarship in the Humanities*, vol. 38, n° 2, 2023, p. 830. *trad.*

16. PUTNAM, « The Transnational and the Text-Searchable », *art. cit.*

cherche plein-texte¹⁷, le déplacement de la forme traditionnelle de recherche vers un espace de consultation numérique supporté par des algorithmes soulève des enjeux épistémologiques et méthodologiques. D'une part, l'utilisation de requêtes basées sur des termes spécifiques tend à renforcer les hypothèses initiales des chercheur·ses en imposant des cadres interprétatifs contemporains sur des contextes historiques, dont le risque est de générer une recherche décontextualisée et de compromettre la représentativité des sources. Les biais préexistants sont dès lors systématiquement confirmés, ce qui entrave l'émergence d'interprétations alternatives et peut conduire à une lecture réductrice de la complexité historique, écartant ainsi les pistes de réflexion non anticipées par le cadre de recherche initial. En ce sens, un tel procédé restreint la sérendipité du travail historique en délimitant un espace de recherche dont les contours sont prédéterminés. D'autre part, l'approche confirmatoire des données se manifeste par une dépendance à des algorithmes dont les mécanismes internes - basés sur des modèles statistiques complexes et des mesures de pertinence - ne sont pas rendus visibles. Cette opacité masque la manière dont les résultats sont triés et filtrés, rendant difficile l'évaluation critique de l'impact de ces outils sur la sélection des sources et la formulation de conclusions. À cet égard, il semble que les historien·ne·s n'interrogent encore que trop rarement les raisons, les modalités et les lieux de l'accès aux sources à l'ère numérique, ainsi que les conséquences de cet accès sur leurs recherches, tant sur le plan des conditions de production que de la validation du savoir historique¹⁸.

À cette observation s'ajoute l'amélioration des capacités de recherche actuelles. L'application récente de techniques de traitement automatique du texte ouvre la possibilité d'étendre l'exploration au-delà de la recherche par mot-clé ou de la navigation, allégeant ainsi la recherche fastidieuse de vastes collections basées sur des métadonnées¹⁹. À cet égard, les pratiques récentes d'exploration de texte²⁰ via une approche de lecture distante sont exemplaires²¹. Or, l'adoption d'une telle méthodolo-

17. UNDERWOOD Ted, « Theorizing Research Practices We Forgot to Theorize Twenty Years Ago », *Representations*, vol. 127, n° 1, 2014, p. 64-72.

18. FICKERS Andreas, « Veins filled with the Diluted Sap of Rationality : A Critical Reply to Rens Bod », *BMGN - Low Countries Historical Review*, vol. 128, n° 4, 2013, p. 155-163 ; KÖNIG Mareike, « Geschichte digital : Zehn Herausforderungen », in *Geschichtswissenschaft im 21. Jahrhundert*, De Gruyter, 2020, p. 67-76.

19. Dans la recherche historique, les métadonnées se définissent comme des « données sur les données » : elles constituent un modèle décrivant le contenu, le contexte et la structure des sources afin d'en garantir la recherche. Elles imposent une normalisation des éléments descriptifs afin de maintenir la cohérence des corpus et la fiabilité des requêtes, qu'il s'agisse de textes, d'images ou d'autres supports documentaires. STEINER Elisabeth, *Metadaten (allgemein)*, 2021.

20. GULDI Jo, « The Revolution in Text Mining for Historical Analysis is Here », *The American Historical Review*, vol. 129, n° 2, 2024, p. 519-543.

21. De manière liminaire, le concept de lecture distante vise à générer une vision abstraite d'un ou plu-

gie concourt à de nombreux « dangers », pour reprendre les termes de Guldi²², le risque étant d'adopter une approche naïve à l'égard des données issues des textes historiques²³.

Si certains projets ont trouvé dans les débats parlementaires un matériel d'exploration pertinent²⁴, une attention particulière s'est récemment portée sur la presse numérisée²⁵. À ce propos, il convient de noter que les interfaces utilisateurs, qui rendent possibles l'accès et l'exploration des contenus, présentent un déficit de transparence. En effet, ces dernières ne fournissent que trop rarement des informations explicites sur les transformations que les documents subissent. Comme l'ont soutenu Ehrmann *et alii*. « [l]es utilisateurs doivent être conscients des conséquences, des biais et des opportunités résultant du traitement et de la datafication²⁶. Les interfaces utilisateurs, dont le but est de servir de passerelles vers ce contenu enrichi et de relayer ces informations, jouent un rôle majeur à cet égard. »²⁷. Avant même qu'un historien-ne ne commence à penser à l'exploration de données, les sources mêmes - et donc les preuves - qui façonneront la manière dont l'histoire est racontée sont souvent déjà filtrées par des prises de décision algorithmiques. Ainsi, l'absence de transparence sur les choix pris par les algorithmes, les scores de performances, les sources et les méthodes d'enrichissement ainsi que de supports pédagogiques induit le risque de produire des résultats aléatoires²⁸. En raison des limites induites dans la capacité des utilisateurs à interpré-

sieurs textes à partir de méthodes computationnelles, passant de l'observation de leurs contenus à la visualisation de leurs caractéristiques globales. Ce dernier est à mettre en opposition avec la lecture proche (*close reading*) qui valorise la lecture approfondie d'un nombre réduit d'ouvrages. Sur la lecture distante, voir en particulier MORETTI Franco, *Distant Reading*, London : Verso, 2013..

22. GULDI Jo, *The Dangerous Art of Text Mining : A Methodology for Digital History*, Cambridge University Press, 2023¹.

23. Guldi identifie trois dangers principaux. Premièrement, la nature fondamentalement incomplète des archives induit le risque d'une représentativité limitée. Secondement, les données textuelles contiennent inévitablement des erreurs et des biais historiques structurels qui compromettent leur fiabilité. Enfin, les chercheur-se-s sont susceptibles d'être influencés par l'illusion d'une prédiction sur le passé, concourant ainsi à démarche interprétative biaisée. GULDI, *The Dangerous Art of Text Mining*, *op. cit.*, p. 25-56.

24. A titre d'exemple nous pouvons citer l'accès aux documents législatifs de divers organismes politiques de l'Union Européenne de 1952 à 1994. EUROPEAN PARLIAMENT, Ask the Archives : The EP Archives Unit Launches its first Generative AI tool, 02.2025.

25. EHRMANN Maud *et alii*, « Digitised Historical Newspapers : A Changing Research Landscape », in BUNOUT Estelle *et alii* (dir.), *Digitised Newspapers – A New Eldorado for Historians ?*, De Gruyter, 2022, p. 1-22.

26. Par datafiction ou mise en données, nous entendons le « [...] processus contenant toutes les étapes allant de la numérisation d'un artefact physique – les archives numérisées – ou de la captation d'un signal – les sources primaires nées numériques – aux possibilités d'analyser ces artefacts et signaux via des outils informatiques, c'est-à-dire une lecture des sources au moyen d'une médiation informatique. » CLAVERT Frédéric, « Une histoire par les données ? Le futur très proche de l'histoire des relations internationales », *Bulletin de l'Institut Pierre Renouvin*, vol. N° 44, n° 2, 2016, p. 120.

27. EHRMANN Maud *et alii*, « Historical Newspaper User Interfaces : A Review », *IFLA WLIC 2019 - Athens, Greece - Libraries : dialogue for change*, vol. 85, 2019, p. 2. *trad.*

28. TILTON, « Relating to Historical Sources », *art. cit.*, p. 1355.

ter de manière critique, ces derniers sont susceptibles d'introduire des généralisations excessives qui sapent la complexité historique et l'interprétation nuancée qu'elle requiert. Si les interfaces *Impresso*²⁹ ou *NewsEye*³⁰ contrebalancent avec cette tendance en mettant l'accent sur la transparence et la collaboration interdisciplinaire, il reste à souligner que ces initiatives restent minoritaires³¹. Dans cette optique, il convient de s'interroger sur la prise de décision algorithmique qui façonne simultanément l'accès et l'analyse aux sources numérisées.

Ces considérations méritent de s'appliquer au contexte d'édition scientifique. Comme l'ont soutenu Romein *et alii*, les transformations numériques ont considérablement élargi les possibilités dans le domaine de l'édition, tant sur l'accès que l'exploration des textes. Cette perspective invite à reconsidérer l'édition numérique, non plus uniquement comme un support numérique de présentation de sources analogiques, mais comme un ensemble de données structurées pouvant être traitées au moyen de divers algorithmes³². Suivant ce propos, il convient reconsidérer la dépendance traditionnelle du texte à sa forme. Dans un processus de transformation fondamentale des médias qu'il qualifie de « transmédialisation », Sahle a soutenu que le texte d'édition est davantage à concevoir comme une ressource d'information modélisée que comme un contenu figé dans un format analogique ou rétro-numérisé. En remplaçant la notation inscrite par une modélisation abstraite à l'aide de langages de balisage

29. Le projet de recherche interdisciplinaire *impresso - Media Monitoring of the Past* a contribué entre 2017 et 2020 à la mise en données d'un corpus multilingue de journaux suisses et luxembourgeois numérisés. Afin de permettre une exploration critique et transparente d'articles de presse à grande échelle, une équipe de linguistes computationnels, de concepteur·rice·s et d'historien·ne·s ont collaboré pour améliorer les outils d'exploration de textes historiques, enrichir les journaux historiques avec des données générées (semi-)automatiquement et intégrer ces données dans les flux de travail de recherche historique au moyen d'une interface utilisateur. EHRMANN Maud, « Explorer la presse numérisée : le projet *Impresso* », *Revue Historique Vaudoise*, vol. 129, 2021, p. 159-173.. Depuis 2024, un second volet nommé *Impresso Media Monitoring of the Past - Beyond Borders : Connecting Historical Newspapers and Radio* s'est ouvert et complétant le corpus de presse par des archives radios numérisées multilingues. Toujours soutenu par une collaboration interdisciplinaire, le projet actuel vise à ouvrir la voie pour l'exploration conjointe de sources journalistiques et radiophoniques dans le cadre de recherches transmédias et transnationales. EHRMANN Maud *et alii*, *Impresso - Media Monitoring of the Past II. Beyond Borders : Connecting Historical Newspapers and Radio.*, 2023.

30. S'il partage avec *Impresso* une approche commune en termes d'outils, de méthodes d'exploration et de coopération interdisciplinaire, le projet européen *NewEye* se distingue par le fait qu'il fournit un assistant de recherche intelligent fondé sur l'IA, capable d'analyser automatiquement des corpus multilingues à grande échelle et de générer automatique de rapports. NEWS EYE, *NewsEye : A Digital Investigator for Historical Newspapers*, 12.2023.

31. OBERBICHLER Sarah *et alii*, « Integrated interdisciplinary workflows for research on historical newspapers : Perspectives from humanities scholars, computer scientists, and librarians », *Journal of the Association for Information Science and Technology*, vol. 73, n° 2, 2022, p. 225-239; EHRMANN Maud *et alii*, « Historical Newspaper Content Mining : Revisiting the *impresso* Project's Challenges in Text and Image Processing, Design and Historical Scholarship », 2020.

32. SPADINI Elena, « Producing Scholarly Digital Editions », in *Reassembling the Republic of Letters in the Digital Age. Standards, Systems, Scholarship*, Göttingen University Press, 2019, p. 251-260.

informatique, le contenu du texte se voit être dissocié de son support, le traduisant en un ensemble de données structurées et modulables. Adopter une orientation axée sur les données renouvelle le texte dans une représentation transmédiatique en lui conférant la capacité d'être reconfiguré et réutilisé dans divers contextes et formats. En recentrant l'information sur sa structure essentielle, le travail d'édition numérique privilégie l'abstraction des éléments textuels en les transformant en données modulables et interopérables³³. Dans sa forme numérique, l'édition savante peut alors être appréhendée comme un système d'information en ce qu'elle repose sur une modélisation explicite des données, une infrastructure technique interopérable et une méthodologie fondée sur un paradigme numérique³⁴. Elle permet ainsi la structuration, la consultation, l'interrogation et la réutilisation critique des sources au sein d'un environnement de recherche numérique³⁵.

Le postulat selon lequel le contenu d'une édition peut être envisagé comme un ensemble de données et, de fait, être soumis à une lecture machinique intégrant l'IA, a récemment fait l'objet de réflexions. D'un point de vue analytique, l'édition se présente comme un corpus numérique accessible en *open source*, où les données éditoriales sont extraites en formats exploitables par des algorithmes, ouvrant la possibilité d'effectuer des analyses statistiques approfondies et de visualiser des tendances éditoriales à partir de grandes collections textuelles.³⁶ Sous l'angle des modes de production éditoriale, elle ouvre la voie à la création de corpus massifs, où le traitement manuel est progressivement remplacé par l'automatisation, menant à une *édition dis-*

33. SAHLE Patrick, « Inhalt und Form : Medienwandel als Transmedialisierung », in *Digitale Editionsformen*, Norderstedt : BoD, 2013, vol. II, p. 157-165.

34. Sahle ne formule pas de définition formelle du paradigme numérique. Il identifie plutôt un ensemble de critères qui, pris ensemble, traduisent une reconfiguration radicale du projet éditorial induite par l'utilisation de technologies numériques et médiatiques par opposition aux modalités traditionnelles de l'édition analogique. En rupture avec le concept statique de publication définitive, qui se matérialise à travers l'ouvrage imprimé, l'édition numérique se définit comme un processus en constante évolution, dont le travail éditorial peut être mis à jour en continu. De plus, la nature collaborative de l'édition numérique suggère qu'elle est susceptible d'être continuellement enrichie par des contributions pluridisciplinaires et externes. Par conséquent, la figure de l'éditeur-riche unique se voit être complétée par des experts techniques, des chercheurs, de même que des contributions issues du *crowdsourcing*. En remodelant la structure du texte d'origine, l'intégration multimédia offre par ailleurs une multiplicité de forme de représentation de se dernier, allant du facsimilé à la transcription critique, tout en passant par des versions annotées et traduites. Enfin, l'intégration de l'hypertextualité facilite des parcours non linéaires et une adaptabilité des usages en interconnectant différentes couches informationnelles. SAHLE Patrick, « What is a Scholarly Digital Edition? », in DRISCOLL Matthew James et PIERAZZO Elena (dir.), *Digital Humanities Series*, Cambridge, UK : Open Book Publishers, 2016¹, vol. 4, p. 19-40.

35. OLTMANNS Elias *et alii*, « Different Preservation Levels : The Case of Scholarly Digital Editions », *Data Science Journal*, vol. 18, 2019, p. 51 ; SAHLE Patrick et VOGELER Georg, *Criteria for Reviewing Scholarly Digital Editions*, 06.2014.

36. JANNIDIS Fotis, « Computational Literary Studies and Scholarly Editing », in COHEN Matt *et alii* (dir.), *Futures of Digital Scholarly Editing*, Minneapolis : University of Minnesota Press, 2025.

tante pour reprendre les termes de Pierrazo³⁷.

La reconfiguration du processus de transmission textuel qui en résulte occasionne ainsi « [...] de nouvelles pratiques de traitement du texte, notamment avec la mise en place de chaînes d'acquisition plus ou moins automatisées, de la numérisation des sources à la mise à disposition d'un texte numérique »³⁸. Dans le cadre de ces évolutions, Hodel a indiqué que « [...] l'extraction d'informations peu[t] être facilement pri[s] en charge par des algorithmes au moyen de l'intelligence artificielle »³⁹. Cette dernière considération requiert une attention particulière pour saisir l'impact de l'IA dans les pratiques éditoriales, et plus particulièrement celles relatives à l'indexation. L'extraction d'information consiste à repérer, dans de grandes collections, une information spécifique ; elle repose sur la création d'une « représentation structurée [...] d'informations sélectionnées à partir de textes »⁴⁰. En considérant le contenu textuel d'un point de vue référentiel, les entités nommées s'imposent alors comme une composante-clé à extraire⁴¹. Définies comme des *entités d'intérêts* qui agissent « comme des ancrages référentiels qui sous-tendent la sémantique des textes et guident leur interprétation »⁴², les entités nommées sont généralement catégorisées sous la forme d'une triade : personnes, organisations et lieux⁴³. Sur le plan pratique, les systèmes d'extraction d'information ont pour objectif de reconnaître les séquences textuelles relatives à ces entités et de les étiqueter en référence aux catégories prédéterminées. L'étape ultérieure consiste en la liaison - également désigné sous le nom de désambiguïsation - des mentions d'entités nommées à une référence unique dans une base de connaissance ou un fichier d'autorité.

Leur réalisation repose sur l'application de techniques informatiques de traitement du langage humain, qualifiée sous le terme de traitement automatique du langage⁴⁴. Si

37. PIERAZZO Elena, « Distant Editing. The Challenges of Computational Methods to the Theory and Practice of Textual Scholarship », in COHEN Matt *et alii* (dir.), *Futures of Digital Scholarly Editing*, Minneapolis : University of Minnesota Press, 2025.

38. PINCHE Ariane, « Des plumes aux pixels : actualité de l'édition scientifique numérique », *Théia. Revue d'histoire et d'histoire de l'art*, vol. 1, 2024.

39. HODEL Tobias Mathias, « Das Ende der Edition ? Ein Blick auf geschichtswissenschaftliche Editionen mit Fokus auf die Frühe Neuzeit – eine Provokation », in, University of Bern, 2024, p. 1. *trad.*

40. COLAVIZZA Giovanni *et alii*, « Index-Driven Digitization and Indexation of Historical Archives », *Frontiers in Digital Humanities*, vol. 6, 2019, p. 4.

41. COLAVIZZA *et alii*, « Index-Driven Digitization and Indexation of Historical Archives », *art. cit.*

42. EHRMANN Maud *et alii*, « Named Entity Recognition and Classification in Historical Documents : A Survey », *ACM Computing Surveys*, vol. 56, n° 2, 2024, p. 2. *trad.*

43. *Ibid.*

44. « Par traitement du langage [naturel], nous entendons les techniques informatiques qui traitent [...] le langage humain écrit, en tant que langage. » *trad.* JURAFSKY Dan *et alii*, *Speech and Language Processing : An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition*, Upper

ce domaine n'est pas nativement lié à l'IA, une attention croissante se porte désormais sur l'apprentissage profond du fait que ses performances surpassaient les approches d'apprentissage automatique traditionnel et celles basées sur des règles⁴⁵. Ainsi, l'extraction d'information, et plus particulièrement le traitement des entités nommées se présente comme l'une des étapes les plus cruciales du traitement automatisé du texte, en cela qu'il alimente un processus plus vaste d'*enrichissement sémantique*, qui consiste en l'ajout d'une couche d'information sémantique supplémentaire aux méta-données⁴⁶. Les informations textuelles ainsi extraites visent à améliorer l'indexation, de même que la recherche et la navigation au sein de larges collections textuelles⁴⁷. Dans cette perspective, les entités nommées peuvent constituer la base d'un certain nombre d'applications dirigées vers des activités de recherche d'informations. Dans le cas des moteurs de recherche, les entités nommées peuvent être utilisées comme un index pour détecter et accéder à des documents⁴⁸. L'identification des entités nommées est ainsi amenée à répondre à deux questions cardinales de l'analyse des contenus textuels en histoire : le *qui* ? - impliquant ici personnes et organisations - et le *où* ? - déterminant le lieu géographique.

Si les promesses de la numérisation concernant les potentialités d'extraction sémantique se sont jusqu'ici largement concentrées sur le domaine archivistique⁴⁹, une extension au contexte de l'édition numérique semble justifiée, dans la mesure où elle accorde une place centrale aux informations sémantiques présentes dans l'encodage et la description des textes⁵⁰. Dans ce cadre, il a été avancé qu'une approche fondée sur les entités nommées peut grandement faciliter la consultation et l'analyse de documents historiques édités, tout en renforçant l'interopérabilité des corpus grâce à la normalisation des données et à leur intégration dans des écosystèmes de données liés⁵¹. Ainsi, des projets d'éditions de différentes natures expérimentent actuellement

Saddle River, NJ : Prentice Hall, 2025, p. 2.

45. EHRMANN *et alii*, « Named Entity Recognition and Classification in Historical Documents », *art. cit.*, p. 26-27.

46. WILDE Max de et HENGCHEN Simon, « Semantic Enrichment of a Multilingual Archive with Linked Open Data », *Alliance of Digital Humanities Organizations*, vol. 11, n° 4, 2017, p. 1-16.

47. COLAVIZZA *et alii*, « Archives and AI », *art. cit.*

48. NOUVEL Damien, *Named Entities for Computational Linguistics*, London : ISTE, 2016, p. 133.

49. COLAVIZZA *et alii*, « Index-Driven Digitization and Indexation of Historical Archives », *art. cit.* ; EHRMANN *et alii*, « Named Entity Recognition and Classification in Historical Documents », *art. cit.*

50. VAN ZUNDERT Joris J., « The case of the bold button : Social shaping of technology and the digital scholarly edition », *Digital Scholarship in the Humanities*, vol. 31, n° 4, 2016, p. 899.

51. KURZ Stephan, « Transkription und Annotation. Die Eingabeseite digitaler Editionen », in *Digital Humanities in den Geschichtswissenschaften*, Böhlau Verlag Wien : Verlag, 2023, p. 333-347 ; ANANIEVA Anna *et alii*, « The Study of Historical Travelogues from a Digital Humanities Perspective : Experiences and New

des approches d'extraction de l'information⁵². S'inscrivant dans cette dynamique, le centre de recherche des *Documents diplomatiques suisses* (Dodis) a depuis peu exploré les opportunités offertes par les technologies d'IA, « aussi bien au niveau des processus de production que de l'accès et l'analyse des données »⁵³. Si l'édition scientifique numérique en histoire accuse un certain retard en Suisse, et ce, en dépit de l'évolution rapide des pratiques de lecture et des exigences grandissantes en matière d'*Open Access*⁵⁴, il convient de souligner le rôle pionnier de Dodis par son recours anticipé à l'informatique, dont la mise en ligne de documents et l'accès à sa base de données via le *World Wide Web* datent du tournant des années 2000⁵⁵. Dans ce cadre, il convient de noter que le centre de recherche a très tôt reconnu un intérêt particulier pour l'indexation des entités d'intérêts présentes dans le contenu des documents historiques. En 1997, Marc Perrenoud identifiait ce qu'il désignait comme « les trois catégories principales d'information » extraites des 2026 sources alors indexées dans la base de données, à savoir 4085 personnes, 2226 organisations et 852 termes géographiques⁵⁶. Ce travail d'indexation s'est poursuivi de manière soutenue : entre 1997 et avril 2005, la saisie et la mise en ligne de quelques 6000 documents ont porté ces chiffres à environ 12 000 personnes, 6000 organisations et 3000 toponymes, chacun étant relié à au moins un document accessible⁵⁷. Si cette approche constitue des contributions notables en matière de recherche numérique pour les historien·ne·s, il convient de rappeler que l'identification des entités, tout comme la recherche de leurs identifiants normalisés, demeure en grande partie la tâche des chercheur·se·s⁵⁸. Face à ce constat, l'intégration des technologies de l'IA se présente comme un substitut efficace à cer-

Approaches », *Comparative Southeast European Studies*, vol. 72, n° 3, 2024, p. 370-385.

52. Notamment KOOLEN Marijn *et alii*, « The Value of Preexisting Structures for Digital Access : Modeling the Resolutions of the Dutch States General », *Journal on Computing and Cultural Heritage*, vol. 16, n° 1, 2023, p. 1-24., GÖRMAR Maximilian, « La reconnaissance d'entités nommées dans les éditions numériques à l'exemple du récit de voyage du pharmacien Wagener », GÖBEL Angela (trad.), *Théia*, n° 1, 2024., ANANIEVA *et alii*, « The Study of Historical Travelogues from a Digital Humanities Perspective », *art. cit.*

53. DIPLOMATISCHE DOKUMENTE DER SCHWEIZ - DOCUMENTS DIPLOMATIQUES SUISSES - DOCUMENTI DIPLOMATICI SVIZZERI, « Jahresbericht 2023 - Rapport annuel 2023 - Rapporto annuale 2023 », 2024, p. 6.

54. NATALE Enrico et KURMANN Eliane, « L'Édition Historique à l'Ère Du Numérique. Un État Des Lieux Du Débat En Suisse. », *traverse. Revue d'histoire / traverse - Zeitschrift für Geschichte*, vol. 3, 2014, p. 135-146.

55. Hodel a repéré une première capture d'écran du site web de Dodis datée du 5 janvier 2001 sur archive.org. HODEL Tobias, « Eine Zunft im digitalen Wandel : die Editionswissenschaften 2.0 in der Schweiz », 2021. Concernant sa base de données, elle apparaît pour la première fois dans l'avant-propos du seizième volume de l'édition publié en 1997. FLEURY Antoine, *Documents Diplomatiques Suisses*, Zürich Locarno Genève : Chronos A. Dadò Genève, 1997, VII.

56. PERRENOUD Marc, « Outils informatiques et documents diplomatiques : L'exemple d'une base de données sur les relations internationales et la politique étrangère de la Suisse », in *Diplomatic sources and international crises*, Rome, 1996, p. 53-54.

57. FLEURY Antoine, *Les Documents diplomatiques suisses*, p. 5.

58. SIBILLE Christiane, « Networking Digital Documents », in *Studies in Historical Documents from Nepal and India*, Heidelberg University Publishing, 2018, p. 195.

taines opérations de production éditoriales, en particulier à la tâche d'annotation des entités. S'il convient de souligner que le projet d'enrichissement sémantique conserve une dimension expérimentale, notons malgré tout qu'une intégration à long terme à l'infrastructure est envisagée⁵⁹.

Dès lors que l'automatisation des tâches de traitement de texte offre des perspectives particulièrement réjouissantes pour les éditeur·rice·s - en ce qu'elle permet de pallier à des tâches manuelles et chronophages⁶⁰ - elle se révèle par la même occasion potentiellement transformatrice, tant sur le plan des potentialités de recherche et d'exploration d'information, que du point de vue des biais et des limitations qu'elle peut induire. L'indexation sémantique, fondée sur la détection et la structuration des entités, constitue un levier majeur en ce qu'elle permet d'orienter efficacement l'identification, la contextualisation et la mise en relation de multiples sources documentaires⁶¹. Interagir avec des sources par l'intermédiaire d'une interface utilisateur invite en parallèle d'interroger les *logiques* de conception des systèmes numériques qui rendent ces interactions possibles, ainsi que les conséquences de ces logiques sur notre compréhension des documents historiques⁶². Si cette réflexion s'applique aux archives numériques, elle peut être étendue à l'édition savante numérique, dans la mesure où elle repose sur une approche de conception, de structuration et d'interaction avec les sources historiques intrinsèquement liée à l'utilisation d'algorithmes pour le traitement de l'information et de systèmes d'information pour leur organisation et leur accès⁶³.

Cependant, la recherche historique ne semble pas avoir engagée une véritable réflexion méthodologique sur l'articulation entre les informations structurées sous forme de données et les dispositifs numériques qui les prennent en charge. En outre, la médiation numérique des sources ne semble être guère prise en compte et reste largement invisible sur le plan méthodologique⁶⁴. Sur les éditions numériques, Vogeler a soutenu

59. STEINER Tobias, ML bei Dodis, Berne, 02.2024. Cette présentation s'est déroulée dans le cadre d'un échange organisé sur le thème « Usage pratique des IA dans des projets d'humanités digitales ». DOCUMENTS DIPLOMATIQUES SUISSES, Dodis goes AI, 01.2025.

60. SELINA Galka, Anwendung von NER auf die Memoiren der Gräfin von Schwerin, 06.2024.

61. EHRMANN *et alii*, « Named Entity Recognition and Classification in Historical Documents », *art. cit.*

62. JENSEN Helle Strandgaard, « Digital Archival Literacy for (All) Historians », *Media History*, vol. 27, n° 2, 2021, p. 7.

63. VOGELER Georg *et alii*, « „Ich glaube, Fakt ist...“ : Der geschichtswissenschaftliche Zugang zum digitalen Edieren », in DÖRING Karoline Dominika *et alii* (dir.), *Digital History*, De Gruyter, 2022, p. 177-178.

64. FRIDLUND Mats, « Digital History 1.5 : A Middle Way between Normal and Paradigmatic Digital Historical Research », in FRIDLUND Mats *et alii* (dir.), *Digital Histories : Emergent Approaches within the New Digital History*, Helsinki University Press, 2020, p. 76.

que « [d]ans la pratique, elles sont acceptées, exigées, leur qualité est louée ou critiquée, mais elles ne sont pas mises en relation avec l'épistémologie de la science historique. Elles sont en quelque sorte transparentes par rapport aux sources elles-mêmes. »⁶⁵. À cette observation, Zundert ajoute que l'adoption de technologies numériques dans le domaine de l'édition semble avoir davantage conduit à une « régression paradigmatique », dans laquelle ces technologies sont interprétées à travers le prisme des conventions et des pratiques héritées du format analogique. Les limites imposées aux utilisateurs d'une représentation visuelle héritée du monde de l'imprimé - en particulier à travers le format HTML qui sous-tend la conception des pages web - ont eu ainsi pour conséquence de masquer la logique sous-jacente de l'encodage sémantique et les fonctionnalités computationnelles qu'elle autorise⁶⁶. Le propos selon lequel les interfaces utilisateurs ne sont que la surface de l'édition doit nous alerter sur le fait qu'elles sont susceptibles de résulter d'un processus d'extraction d'informations, en particulier de reconnaissance et de liaison d'entités nommées.

Ainsi, l'objectif affiché selon lequel l'application de telles méthodes consiste à « créer un texte fiable, soumis à une critique textuelle classique, et d'en extraire les informations utiles aux historien-ne-s »⁶⁷ exige d'être mise en perspective avec le déploiement d'algorithmes qu'elles mobilisent en arrière-plan. Leurs mises en œuvre, notamment lorsqu'elle s'appuie sur des techniques d'apprentissage profond, soulèvent cependant des questions cruciales quant à leur transparence. Ces modèles, qui reposent sur des processus décisionnels automatisés, deviennent des « boîtes noires », dont le fonctionnement interne reste largement opaque pour les historien-ne-s⁶⁸. Pierazzo a récemment soutenu que l'intégration des outils d'IA dans le processus éditorial redéfinit en profondeur le contrôle critique et la transparence des analyses textuelles. En déléguant une partie du travail éditorial à des algorithmes, l'historien-ne ne peut plus se limiter à observer et contrôler chaque opération manuelle effectuée par l'éditeur-riche⁶⁹.

65. VOGELER *et alii*, « „Ich glaube, Fakt ist..." », *art. cit.*, p. 185. *trad.*

66. VAN ZUNDELT, « The case of the bold button », *art. cit.*, p. 901.

67. VOGELER Georg, « The "assertive edition" : On the consequences of digital methods in scholarly editing for historians », *International Journal of Digital Humanities*, vol. 1, n° 2, 2019, p. 313. *trad.*

68. SCHWANDT Silke, « OPENING THE BLACK BOX OF INTERPRETATION : DIGITAL HISTORY PRACTICES AS MODELS OF KNOWLEDGE », *History and Theory*, vol. 61, 2022, p. 77-85; WEBER Dominic, « On the Historiographic Authority of Machine Learning Systems », 2024; HODEL Tobias, « Die Maschine und die Geschichtswissenschaft : Der Einfluss von deep learning auf eine Disziplin », in DÖRING Karoline Dominika *et alii* (dir.), *Digital History*, De Gruyter, 2022, p. 65-80.

69. PIERAZZO, « Distant Editing. The Challenges of Computational Methods to the Theory and Practice of Textual Scholarship », *art. cit.*

De ce point de vue, la transformation des sources historiques en objets de données complexes, de même que l'intégration d'outils de traitement automatique, soulève autant des défis méthodologiques qu'épistémologiques.⁷⁰ Afin de garantir une compréhension maîtrisée des processus de production du savoir historique et ne pas laisser passivement « les algorithmes faire leur magie »⁷¹, une réflexion critique et méthodologique capable de confronter les spécificités techniques des modèles computationnels aux exigences disciplinaires de l'histoire s'avère souhaitable⁷². Au regard de ce qui précède, nous proposons de nous interroger sur les éléments suivants :

Comment l'utilisation de techniques automatisées de reconnaissance et de liaison d'entités nommées, appliquées aux Documents diplomatiques suisses, modifie-t-elle concrètement l'interprétation des sources historiques ? Plus précisément, comment les processus algorithmiques influencent-ils l'élaboration du corpus d'investigation et les résultats de recherche historique qui en résultent ?

Aborder les tâches d'enrichissement dans le cadre de l'édition scientifique nécessite de se situer au niveau de la production de l'information historique, en amont de sa mise à disposition auprès des utilisateurs finaux⁷³. Dans ce cadre, Dodis apparaît comme un espace d'expérimentation particulièrement pertinent pour explorer l'introduction du traitement automatisé sur des documents édités, tant sur le plan de l'annotation de leur contenu que de leur indexation. Le présent travail s'attache donc à explorer les opportunités offertes par la reconnaissance et la liaison d'entités nommées dans le contexte spécifique d'une édition scientifique historique, tout en soumettant sa mise en œuvre à un appareil critique. Pour appréhender ces tâches d'enrichissement sémantique, notre objectif est de proposer une approche hybride, alliant des composantes techniques et herméneutiques, dans le but de contribuer aux champs des humanités numériques et à la science historique. Nous adoptons la perspective proposée par Althage *et alii* selon laquelle la production de connaissance réside autant dans l'application de méthodes numériques aux objets traditionnels de la recherche historique que

70. EHRMANN *et alii*, « Digitised Historical Newspapers », *art. cit.*

71. KORKEAMÄKI Laura et KUMPULAINEN Sanna, « Interacting with Digital Documents : A Real Life Study of Historians' Task Processes, Actions and Goals », in *Proceedings of the 2019 Conference on Human Information Interaction and Retrieval*, Glasgow Scotland UK : ACM, 2019, p. 35-43.

72. HOOLAND Seth van et COECKELBERGS Mathias, « Exploring Large-Scale Digital Archives – Opportunities and Limits to Use Unsupervised Machine Learning for the Extraction of Semantics », in *Handbook of Digital Public History*, De Gruyter Oldenbourg, 2022, p. 517-530.

73. BOONSTRA Onno *et alii*, *Past, Present and Future of Historical Information Science*, s.l. : DANS, 2006 ; MEROÑO-PEÑUELA Albert *et alii*, « Semantic technologies for historical research : A survey », *Semantic Web*, vol. 6, n° 6, 2014, p. 539-564.

dans l'adoption d'une approche analytique, inspirée des sciences historiques, pour interroger l'infrastructure informatique et ses objets numériques, tels que les données et les outils⁷⁴. À cette fin, nous proposons d'articuler cette recherche méthodologique de la manière suivante.

La première partie proposera d'établir les fondations sur lesquelles repose la présente recherche. L'édition scientifique sera d'abord présentée dans son articulation au domaine de recherche historique, considérant les reconfigurations induites par le numérique. Dans le sillage des humanités numériques, nous traiterons des reconfigurations offertes par les technologies de l'information, où une attention particulière sera portée au standard d'annotation des textes édités. Nous proposerons par la suite d'exposer les principes fondamentaux de la reconnaissance et la liaison d'entités nommées et les enjeux que soulèvent ces approches lorsqu'elles qu'elles sont appliquées à des documents historiques. Une revue systématique de la littérature nous permettra de mettre en évidence l'attention modeste accordée dans le champ historique. En étendant notre exploration à des champs de recherches connexes, nous mettrons en évidence un écueil : celui d'une recherche majoritairement tournée vers la performance statistique des modèles d'entités nommées.

Pour remédier à ces constats, nous proposerons, dans la section suivante, de combiner le besoin de modélisation, tel qu'exprimé par les humanités numériques, aux exigences d'une réflexion critique sur les sources historiques – envisagées ici comme des données numériques – ainsi que sur les outils numériques avec lesquels elles interagissent. Sur la base de ces considérations, nous détaillerons notre approche méthodologique, articulée autour du concept de *digital scopes*⁷⁵. À la suite des travaux de Koolen et Hoekstra, nous soutiendrons que l'acte d'interprétation ne peut être dissocié de l'ensemble du processus de transformation des données historiques, en cela qu'elle est le produit cumulatif d'un ensemble de décisions méthodologiques prises par le chercheur·se. Dans le but de réduire autant que possible l'opacité, la documentation minutieuse de ces transformations à l'aide d'outils spécialisés constituera la condition centrale d'une approche fondée sur la transparence et l'explicitation de chaque étape

74. ALTHAGE Melanie *et alii*, Digitale Methoden in der geschichtswissenschaftlichen Praxis : Fachliche Transformationen und ihre epistemologischen Konsequenzen. Proceedings der Digital History 2023, Berlin, 23.-26.5.2023, Zenodo, 09.2023.

75. HOEKSTRA Rik et KOOLEN Marijn, « Data scopes for digital history research », *Historical Methods : A Journal of Quantitative and Interdisciplinary History*, vol. 52, n° 2, 2019, p. 79-94.

de la chaîne de traitement. En ce sens, la transformation des données sera considérée comme un cheminement interprétatif qui doit être rendu visible et critiquable. Cette section visera par ailleurs à mettre en évidence les différentes échelles de lectures à combiner. Dans cette idée, il sera question de préciser les modalités d'évaluations dans le but d'apprécier les entités détectées de manière nuancée en associant des mesures quantitatives à des appréciations qualitatives.

Notre troisième partie introduira notre cas d'étude. Nous dresserons le portrait du centre de recherche des Documents diplomatiques suisses dans les contributions qu'il offre à la recherche en histoire contemporaine avant de nous atteler à ses pratiques éditoriales. Dans le but de dépasser une lecture purement analogique de l'édition et d'adopter une perspective centrée sur son infrastructure numérique, nous présenterons les processus informatisés des documents édités permettant leur publication sur l'interface dédiée. La description de la mise en données des textes nous permettra de définir les critères du corpus. À ce stade, la modélisation formelle de ce dernier nous permettra d'opérationnaliser notre approche fondée sur le traitement automatisé des textes édités. Dans cette perspective, nous pourrions établir une critique de nos données d'entrées ; il importerait d'analyser leur qualité et leur provenance, tout en pointant les biais potentiels sur les résultats ultérieurs. En identifiant les zones de vigilance du corpus, cette étude préliminaire préparera la mise en place du pipeline* automatisé.

La quatrième partie décrira l'implémentation concrète du pipeline de traitement, en explicitant les choix techniques et en documentant précisément les étapes selon un ordre logique : la configuration logicielle sera dévoilée, puis les étapes d'extractions des entités seront révélées, de même que les stratégies de liaison de ces dernières. Le déploiement ne se limitera pas à une démarche technique, mais visera à démontrer la dimension réflexive qu'elle implique.

La cinquième partie exposera les résultats obtenus. L'analyse quantitative s'appuiera sur des mesures classiques appliquées à l'ensemble du corpus. En complément, l'analyse qualitative s'appuiera sur des études de cas révélant les limites d'une prédiction automatisée. Ces situations mettront en lumière les tensions qui émergent entre l'application de traitement computationnel et les pratiques interprétatives en histoire. Dans cette optique, maintenir un aller-retour constant entre la lecture distante et

proche s'avérera d'autant plus pertinent dans le but de produire des résultats fiables.

La sixième partie prolongera l'analyse en proposant une discussion critique. Elle proposera d'abord une réflexion sur les modélisations sous-jacentes associées à l'architecture neuronale sur laquelle se fonde ce travail. Ensuite, les problématiques liées à l'incertitude introduite dans le cadre de notre approche computationnelle seront examinées. Enfin, nous proposerons d'aborder les entités nommées - et le système d'extraction d'informations dans lesquelles elles s'intègrent - à travers une perspective épistémologique inspirée des travaux sur la nature de l'information historique.

Enfin, la conclusion reviendra sur les apports du travail. Nous tenterons de souligner la capacité à produire des résultats concrets, tout en renouvelant la réflexion critique sur les pratiques éditoriales et historiennes, particulièrement lorsqu'elles s'appuient sur des procédures automatisées.

2 De l'édition savante à l'objet de données : repenser l'inscription numérique du texte historique

Parmi l'infinie variété des *lieux* dans lesquels l'historien-ne puise de l'information, l'édition savante⁷⁶ apparaît comme un espace de premier ordre⁷⁷. En amont de l'exploration approfondie de fonds d'archives, elle offre un accès anticipé à un corpus documentaire rigoureusement établi et contextualisé, facilitant ainsi une analyse préliminaire des phénomènes qu'ils-elles souhaitent approfondir. En cela, les éditions savantes constituent un instrument fondamental de la recherche historique, participant activement à l'élaboration de leur objet de recherche⁷⁸.

Ce propos, extrait d'ouvrages de référence destinés aux étudiant-e-s en histoire, met volontiers en avant les avantages que l'édition offre en termes d'accessibilité et de fiabilité. Du point de vue de l'historiographie, il semble que toutefois l'évocation de ces critères reste cantonnée à la portée instrumentale de l'édition, sans qu'elle s'accompagne d'une analyse méthodologique plus approfondie. Le propos selon lequel, « il n'y a pas de recherche en histoire sans source éditée »⁷⁹ mérite une plus grande attention, tant sur le plan de la définition même de l'édition que sur les transformations induites par son inscription dans un environnement numérique et les pratiques qui en résultent.

2.1 Définir l'édition savante à l'ère numérique : entre tradition critique et *paradigme numérique*

Le terme même d'édition renvoie moins à une définition univoque qu'à une notion polysémique. Il recouvre des pratiques variées selon les traditions disciplinaires, les emprunts théoriques et les aires géographiques, se traduisant dans la pratique par des approches singulières. L'hétérogénéité méthodologique qui en ressort entrave l'idée

76. L'édition savante s'inscrit dans de nombreuses traditions disciplinaires, qui dépasse largement le domaine historique. Pour éviter toutes confusions dans ce qui suit, l'édition - ou tout substantif qui y est - sera uniquement considérée sous une acception historique.

77. ZIMMERMANN Michel *et alii*, « Le commentaire de documents en histoire », 2012, p. 209.

78. BRUNDAGE Anthony, *Going to the sources : a guide to historical research and writing*, Hoboken, NJ : Wiley Blackwell, 2018, p. 111. ZIMMERMANN *et alii*, « Le commentaire de documents en histoire », *art. cit.*, p. 22. PREVENIER Walter et HOWELL M., *From Reliable Sources. An Introduction to Historical Methods*, Cornell University Press, Ithaca, 2001, p. 42.

79. SAHLE Patrick, « Digitale Editionsformen. Teil 1 : Das typografische Erbe », in, Norderstedt : BoD, 2013, p. 39. *trad.*

même d'une cohérence éditoriale d'ensemble ⁸⁰.

Face aux clivages théoriques et méthodologiques, l'approche de Sahle apparaît particulièrement pertinente en formulant une définition à la fois large et inclusive. Selon lui, tout projet éditorial de nature scientifique peut être compris comme une « représentation critique de documents historiques ». La *représentation* renvoie à la transformation - ou recodification - de l'objet édité en un autre média, qu'il soit une reproduction visuelle ou textuelle. Cette opération couvre un large spectre, s'étendant de la reproduction matérielle fidèle à la reconstitution d'une intention ou d'un original perdu. La *critique* est quant à elle appréhendée comme une notion large et ouverte, intégrant tous les processus réflexifs basés sur une démarche savante. En cela, elle désigne toutes les opérations éditoriales, depuis la sélection des objets à éditer jusqu'à leur description, en passant par les choix de transcription, d'annotation et de jugements éditoriaux relatifs à la ponctuation, l'orthographe, et les corrections. Le terme *document* doit ici être compris à la fois comme un terme générique désignant les objets physiques descriptibles et les textes qu'ils contiennent. Enfin, l'adjectif *historique* renvoie ici à la dimension temporelle qui sépare le présent de la production de la transmission du document. En cela, le terme désigne la distance à combler entre notre compréhension actuelle et le besoin d'explication de la réalité historique. Il s'agit en outre de créer un pont entre le passé et le présent, éclairant à la fois sur les conditions d'élaboration et de réception du document. En accordant autant d'importance à la matérialité documentaire qu'à son analyse critique, cette définition permet de concilier les spécificités de chaque tradition éditoriale. Elle offre ainsi un cadre unifié : la pluralité des représentations d'un document n'est plus considérée comme un manque de cohérence, mais comme la preuve de la souplesse et de la richesse d'une démarche qui demeure fondamentalement critique ⁸¹.

Aborder l'édition numérique à partir de cette définition reste pertinent, dans la mesure où les objets et les objectifs de recherche restent identiques à ceux de la production

80. Citons par exemple l'édition historico-critique, héritière des traditions européennes du XIX^e et XX^e siècle, qui déploie un appareillage analytique dense dans une ambition de rigueur philologiques. L'accent est mis sur la présentation des textes, leur genèse et à la documentation des supports textuels. Elle contraste sensiblement avec l'édition documentaire, davantage ancrée dans la tradition américaine, qui privilégie la fidélité stricte au témoin original. Fondée sur une conception du texte comme artefact, cette approche priorise l'accès au contenu informatif du document, minimisant toutes interventions interprétatives. L'idée sous-jacente est que le document vaut avant tout comme source de preuve historique plutôt qu'en tant qu'objet en soi (VAN MIERLO Wim, *Scholarly Editing in Perspective*, Cambridge New York Port Melbourne [etc.] : Cambridge University Press, 2025, p. 1-13.

81. SAHLE, « What is a Scholarly Digital Edition ? », *art. cit.*

imprimée. La distinction fondamentale se situe au niveau de la *forme* de l'édition. Partant de l'opposition entre édition imprimée et numérique, Sahle souligne que chacune est guidée par un paradigme qui lui est propre, impliquant une théorie, une méthode et une pratique spécifique. Contraint aux moyens typographiques de *représentation* de l'information ainsi qu'à sa *présentation* dans l'espace bidimensionnel de la page, l'édition imprimée ne peut restituer la multiplicité des vues pouvant être produites pour un même texte, de même que l'interactivité et les liens hypertextuels qui constituent son dispositif. Sahle insiste sur la distinction entre *représentation* – qui renvoie à la structuration fondamentale du document, en tant que produit d'une transcription ou d'une mise en donnée – et la *présentation*, qui correspond au produit accessible au lecteur ou à l'utilisateur via une interface⁸².

Penser en termes de multiplicité de vues sur le texte conduit en effet à repenser sa conception traditionnelle dans sa forme éditée. L'édition numérique sépare le contenu textuel de la couche de présentation accessible à l'utilisateur, caractéristique indissociablement liée dans la forme imprimée. Le processus d'édition n'est pas la traduction d'un document analogique en une version numérique mais bien une transcription du contenu et de la signification du texte qu'il intègre dans une forme numérique. La transcription est ainsi perçue comme distincte de sa forme et comme indépendant du médium physique. En ce sens, l'édition numérique vient avec une forme d'abstraction, d'éloignement de la matérialité du document vers l'idée que le texte est un contenu qui peut être isolé de la présentation de l'objet physique⁸³. En exposant les choix éditoriaux et en rendant visible les processus d'édition, la forme numérique permet ainsi une évaluation critique plus fine de l'encodage numérique de l'édition afin d'y cerner les possibles interprétations contenues dans le texte et d'en déterminer ce qui est transmis ou perdu. Dans cette configuration, elle dépasse la présentation linéaire et statique de l'imprimé. L'édition numérique, par sa capacité à intégrer des outils de navigation avancés, des options de recherche sophistiquées et une mise en réseau des informations à travers les bases de données, offre au lecteur un accès dynamique et évolutif aux contenus, qualités qui se perdent inévitablement lors de toute conversion en format imprimé. De cette manière, la numérisation, qui consiste en la conversion d'un support traditionnel en données informatiques, ne saurait reproduire l'ensemble

82. SAHLE, « What is a Scholarly Digital Edition ? », *art. cit.*

83. SAHLE Patrick, « Digitale Edition », in JANNIDIS Fotis *et alii* (dir.), *Digital Humanities*, Stuttgart : J.B. Metzler, 2017, p. 234-249.

des propriétés et des potentialités inhérentes à une édition conçue dès l'origine selon le paradigme numérique.

Le paradigme numérique se caractérise ainsi non pas par un passage du support papier au numérique, mais bien par sa « transmédialisation » : une approche résolument axée sur les données numériques, où l'accent est mis sur l'abstraction, la modélisation et les représentations polyvalentes du texte. Ce paradigme, tel qu'articulé dans les études de Sahle, conduit à une réinterprétation de la pratique éditoriale traditionnelle. Plutôt que de produire un texte unique et figé, l'édition numérique savante se présente comme un processus ouvert et itératif. La conception d'une édition numérique ne se limite plus à une opération de transcription, mais renvoie à une approche orientée vers la représentation abstraite de la connaissance de l'éditeur·rice. Cette dernière se formalise à travers des techniques d'encodage et de balisage qui permettent d'extraire et d'organiser les structures intrinsèques du document. En définitive, Sahle nous invite à dépasser l'interprétation centrée sur la transformation des supports de publication — laquelle réduit le changement médiatique contemporain à la simple transition des médias analogiques vers les médias numériques — afin de penser ce tournant comme un déplacement plus profond : celui d'une pensée structurée par les modèles et les données ⁸⁴.

2.2 L'apport des humanités numériques : modéliser la connaissance éditoriale à partir de standards

Le traitement informatisé de documents édités s'est initialement caractérisé par une multitude d'approches diverses dans le domaine de l'édition numérique, reflétant l'absence d'un cadre standardisé partagé par la communauté savante ⁸⁵. Cette fragmentation a eu pour conséquence un manque profond d'interopérabilité, en particulier dans l'échange et l'intégration des ressources textuelles numériques, qui s'est traduit à terme par l'incompatibilité des différents projets éditoriaux ⁸⁶. La prise de conscience des limites imposées par la multiplicité des systèmes d'encodage textuel a conduit à la progressive standardisation des pratiques dès la fin des années 1980. Les humanités

84. SAHLE Patrick, « Zwischen Mediengedundenheit und Transmedialisierung », *Editio*, vol. 24, n° 2010, 2010, p. 23-36.

85. SAHLE et VOGELER, Criteria for Reviewing Scholarly Digital Editions, *cit.*

86. BURNARD LOU, « How modeling standards evolve : The case of the TEI », in *The Shape of Data in Digital Humanities*, Routledge, 2018, p. 107.

numériques doivent, en partie, leur raison d'être à l'essor de l'édition numérique, à laquelle elles demeurent encore aujourd'hui étroitement liées⁸⁷. Ainsi, une relation étroite s'est tissée entre la communauté de la « Text Encoding Initiative » (TEI) et celle des éditeur-riche-s scientifiques numériques⁸⁸. Dans ce contexte, la TEI reflète le consensus actuel de la communauté scientifique, proposant des recommandations pour la création et la gestion sous forme numérique des données textuelles créées et utilisées par les chercheur-se-s en sciences humaines⁸⁹. Ainsi, elle fournit les outils nécessaires au traitement des éditions numériques, tout en favorisant les réflexions et les échanges autour des pratiques éditoriales communes au sein d'une communauté particulière. Ce lien s'est notamment matérialisé autour d'une revue, la *Journal of the Text Encoding Initiative*⁹⁰.

Avant d'aborder les aspects plus techniques du standard, il importe d'en interroger son niveau plus *profond*⁹¹. Ici, deux aspects étroitement imbriqués méritent un commentaire : la TEI doit être envisagée en tant qu'outil de modélisation et d'analyse, mais également comme une ontologie pour la phénoménologie du texte et de la page⁹². La notion même de *modèle* - en particulier dans son acceptation formelle - mérite à ce stade d'être clarifiée, parce qu'elle constitue un point nodal dans le champ des humanités numériques⁹³. Stachowiak propose une définition du modèle à trois niveaux :

1. Un modèle est une représentation - une reproduction - d'un objet ou d'un concept dans un but précis à un moment donné.
2. Cette représentation se concentre sur certaines caractéristiques jugées pertinentes en fonction des objectifs du-de la modélisateur-riche, tout en en négligeant d'autres.
3. La sélection de ces caractéristiques n'est pas triviale mais fonctionnelle : elle remplit une fonction spécifique à accomplir⁹⁴.

87. HODEL, « Eine Zunft im digitalen Wandel », *art. cit.*

88. VOGELER, « The "assertive edition" », *art. cit.*

89. BURNARD LOU, *Qu'est-ce que la Text Encoding Initiative ?*, BURGHART Marjorie (trad.), Marseille : OpenEdition Press, 2015.

90. PINCHE, « Des plumes aux pixels : actualité de l'édition scientifique numérique », *art. cit.*

91. JANNIDIS Fotis et FLANDERS Julia, « Glossary », in JANNIDIS Fotis et FLANDERS Julia (dir.), *The Shape of Data in the Digital Humanities : Modeling Texts and Text-based Resources*, Abingdon, Oxon ; New York, NY : Routledge, 2019. | Series : Digital research in the arts and humanities : Routledge, 2018¹, p. 331.

92. PIERAZZO Elena, *Digital Scholarly Editing : Theories, Models and Methods*, London New York : Routledge, 2016, p. 307.

93. PIOTROWSKI Michael et XANTHOS Aris, « Décomposer les humanités numériques », *Humanités numériques*, n° 1, 2020.

94. JANNIDIS Fotis et FLANDERS Julia, « A gentle introduction to data modeling », in JANNIDIS Fotis et

Parce qu'il n'est pas traitable par un ordinateur, un modèle doit être représenté formellement, c'est-à-dire sous une forme non ambiguë et explicite. Dans cette optique, modéliser revient à expliciter les structures abstraites d'un objet d'étude en les traduisant dans un langage formel⁹⁵. L'initiative TEI est un exemple typique du travail mené dans le cadre de la modélisation dans le champ des humanités numériques⁹⁶.

En tant qu'outil de modélisation, la TEI offre un système structuré et standardisé pour l'encodage du texte. Contrairement à la rétro-numérisation du texte ou à sa retranscription, l'introduction de balises crée un modèle, en codant explicitement les caractéristiques de l'objet d'édition. Les TEI Guidelines incarnent cet ensemble de pratiques d'encodage. À travers un marquage descriptif de plus de 500 éléments et attributs, il devient possible de structurer et de représenter de manière explicite la complexité des textes et de leur matérialité. Comprise comme un outil d'analyse, la TEI rend les caractéristiques textuelles explicitement encodées accessibles et exploitables par des applications informatiques. Cette capacité de traitement permet notamment la recherche et l'interrogation ciblées de données textuelles encodées, de même que des possibilités d'identification et d'extraction d'éléments textuels précis (noms propres, lieux, dates, etc.). Ainsi, la TEI ne se limite pas à la description du texte, mais offre une infrastructure puissante pour son exploration et son interprétation approfondie.

Dans l'intention de répondre à la majorité des objectifs scientifiques des études textuelles en sciences humaines, il convient de mettre en évidence la capacité de la TEI à établir à un vocabulaire partagé, transcendant les frontières disciplinaires, l'ensemble des directives permettant de parler de l'objet d'édition de manière cohérente et normalisée. Selon Cummings, l'avantage de la TEI réside dès lors dans son niveau d'indirection pragmatique qui offre la possibilité d'être utilisée par des communautés éditoriales très différentes⁹⁷. Par conséquent, l'initiative se présente moins comme une prescription que comme un cadre hautement personnalisable - parfois dénommé *meta-standard*⁹⁸ - pour la construction et la documentation de modèles de données pour

FLANDERS Julia (dir.), *The Shape of Data in the Digital Humanities : Modeling Texts and Text-based Resources*, Abingdon, Oxon ; New York, NY : Routledge, 2019. | Series : Digital research in the arts and humanities : Routledge, 2018¹, p. 28.

95. JANNIDIS Fotis, « Grundlagen der Datenmodellierung », in JANNIDIS Fotis *et alii* (dir.), *Digital Humanities*, Stuttgart : J.B. Metzler, 2017, p. 99-108.

96. JANNIDIS et FLANDERS, « The Shape of Data in the Digital Humanities », *art. cit.*

97. CUMMINGS J, « The Present and Future of Encoding Text(s) », in O'SULLIVAN James (dir.), *The Bloomsbury Handbook to the Digital Humanities*, Bloomsbury Publishing, 2022, p. 147-157.

98. BURNARD, « How modeling standards evolve », *art. cit.*

des projets éditoriaux particuliers⁹⁹.

Cela suggère en creux que la TEI se présente comme une ontologie flexible en offrant un système structuré de concepts et de relations pour comprendre et représenter les caractéristiques observables du texte et de son support, qu'il s'agisse d'éléments structurels et sémantiques du texte, en passant par la présentation matérielle du document, relevant les erreurs ou abréviations. A ce titre, la TEI est qualifiée d'*ontologiquement agnostique* dans la manière dont elle définit des objets pour l'encodage : si elle spécifie l'objet de balisage pour encoder un phénomène textuel spécifique, elle ne prescrit pas comment déterminer la nature de ce dernier¹⁰⁰. Comme le synthétise Pinche, « [l']esprit même de la TEI n'est pas de contraindre les éditeurs à un choix technique appliqué de manière mécanique, mais de permettre aux choix épistémologiques de rester centraux dans la modélisation des données »¹⁰¹.

En ce sens, l'encodage du texte constitue une formalisation interprétative, ou, dit autrement, une construction intellectuelle. La TEI permet de dépasser l'approche réductrice selon laquelle elle serait uniquement un format adapté au traitement informatisé du texte pour penser le modèle d'intelligibilité de l'éditeur-rice rendu explicite par les choix de balisage qu'il effectue. La documentation de l'intervention éditoriale dans le texte offre une plus grande transparence à l'égard du-de la lecteur-rice. Ainsi, la TEI donne les moyens de capturer la lecture de l'éditeur-rice - en tant que processus actif d'identification et d'interprétation du sens du textes - en cela qu'elle fournit les moyens de formaliser son interprétation.

2.3 Automatiser l'annotation de textes historiques : vers une perspective centrée sur les entités nommées

L'annotation, entendue traditionnellement comme l'ajout réfléchi d'éléments textuels ou graphiques destinés à fournir une contextualisation additionnelle et une explication d'un texte, trouve son origine dans la tradition savante médiévale. Dans cette

99. La capacité de la TEI à accueillir et à formaliser l'interprétation singulière d'un-e éditeur-rice est rendue possible par le format *TEI ODD* (One Document Does it all), qui permet à chaque projet d'adapter la norme à ses besoins spécifiques, tout en garantissant l'interopérabilité avec d'autres projets fondés sur le même socle méthodologique. Il ne vise pas à uniformiser les interprétations, mais à fournir un cadre pour les rendre explicites et potentiellement interopérables. OXYGEN XML EDITOR, TEI ODD Document Type (Framework).

100. CUMMINGS J, « The Present and Future of Encoding Text(s) », *art. cit.*

101. PINCHE, « Des plumes aux pixels : actualité de l'édition scientifique numérique », *art. cit.*

optique, annoter demeure un acte destiné à un-e lecteur-rice, ouvert à l’ambiguïté et inscrit dans une tradition dialogique entre textes et commentaires. En se transposant au XX^e siècle dans les systèmes d’information, la pratique d’annotation s’est dotée d’une seconde vocation : fournir un balisage formalisé conçu prioritairement pour les traitements de données. Les balises doivent être interprétables par la machine sans avoir recours à la déduction, d’où l’utilisation à un vocabulaire contrôlé, des ontologies et à la désambiguïsation systématique, le but étant d’ajouter des métadonnées, des commentaires, des balises ou d’autres informations qui complètent les données d’origine et les rendent plus riches ou plus utilisables¹⁰². Qu’elle s’adresse à une lecture humaine ou machinique, l’annotation instaure un cadre organisationnel et un ajout d’information additionnelle par rapport à un texte original, facilitant ainsi la recherche et l’analyse de ce dernier. Dans une perspective méthodologique axée sur les pratiques numériques, Rapp propose de distinguer les procédures d’annotation, manuelles ou automatisées, ainsi que les types et les fonctions d’annotation qui y sont associées¹⁰³.

L’annotation manuelle relève d’une démarche herméneutique où l’expertise du-de la chercheur-se prime : elle repose sur des directives ou des lignes directrices de balisage explicites pour le repérage, la sélection et la qualification des segments textuels - telles que celles mises en œuvre dans le cadre de la TEI - afin de formuler et formaliser une grande variété de phénomènes textuels, allant de la structure narrative à la fonction discursive¹⁰⁴. Cette approche, exécutée par des humains et caractérisée par un coût temporel élevé, privilégie des types d’annotation ciblée à forte valeur interprétative — notamment sémantiques, discursives et argumentatives — qui nécessitent des compétences humaines et un savoir contextuel qui échappent à l’automatisation. Comme l’a soutenu Burnard, « le balisage transpose une interprétation (humaine) du texte en un ensemble de codes sur lesquels un traitement informatique peut être effectué. Il nous permet ainsi d’enregistrer les interprétations humaines d’une manière mécaniquement partageable »¹⁰⁵. En ce sens, les fonctions de l’annotation manuelle sont avant tout qualitatives : elles visent à expliciter certains phénomènes textuels

102. NANTKE Julia et SCHLUPKOTHEN Frederik, « Introduction », in *Annotations in Scholarly Editions and Research*, De Gruyter, 2020, p. 1-18.

103. RAPP Andrea, « Manuelle und automatische Annotation », in JANNIDIS Fotis *et alii* (dir.), *Digital Humanities*, Stuttgart : J.B. Metzler, 2017, p. 253-267.

104. VOGELER, « The “assertive edition” », *art. cit.*

105. ROMELE Alberto *et alii*, « Digital hermeneutics : from interpreting with machines to interpretational machines », *AI & SOCIETY*, vol. 35, n° 1, 2020, p. 75. *trad.*

complexes, à rendre formellement lisibles des interprétations expertes, à fournir un support à l'analyse qualitative, et à permettre, dans certains contextes, la documentation de lectures multiples ou d'ambiguïtés. Par ailleurs, dans un environnement numérique, l'annotation manuelle favorise la ré-utilisabilité des données grâce à l'usage de formats structurés et interopérables selon les principes *Findable, Accessible, Interoperable, Reusable* (FAIR)*. Elle répond ainsi à une double exigence : formaliser les structures du texte pour les rendre traitables par machine, tout en matérialisant les interprétations humaines dans un cadre transparent et reproductible¹⁰⁶.

À l'inverse, l'annotation automatique repose sur la mise en œuvre de procédures algorithmiques, c'est-à-dire automatiques¹⁰⁷. L'annotation automatisée s'inscrit dans un paradigme hérité de la recherche en linguistique et le traitement automatique des langues, visant en premier lieu la reproductibilité des résultats, la scalabilité des traitements et la couverture massive des corpus¹⁰⁸. À terme, leur fonction principale est de rendre le texte interrogeable à grande échelle, d'alimenter des analyses quantitatives, d'assurer l'homogénéité des corpus traités, tout en facilitant l'interopérabilité via des formats et identifiants standardisés. Ici, les entités nommées se présentent comme une composante standard, à l'interface entre description linguistique et structuration formelle du sens : il s'agit d'ajouts descriptifs apposés aux données textuelles qui visent à structurer et enrichir sémantiquement le corpus¹⁰⁹. Il convient toutefois de souligner qu'elles ne bénéficient pas d'une image claire dans la théorie linguistique. En effet, elles renvoient moins à une définition consensuelle¹¹⁰ qu'à un ensemble de critères linguistiques¹¹¹. Retenons néanmoins que les travaux actuels en TALN tirent leur cadre définitoire de la proposition de Nadeau et Sekine. Ces derniers mettent en évidence la relation fondamentale entre entité nommée et référence : « le terme « nommé » vise à restreindre [les entités nommées] aux seules entités pour lesquelles un ou plusieurs désignateurs rigides [...] désignent le référent. [...] Les désignateurs

106. RAPP, « Manuelle und automatische Annotation », *art. cit.*, p. 258.

107. RAPP, « Manuelle und automatische Annotation », *art. cit.*

108. MEISTER Jan Christoph, « Annotation als Markup avant la lettre », in JANNIDIS Fotis (dir.), *Digitale Literaturwissenschaft*, Stuttgart : J.B. Metzler, 2022, p. 353-383.

109. REHM Georg, « Observations on Annotations », in *Annotations in Scholarly Editions and Research*, De Gruyter, 2020, p. 299-324.

110. VAN HOOLAND Seth *et alii*, *Introduction aux humanités numériques : méthodes et pratiques : Sciences humaines et sociales*, De Boeck Supérieur, 2016, p. 142.

111. Nous n'approfondirons pas les nombreux débats entourant la définition des entités nommées au sein de la discipline linguistique. Pour une analyse détaillée à ce sujet, voir EHRMANN Maud, *Les Entités Nommées, de la linguistique au TAL : Statut théorique et méthodes de désambiguïsation*, phdthesis, Paris Diderot University, 2008. NOUVEL, *Named entities for computational linguistics*, *op. cit.*, p. 11-22.

rigides comprennent les noms propres ainsi que certains termes désignant des types naturels, tels que les espèces biologiques et les substances »¹¹². Autrement dit, les entités nommées désignent les unités référentielles qui structurent la sémantique d'un texte et orientent son interprétation, telles que les noms de personnes, les lieux et les organisations. Leur singularité repose sur deux propriétés complémentaires : d'une part, leur monoréférentialité — chaque entité renvoie à un référent unique, distinct des autres entités ou de la classe conceptuelle à laquelle il appartient ; d'autre part, leur autonomie référentielle — leur seule mention suffit à convoquer ce référent dans le texte, sans autre clarification. Qu'il s'agisse d'une convention dénomminative, comme pour les noms propres, ou d'une description définie plus ou moins détaillée, ce fonctionnement référentiel demeure le critère décisif qui limite leur portée¹¹³.

D'un point de vue méthodologique, l'approche d'annotation automatisée, essentiellement technique et fonctionnelle, repose sur une description systématiquement réglemantée du texte. Dès lors que les entités nommées sont appréhendées comme des unités de référence dans le texte, il nécessite de délimiter le domaine référentiel que l'on entend modéliser. Annoter requiert donc d'établir au préalable un cadre sémantique, sous la forme de typologie, afin de formaliser de manière descriptive les catégories sélectionnées et leur portée¹¹⁴. S'ensuit l'établissement d'un guide d'annotation visant à fournir des définitions opérationnelles des étiquettes et des caractéristiques à associer aux données. Ici, l'objectif affiché est la maximisation de la cohérence entre annotateurs-rices humains dans le but de fournir une base solide pour les traitements automatisés ultérieurs¹¹⁵. En outre, il s'agit de viser la désambiguïsation maximale, considérée comme une condition centrale à l'implémentation d'un processus fondé sur l'apprentissage supervisé*. De cette manière, l'annotation automatisée demeure avant tout tributaire de la qualité et de la cohérence des données manuelles initiales. À terme, cette approche un standard de référence sur la base duquel l'évaluation et l'entraînement de modèles pour le traitement automatique du langage naturel sont effectués¹¹⁶. Pustejovsky évoque cette exigence : « pour que les algorithmes apprennent de manière efficace et efficiente, l'annotation effectuée sur les données doit être pré-

112. NADEAU David et SEKINE Satoshi, « A survey of named entity recognition and classification », *Linguisticae Investigationes*, vol. 30, n° 1, 2007, p. 3. trad.

113. NOUVEL, *Named entities for computational linguistics*, op. cit., p. 41-46.

114. NOUVEL, *Named entities for computational linguistics*, op. cit., p. 48.

115. *Ibid.*, p. 59.

116. IDE Nancy, « Introduction : The Handbook of Linguistic Annotation », in IDE Nancy et PUSTEJOVSKY James (dir.), *Handbook of Linguistic Annotation*, Dordrecht : Springer Netherlands, 2017, p. 1-18.

cise et pertinente par rapport à la tâche que la machine doit accomplir »¹¹⁷. Cette logique suppose donc une modélisation rigide du contenu textuel, fondée sur des opérations de catégorisation et de classification stricte, non susceptibles d’être modifiée de manière *ad hoc*¹¹⁸.

La notion d’annotation recouvre ainsi un large éventail de significations dans les pratiques de recherche, témoignant de la diversité des approches théoriques et méthodologiques qui lui sont associées. Cette hétérogénéité témoigne de pratiques multiples, qui ne s’excluent pas mutuellement, mais tendent au contraire à se recouper en fonction des contextes d’annotation.

2.4 Entre tropisme de la performance et invisibilisation historiographique

Historiquement, les tâches de reconnaissance et de liaison d’entités nommées sont dominées par le champ de la linguistique, avant de se tourner vers les domaines du traitement automatique du langage naturel et de l’intelligence artificielle¹¹⁹. Ces filiations disciplinaires ont façonné une littérature qui repose sur des métriques de performances. L’état de l’art couvrant vingt années de recherche sur la reconnaissance d’entités nommées appliquée aux documents historiques illustre cette dynamique. Si le propos dresse un panorama utile des avancées méthodologiques, il constitue essentiellement un cadrage technique : les particularités documentaires – qu’il s’agisse de la diversité diachronique des corpus, du bruit introduit par la reconnaissance optique de caractères, de l’évolution des pratiques orthographiques ou de la pénurie de ressources – ne sont pas discutées pour leur portée interprétative, mais pour leur effet perturbateur sur l’apprentissage automatique. Même la question des typologies de classification et du manque de matériel à disposition est abordée sous l’angle d’une optimisation de données d’entraînement¹²⁰. La traduction des enjeux intrinsèques aux sources historiques en paramètres mesurables confirme une telle logique d’ingénierie : la complexité historique y est moins considérée comme un objet d’interprétation que comme une contrainte à neutraliser pour perfectionner l’efficacité algorithmique.

117. PUSTEJOVSKY James et STUBBS Amber, « Chapter 1. The Basics », in *Natural language annotation for machine learning : a guide to corpus-building for applications*, Beijing Köln : O’Reilly, 2013, p. 1-31. trad.

118. MEISTER, « Annotation als Markup avant la lettre », *art. cit.*

119. MUNNANGI Monica, A Brief History of Named Entity Recognition, arXiv, 2024.

120. EHLMANN *et alii*, « Named Entity Recognition and Classification in Historical Documents », *art. cit.*, p. 6-11.

Les réussites sont quantifiées par la progression de métriques tandis que les priorités futures énumérées correspondent toutes à des chantiers techniques d'optimisation, de généralisation et de standardisation des modèles¹²¹.

Dans cette optique, Lowrie a offert une perspective ethnographique précieuse sur l'épistémologie de la science des données, mettant en évidence la centralité de l'efficacité comme critère d'évaluation des algorithmes. Parce qu'ils sont conçus pour effectuer des tâches spécifiques, ils exigent une attention portée à leur mise en œuvre concrète, c'est-à-dire à la manière dont ces algorithmes interagissent avec des données réelles au sein de systèmes computationnels – englobant à la fois les logiciels qui les implémentent et les architectures matérielles sur lesquelles ils s'exécutent. Par conséquent, le standard épistémologique pour les évaluer ne se situe pas au niveau du code source des algorithmes ou dans la recherche une vérité intrinsèque en eux, mais dans l'analyse des résultats ainsi que dans la manière dont ils opèrent lorsqu'ils interagissent avec les données et l'infrastructure numérique, dans un contexte réel ou simulé. L'efficacité désigne la capacité de ces assemblages à fournir un fonctionnement performant répondant à des tâches pratiques et à optimiser l'utilisation des ressources, notamment le temps de calcul, tout en rendant l'approche autant reproductible que possible. L'efficacité constitue ainsi un critère structurant de l'épistémologie de la science des données contemporaine, où la connaissance se fabrique dans l'action et non dans l'abstraction¹²².

Parce qu'elle s'inscrit dans des cultures disciplinaires résolument axées sur les données, la problématique des entités nommées a tendu à restreindre l'horizon de la recherche à leur seule production, reléguant ainsi les considérations humanistes à un pôle périphérique. Ce faisant, le déploiement des solutions s'est fait au détriment d'une réflexion critique sur leurs usages interprétatifs propres aux sciences humaines¹²³. Notons toutefois, que quelques propositions récentes, bien que marginales, ont émergé au sein de la communauté historienne, ouvrant des perspectives alternatives. Humbel *et alii* ont rappelé la dimension idéologique de l'automatisation, en montrant que la création, l'utilisation et la promotion de technologies algorithmiques ne sauraient

121. *Ibid.*, p. 32-37.

122. LOWRIE Ian, « Algorithmic rationality : Epistemology and efficiency in the data sciences », *Big Data & Society*, vol. 4, n° 1, 2017, p. 2053951717700925.

123. VAN ZUNDERT Joris J., « Screwmeneutics and Hermeneumericals : The Computationality of Hermeneutics », in SCHREIBMAN Susan *et alii* (dir.), *A New Companion to Digital Humanities*, Wiley, 2015¹⁻²⁶, p. 15.

être considérés comme des processus neutres, pas plus que les résultats qu'ils produisent¹²⁴. Alors que la perception courante parmi les chercheur·euse·s est que la « véritable recherche » commence après que les données numériques ont été nettoyées, normalisées et organisées »¹²⁵, il convient de souligner que le traitement des entités nommées doit avant tout être présenté comme une intervention algorithmique : elle transforme les données selon des règles prédéfinies, des modèles statistiquement entraînés et des jeux de données particuliers, et influe, ce faisant sur les interprétations ultérieures. Dans ce prolongement, Hodel a suggéré que le traitement automatique des entités nommées doit susciter une réflexion critique sur les conditions de production, d'interprétation et d'usage des résultats algorithmiques dans les sciences historiques. Suivant son propos, la phase d'apprentissage des modèles de réseaux de neurones constitue un point névralgique. En effet, ces modèles requièrent une structuration préalable du texte, impliquant des décisions normatives quant à la composition du corpus, au choix des classes d'entités, et aux conventions des annotations. De ce fait, les conditions techniques et conceptuelles qui ont présidé à leur production orientent la manière dont les entités sont définies, catégorisées et, *in fine* reconnues par le système selon un principe d'imitation. En faisant reposer l'acte d'interprétation sur les entrées et les sorties, Hodel suggère que les entités produites ne sont jamais des objets donnés, mais des reconstructions probabilistes, issues de transformations computationnelles complexes. Dès lors, les effets de ces opérations orientent les lectures, structurent les objets de recherche, et contribuent à faire émerger certaines catégories ou formes d'identification au détriment d'autres. En ce sens, les technologies de traitement d'entités nommées participent ainsi activement à la construction des données historiques et aux cadres interprétatifs dans lesquels elles prennent sens¹²⁶.

Si Hodel a soutenu à juste titre que l'utilisation du *deep learning* en sciences historiques entraînera une nouvelle réflexion méthodologique attentives aux réalités techniques et aux spécificités propres à la discipline¹²⁷, il reste à constater que pour l'heure, les approches interprétatives restent marginales¹²⁸. Cependant, cette considération

124. HUMBEL Marco *et alii*, « Named-entity recognition for early modern textual documents : a review of capabilities and challenges with strategies for the future », *Journal of Documentation*, vol. 77, n° 6, 2021, p. 1223-1247.

125. HOEKSTRA et KOOLEN, « Data scopes for digital history research », *art. cit.*

126. HODEL, « Die Maschine und die Geschichtswissenschaft », *art. cit.*

127. *Ibid.*, p. 65.

128. WETTLAUER Jörg, « Methoden der Digital History/Digitalen Geschichtswissenschaft », in HAAS Stefan (dir.), *Handbuch Methoden der Geschichtswissenschaft*, Wiesbaden : Springer Fachmedien Wiesbaden, 2023, p. 4, 14.

peut être replacé dans un appel plus large d'une *herméneutique numérique*, où les données et les outils numériques prennent progressivement une place centrale dans le processus de recherche.

3 Un cadre pour penser la transformation des données historiques

La mise en données exponentielle des sources historiques, qu'elle soit rétro-numérisée ou nativement numérique, promet de nouvelles approches quantitative et computationnelle, en particulier de lecture distante ¹²⁹, le constat étant que ces analyses se fassent au détriment de principes fondamentaux de la discipline historique. La crainte de verser dans des méthodes exclusivement positivistes a donné naissance à un « critical turn » dans lequel une dialectique interdisciplinaire doit permettre de dépasser les écueils qui se présentent de part et d'autre. En histoire numérique, ce tournant a notamment été conceptualisé sous le terme de l'« herméneutique numérique ». Cette dernière apparaît selon nous comme une approche clé pour penser l'hybridation des pratiques de recherche numériques et historiques, en particulier dans le domaine de l'édition numérique ¹³⁰.

3.1 Du texte-source au texte-données : vers une herméneutique numérique

L'essor des humanités numériques s'est accompagné d'un certain optimisme, annonçant l'avènement des « humanités 2.0 » capable de réconcilier la tradition positiviste avec l'herméneutique. Néanmoins, une telle approche comporte le risque de verser dans le solutionnisme technologique, occultant ainsi la complexité épistémologique et les enjeux de l'historicité. Plutôt que se limiter à une approche purement utilitaire de technologies numériques dans la recherche historique, Fickers propose une perspective qui reconnaît et intègre l'impact des infrastructures numériques sur la recherche, la critique des sources et la construction du récit du passé. Il s'agit de tirer parti des humanités numériques dans le sens d'un enrichissement critique de la démarche historique classique face aux défis méthodologique et épistémologique de la pratique de l'histoire aux réalités de l'ère numérique ¹³¹.

Cette proposition s'est plus récemment consolidée dans le cadre conceptuel de l'*herméneutique numérique*, entendue comme un engagement critique et réflexif vis-à-vis

129. MORETTI, *Distant reading*, *op. cit.*

130. VOGELER *et alii*, « „Ich glaube, Fakt ist...“ », *art. cit.*, p. 179-180.

131. FICKERS, « Veins filled with the Diluted Sap of Rationality », *art. cit.*

des infrastructures, des données et des outils numériques, qui influencent les modalités de production du sens historique et les manières d'interpréter le passé. Ce cadre engage une réflexion praxéologique sur les questions et perspectives de recherche, les méthodes mobilisées, les interprétations produites, ainsi que sur les formes d'argumentation et les formats narratifs induits par les médiations numériques¹³². En cela, l'herméneutique numérique se présente comme une « mise à jour » de son corollaire traditionnelle¹³³. Il s'agit de rendre visible les interventions numériques dans toutes les phases de la recherche, de la sélection des sources à la publication des résultats. Pour le dire autrement, l'herméneutique numérique cherche à promouvoir une réflexion transparente et responsable sur la manière dont les processus de collecte, d'analyse et de visualisation des données assistés par des outils conditionnent les résultats de la recherche¹³⁴.

Suggérer que la *critique de sources numériques* peut être entendue comme la *critique des données*¹³⁵ implique une réflexion sur les transformations ontologiques que subissent les sources lors de leur conversion en données. L'intégration des sources analogiques dans des environnements numériques ne se limite pas à la rétro-numérisation d'un objet analogique, qu'il s'agisse d'un texte, d'une image, ou d'un artefact tridimensionnel¹³⁶. S'il faut reconnaître que cette opération de conversion dépasse la simple duplication technique, en tant qu'opération de médiation numérique fondée sur des choix concernant les propriétés à conserver, les modalités de codage, et les formes de restitution, la mise en données — ou *datification* — prolonge cette première étape en transformant le matériau numérisé en un objet structuré, enrichi et conçu pour l'exploitation computationnelle. En effet, un tel dispositif convertit des objets historiques en données, en particulier des textes, articulées selon des formats, des hiérarchies et des standards en vue de leur exploitation, de leur contextualisation et de

132. FICKERS Andreas, « What the D does to history : Das digitale Zeitalter als neues historisches Zeitre-gime ? », in *Digital History*, De Gruyter Oldenbourg, 2022, p. 45-48.

133. FICKERS Andreas, « Update für die Hermeneutik. Geschichtswissenschaft auf dem Weg zur digitalen Forensik ? », 2020, p. 158.

134. FICKERS Andreas *et alii*, « Digital history and hermeneutics – between theory and practice : An introduction », in FICKERS Andreas et TATARINOV Juliane (dir.), *Digital History and Hermeneutics*, De Gruyter, 2022, p. 6-14.

135. FICKERS, « Update für die Hermeneutik. Geschichtswissenschaft auf dem Weg zur digitalen Forensik ? », *art. cit.*, p. 160-162.

136. Notre analyse se fonde ici uniquement sur les documents numérisés en tant que types d'objets numériques. Feichtinger *et alii* élargissent l'identification des formes numériques des sources historiques aux documents nativement numériques et aux documents réincarnés. FEICHTINGER Moritz *et alii*, « 2.1. Theoretische Grundlagen einer digitalen Quellenkritik », in, Zenodo, 2024. Ces types d'objets numériques qui se distinguent, par leur nature, des documents numérisés ne feront pas l'objet d'un examen dans le cadre de ce travail, dans la mesure où ils ne sont pas représentés dans notre corpus.

leur réutilisation¹³⁷. De cette manière, la source mise en données constitue une nouvelle forme de représentation de l'information historique où le contenu est dissocié de sa forme initiale¹³⁸. Plutôt que de les naturaliser, les données doivent être pensées comme le résultat d'un processus interprétatif portant sur la sélection, la codification et la hiérarchisation de l'information¹³⁹. De cette manière, les données deviennent des objets épistémiques particuliers qui diffèrent de leur référent analogique et appelle par conséquent à une critique spécifique quant à ses conditions de production, de transmission et d'interprétation.

Il s'agit d'interroger, de manière réflexive, l'authenticité des données numériques, d'évaluer la fiabilité de leurs chaînes de production, de stockage et de migration, et de contextualiser leur matérialité, leur historicité et leur performativité au sein des dispositifs socio-techniques qui les façonnent. Cette démarche, telle que formulée par Andreas Fickers, invite à dépasser l'illusion d'un accès direct et neutre à la trace historique par l'intermédiaire des données numériques. Toute donnée, qu'elle soit produite ou réutilisée, résulte en effet d'une chaîne de médiations épistémologiques et techniques. Dès lors, il convient d'articuler à l'analyse de l'authenticité historique, entendue comme le résultat d'un processus historiographique visant à déterminer la facticité d'événements passés, celle de l'authenticité informationnelle, qui suppose la vérification de l'intégrité des données. Celle-ci requiert d'évaluer, d'une part, l'intégrité informatique - c'est-à-dire la préservation du code binaire et à l'exactitude sémantique entre fait réel et fait modélisé ; d'autre part, l'intégrité du contenu, entendue comme la stabilité du sens ou de la signification des jeux de données malgré d'éventuelles altérations techniques, notamment liées aux opérations de copies ou de migrations des données ; et enfin l'intégrité de la présentation, qui souligne le caractère performatif des données, dépendant des interfaces de visualisation. Adopter cette angle permet de souligner que toute infrastructure numérique recode et recontextualise toutes les sources numériques. Parce qu'elles sont indissociables de leurs contextes matériels et logiciels, les données possèdent une matérialité *stratifiée et distribuée* : leur stockage, leur visualisation et leur réutilisation dépendent nécessairement des infrastructures qui les façonnent activement. La donnée n'est jamais brute ni neutre, mais un construit

137. *Ibid.*

138. HILTMANN Torsten, « Hermeneutik in Zeiten der KI : Large Language Models als hermeneutische Instrumente in den Geschichtswissenschaften », in *KI:Text*, De Gruyter, 2024, p. 206.

139. FEICHTINGER *et alii*, « 2.1. Theoretische Grundlagen einer digitalen Quellenkritik », *art. cit.*

normatif et historiquement situé. La critique des données s'impose ainsi comme une extension contemporaine de la critique des sources, tout en les reconfigurant à l'aune des environnements numériques contemporains ¹⁴⁰.

Interagir avec des données numériques implique nécessairement un médiateur – un outil numérique –, entendu ici comme l'ensemble des dispositifs computationnels – interfaces, chaînes logicielles, algorithmes – qui transforme, structure et interprète les données. Dans cette perspective, Van Es a reconnu l'importance d'évaluer de manière critique les outils numériques, ces derniers participant activement à la production de connaissance ¹⁴¹. Tirant parti de ce constat, Dobson appelle à interroger la fonction interprétative des outils computationnels dans les résultats qu'ils produisent ¹⁴². Une attention particulière doit alors être portée aux processus de transformation opérés par l'outil numérique sur les données. Il s'agit d'étendre la critique des sources numériques proposée par Fickers aux modalités même de leur fabrication ¹⁴³. La critique des outils numériques, telle que proposée par Koolen, avance donc par un va-et-vient itératif et réflexif entre questionnement, méthode, données et outil, supporté par un journal de bord et de tests systématiques qui rendent visibles les modélisations implicites que suggèrent les outils utilisés ¹⁴⁴.

Si la critique des outils n'est pas nouvelle, un tel engagement s'impose, dans la mesure où le recours croissant aux outils numériques tend à encourager une posture empiriciste, sinon positiviste, dans laquelle leur utilisation non problématisée occulte les présupposés méthodologiques et les logiques de conception qu'ils véhiculent ¹⁴⁵. Dès lors, un outil ne doit pas être appréhendé uniquement comme un simple instrument méthodologique en vue de produire des résultats académiques, mais comme un dispositif technique distinct, intégrant déjà des méthodes susceptibles d'influencer en profondeur les modalités de production des connaissances ¹⁴⁶. Une réflexion concomi-

140. FICKERS, « Update für die Hermeneutik. Geschichtswissenschaft auf dem Weg zur digitalen Forensik? », *art. cit.*, p. 162-166.

141. Es Karin Van et alii, « Tool Criticism and the Computational Turn. A "Methodological Moment" in Media and Communication Studies », *Medien & Kommunikationswissenschaft*, vol. 69, n° 1, 2021, p. 50.

142. DOBSON James E., « On reading and interpreting black box deep neural networks », *International Journal of Digital Humanities*, vol. 5, n° 2-3, 2023, p. 433.

143. HOEKSTRA et KOOLEN, « Data scopes for digital history research », *art. cit.*

144. KOOLEN Marijn et alii, « Toward a model for digital tool criticism : Reflection as integrative practice », *Digital Scholarship in the Humanities*, vol. 34, n° 2, 2019, p. 380-382.

145. Es Karin van, « Unpacking tool criticism as practice, in practice », *Digital Humanities Quarterly*, vol. 17, n° 2, 2023, p. 1.

146. Es et alii, « Tool Criticism and the Computational Turn. A "Methodological Moment" in Media and Communication Studies », *art. cit.*, p. 50.

tante doit ainsi être engagée pour comprendre la manière dont les outils numériques co-créent les objets d'étude épistémiques étudiés ¹⁴⁷.

Cette posture doit composer avec deux conditions. D'une part, la plasticité des usages requiert de reconnaître l'écart entre finalité déclarée de l'outil numérique et les pratiques réelles de recherche. Plutôt que de naturaliser ces outils, leur utilisation appelle à un examen critique des hypothèses et des limites qui les sous-tendent, ainsi que du contexte dans lequel ces outils ont été développés, de leur pertinence pour l'objectif de recherche, et des usages détournés auxquels ils peuvent donner lieu. ¹⁴⁸. Anticiper et reconnaître ces biais permet de saisir l'impact des outils dans les résultats de recherche et de les réintégrer dans un questionnement interprétatif. En raison de la pluralité des usages, l'absence d'un standard d'évaluation requiert d'autre part d'explicitier les critères retenus pour juger la pertinence de l'outil au regard de l'objectif scientifique. De cette manière, la critique des outils numériques propose d'intégrer la réflexion au cœur même du cycle de traitement numérique : en analysant, documentant et ajustant les hypothèses d'un outil avant et pendant son exécution, elle replace l'herméneutique en amont du calcul algorithmique.

3.2 Renforcer la transparence : le cadre des *digital scopes*

Avec l'essor des « big data », la métaphore du microscope s'est largement imposée pour décrire l'instrument permettant de saisir des agrégats massifs de données historiques ¹⁴⁹. Or, cette image reste insuffisante, dans la mesure où elle ne rend pas compte du caractère itératif, transformationnel et interprétatif du processus par lequel les historien·ne·s interagissent avec les données. Pour combler cette lacune, Hoekstra et Koolen propose le concept de *data scope* : un procédé réflexif qui construit, à partir d'un corpus de données hétérogènes, une vue analytique - et, par conséquent, nécessairement spécifique - pour une question de recherche donnée. Loin d'un simple guide de « bonnes pratiques » techniques, il constitue une réponse aux appels à théoriser l'usage des données à grande échelle et aux mises en garde contre la décontextualisation de la recherche historique au sein des espaces numériques, étendant ainsi la

147. FICKERS *et alii*, « Digital history and hermeneutics – between theory and practice », *art. cit.*

148. Es *et alii*, « Tool Criticism and the Computational Turn. A “Methodological Moment” in Media and Communication Studies », *art. cit.*, p. 47. DÜRING Marten *et alii*, « Transparent generosity. Introducing the *impresso* interface for the exploration of semantically enriched historical newspapers », *Historical Methods : A Journal of Quantitative and Interdisciplinary History*, vol. 57, n° 1, 2024, p. 23.

149. GRAHAM *et alii*, « The Joys of Big Data for Historians », *art. cit.*

critique des sources aux opérations algorithmiques qui façonnent le corpus.

Hoekstra et Koolen définissent le data scope comme « le processus par lequel différentes vues sur les données de recherche sont créées, pertinentes pour une question de recherche spécifique »¹⁵⁰. Ces *vues* reposent sur un dispositif central que les auteurs proposent de désigner par *axes de données* : des éléments transversaux, communs à plusieurs ensembles de données, considérés comme suffisamment significatifs pour constituer des *axes* à partir desquels ces ensembles peuvent être rapprochés et comparés. La valeur des axes de données réside ainsi dans leur capacité à relier des données fragmentaires issues de sources hétérogènes et à leur conférer une cohérence structurelle. Déterminer ces axes revient donc à identifier, dans chaque source, les dimensions jugées pertinentes au regard de la problématique étudiée¹⁵¹. Ce faisant, les axes de données structurent les interrogations, facilitent l'exploration des corpus et ouvrent la voie à des comparaisons systématiques entre ensembles de données initialement disparates. De ce point de vue, un type d'entité nommée peut constituer un axe de données : il s'agit d'unités spécifiques présentes au sein d'un ensemble de données - comme les personnes, les organisations ou les lieux -, qu'il convient de repérer et de collecter en vue de fournir une lecture transversale.

Concrètement, ce processus « médiatise » la perspective de recherche en transformant les données brutes par une série de cinq activités interprétatives¹⁵². À noter qu'elles ne sont pas nécessairement toutes présentes dans le processus de recherche et que la linéarité présenté ici n'implique pas qu'elles suivent l'ordre prédéfini.

- La *sélection* consiste à circonscrire le corpus, décision qui conditionne la représentativité ainsi que la portée analytique des résultats de recherche.
- La *modélisation* est l'acte de traduction des sources en une représentation formelle de données par la détermination des *axes de données*, choix qui détermine simultanément le cadre interprétatif et la faisabilité des traitements computationnels ultérieurs.
- La *normalisation* renvoie à l'activité visant à réduire la variation formelle des

150. HOEKSTRA et KOOLEN, « Data scopes for digital history research », *art. cit.*, p. 80. *trad.*

151. Pour exemplifier leur propos, Koolen et Hoekstra proposent le cas d'étude des émigrants australiens. Les chercheurs ont choisi comme axe des données les événements de la vie des migrants, extraits principalement de cartes consulaires. En liant entre elles des sources hétérogènes - notamment issues des archives australiennes et néerlandaises ainsi que des collections personnelles - et en structurant chaque événement autour de certains objets de données telles que les personnes, les dates et les lieux, ce choix d'axe de données a permis une analyse transversale des parcours migratoires. *Ibid.*, p. 81-83.

152. *Ibid.*, p. 80.

données - quelles soient lexicales, orthographiques, ou temporelles - en ramenant chaque occurrence à une forme canonique unique, afin de prévenir les doublons et de garantir la cohérence des comptages et de faciliter la mise en relation de sources hétérogènes.

- La *liaison* établit des connexions explicites entre des objets de données provenant d'ensemble de données distinct de manière à établir des correspondances stables entre eux.
- La *classification* réduit la complexité en assignant aux objets de données des catégories prédéfinies, ajoutant une couche sémantique indispensable pour faire émerger des tendances tout en rendant explicites les critères d'assignation.

En enregistrant la provenance de chaque transformation, le *data scope* se présente avant tout comme un dispositif réflexif qui décrit systématiquement le processus par lequel des données brutes – souvent hétérogènes, fragmentées – sont progressivement remodelées, révélant certains aspects tout en en reléguant d'autres au second plan. Plutôt que de livrer une vision définitive du corpus, le *data scope* vise à documenter systématiquement les choix effectués à chaque étape et à expliciter leurs bases interprétatives. La construction d'un *data scope* n'obéit pas à un enchaînement linéaire : Les transformations successives des données impliquent des choix basés sur l'exploration et l'interprétation qui requiert d'être inscrits dans une traçabilité explicite. L'enjeu principal de l'approche réside donc dans la visibilité des choix interprétatifs. Le but est de raisonner et de décrire les différentes étapes suivies par le·la chercheur·se dans un processus de recherche axé sur les données, ainsi que l'impact des choix opérés à chacune des étapes sur les résultats de la recherche et leur interprétation.

Cette documentation détaillée permet aux pairs de comprendre la logique des choix opérés, les biais potentiels introduits, et les effets de ces transformations sur les résultats et l'interprétation qui en résultent. De cette manière, il s'agit de rendre compte du caractère itératif d'un tel processus afin de décrire, d'argumenter et de rendre transparentes les activités du·de la chercheur·se avec les données numériques qu'ils transforment et les choix méthodologiques qui les guident. En ce sens, l'interaction avec les données doit être considérée comme faisant partie intégrante de la recherche numérique, et la création d'un *data scope* est un élément essentiel de la critique des sources et des outils numériques nécessaires pour rendre toutes les formes d'historiographie

numérique transparentes et auditables.¹⁵³ En rendant visibles ces allers-retours, une telle approche méthodologique répond aux exigences contemporaines des projets en histoire numérique¹⁵⁴.

En somme, le concept de data scope fournit un cadre pour rendre visibles les opérations interprétatives que dissimulent souvent les pipelines numériques¹⁵⁵ : il fournit un outil critique pour confronter leurs résultats à la communauté - disciplinaire et interdisciplinaire - et répond aux besoins d'informations sur les opportunités et les mises en garde inhérentes au traitement des données¹⁵⁶. De cette manière, le cadre proposé par Koolen et Hoekstra se présente comme une approche responsable et reproductible pour l'histoire numérique tout en opérationnalisant l'extension de la critique des sources à la critique des données et des outils : il souligne l'importance des circonstances dans lesquelles les données sont créées et conservées, transformées, constituant autant de critères centraux à leur interprétation¹⁵⁷.

3.3 Lecture distante et lecture proche : pour une dialectique critique

Le rapprochement progressif entre les sciences humaines et les méthodes computationnelles a suscité une critique profonde des approches fondées sur le *big data*, perçues comme une rupture avec la tradition herméneutique propre aux humanités, et ce, en raison des risques qu'elles comportent en termes de réductionnisme, d'insuffisance explicative et de téléologisme.¹⁵⁸ Ces critiques tendent à réduire le potentiel de l'informatique à une méthodologie de la quantification. Pour dépasser ces oppositions binaires, il a récemment été soutenu le potentiel heuristique des méthodes et des outils numériques pour encourager de nouvelles formes d'exploration des don-

153. *Ibid.*, p. 92-93.

154. ROBERTSON Stephen et MULLEN Lincoln, « Arguing with Digital History : Patterns of Historical Interpretation », *Journal of Social History*, vol. 54, n° 4, 2021, p. 1005-1022.

155. HOEKSTRA et KOOLEN, « Data scopes for digital history research », *art. cit.*, p. 90.

156. DÜRING *et alii*, « Transparent generosity. Introducing the *impresso* interface for the exploration of semantically enriched historical newspapers », *art. cit.*, p. 21. BAGNALL Kate et SHERRATT Tim, « Missing Links : Data Stories from the Archive of British Settler Colonial Citizenship », *Journal of World History*, vol. 32, n° 2, 2021, p. 298. HODEL, « Die Maschine und die Geschichtswissenschaft », *art. cit.*, p. 67.

157. KOOLEN *et alii*, « Toward a model for digital tool criticism », *art. cit.*, p. 382-383.

158. L'ouvrage *Distant reading* constitue un jalon incontournable de ces débats. Son approche a en effet été accusée de réduire la richesse interprétative des textes au profit d'indicateurs formels, de marginaliser l'interprétation pour une explication causale, ainsi que de négliger les dimensions historiques, contextuelles et agenciées des œuvres littéraires. Pour un complément sur ces critiques, voir VAN ZUNDERT, « Screwmenetics and Hermenumericals », *art. cit.*, p. 13-14.

nées, variant du niveau macroscopique au microscopique¹⁵⁹. Pour le dire autrement, il s'agit d'adopter une approche des outils et des données qui combine des exigences tant quantitatives que qualitatives.

Introduite dans l'essai « Conjectures on World Literature », la lecture distante pose le compromis d'une distanciation avec le texte ; l'élargissement du cadre d'analyse implique la perte proportionnelle d'informations¹⁶⁰. Pour Moretti, il s'agit ainsi d'*apprendre à ne pas lire* dans le but faire émerger des régularités et des dynamiques structurales à partir de vastes ensembles textuels. Loin d'exclure l'interprétation, la lecture distante propose un changement de focale : elle repose sur la constitution de corpus représentatifs et sur l'identification de motifs, de fréquences ou de variations formelles à travers des visualisations de données. Aborder une analyse à travers une lecture distante est inséparable d'une réflexion sur la construction de corpus, l'inclusion ou l'exclusion de textes et les biais qui en résultent. S'il convient de mentionner que l'analyse proposée par Franco Moretti est initialement ancrée dans le champ des études littéraires, sa contribution a suscité un intérêt général dans le champ des études textuelles. Dans le sillage des humanités numériques, son ouvrage *Distant Reading* s'impose comme une perspective alternative à l'herméneutique traditionnelle offrant une méthodologie originale qui repose sur une approche quantitative et formelle.

La lecture proche trouve un ancrage privilégié dans le champ des études littéraires¹⁶¹. En déplaçant son attention du niveau macro au micro, le-la chercheur-se se rapproche de son objet d'étude et applique un mode de lecture adéquat. Il s'agit dès lors de discerner les différentes couches de sens qui mènent à une compréhension approfondie. En d'autre terme, la lecture proche consiste en l'interprétation approfondie d'un passage textuel par la détermination des différents éléments qui le composent : elle vise une analyse détaillée des entités en présence, de leur développement et de leur interaction, des mots et expressions employés, de la structure et du style du texte, ainsi que des schémas argumentatifs¹⁶². Si une telle approche semble s'opposer aux pratiques à plus grandes échelles, les outils numériques peuvent attirer l'attention sur des régu-

159. FICKERS Andreas et ARMASELU Florentina, « Introduction », in *Zoomland*, De Gruyter Oldenbourg, 2023, p. 7. GRAHAM *et alii*, « The Joys of Big Data for Historians », *art. cit.*, XVI.

160. MORETTI, *Distant reading*, *op. cit.*, p. 40-55.

161. Le concept de lecture distante désigne la prise de distance avec celui de *close reading* (lecture proche ci-après). Issu du mouvement de la New Criticism au milieu du XXe siècle, ce dernier tend à se restreindre au commentaire traditionnel d'un petit nombre de textes canoniques.

162. JÄNICKE Stefan *et alii*, *On Close and Distant Reading in Digital Humanities : A Survey and Future Challenges*, The Eurographics Association, 2015.

larités ou des dissonances dans de vastes corpus, stimulant ainsi la formulation d'hypothèses ou la poursuite d'indices inattendus ¹⁶³. Ce faisant, ces outils n'éclipsent pas le regard de l'historien-ne, mais l'invite à déplacer ou élargir son champ d'attention, à condition de rester attentif aux effets de cadrage et aux logiques décontextualisantes et normalisantes des algorithmes. En ce sens, le caractère heuristique des méthodes computationnelles, en cela qu'elles ouvrent de nouvelles pistes, ne doit pas se substituer au jugement historien mais être penser dans leur articulation.

Évoluer de manière dialectique entre lecture proche et lecture distante doit ainsi permettre de passer avec aisance du *micro* au *macro* sans perdre de vue l'un ou l'autre. En zoomant et en dézoomant, il devient possible de discerner ce qui rend un élément distinctif dans un contexte très large. En cela, une telle dialectique permet de comprendre non seulement les résultats de la recherche, mais aussi les conditions numériques de leur production, en rendant visibles les couches successives du processus herméneutique à l'œuvre dans l'histoire numérique. Combiner des niveaux de lecture suggère d'explicitier les pratiques numériques en soulignant la coconstruction du savoir historique à l'intersection des outils, des infrastructures et des interprétations. Elle incarne ainsi une forme de lecture historiographique adaptée à l'ère des humanités numériques ¹⁶⁴.

163. MADDEN Amanda, « Menocchio Mapped : Italian Microhistory and the Digital Spatial Turn », in *Zoomland*, De Gruyter Oldenbourg, 2023, p. 77-96.

164. FICKERS Andreas et CLAVERT Frédéric, « On pyramids, prisms, and scalable reading », *Journal of Digital History*, vol. 1, n° 1, 2021, p. 1-13.

4 Éditer les sources, modéliser le corpus : Les *Documents diplomatiques suisses* comme terrain d'expérimentation

Situé à l'intersection entre la recherche en histoire contemporaine et des humanités numériques, le centre de recherche des Documents diplomatiques suisses offre un cadre propice à l'expérimentation de nouveaux modèles d'édition numérique. En amorçant une transition d'une démarche centrée sur la rétro-numérisation à orientation vers une approche orientée données, le centre de recherche a récemment mis en œuvre un processus d'encodage ciblé de ses publications. Après avoir présenté la nature hybride du projet éditorial, l'exposé de la structuration sous-jacente des documents encodés permettra d'envisager une première exploration de son contenu et des métadonnées qui s'y réfèrent.

4.1 Entre contribution historiographique et innovation numérique

Lancée dans les années 1970, le projet de publication des Documents Diplomatiques Suisses (DDS) a marqué un tournant majeur dans l'historiographie helvétique contemporaine¹⁶⁵. Comme le soulignait Fleury, elle représente une « étape qualitative considérable » franchie à la fin du XX^e siècle¹⁶⁶. Plus qu'une simple addition à la bibliographie existante, la collection a transformé en profondeur les conditions de la recherche historique¹⁶⁷. En comblant un vide notable - à savoir l'absence d'une documentation scientifique systématique sur la politique extérieure de la Suisse et sur les jugements émis par ses représentants à l'étranger - la publication des volumes a contribué à la constitution d'une base documentaire inédite et consolidée à partir des fonds des Archives fédérales suisses. Ce faisant, le projet a activement contribué au renouvellement intellectuel du champ historique, en élargissant les objets de re-

165. Nous n'entrerons pas ici dans le détail de la constitution du projet de recherche. Notons que Fleury en retrace sa genèse et son développement. FLEURY Antoine, « Les documents diplomatiques suisses : histoire d'une publication majeure des historiens suisses », 1991. Par ailleurs, le centre de recherche a documenté une partie son histoire sous le registre thématique <https://dodis.ch/T1341>

166. *Ibid.*, p. 533.

167. L'édition des Documents diplomatiques suisses comprend trois séries : la première couvre la période 1848–1945 et compte quinze volumes ; la deuxième porte sur les années 1945–1989 et comprend, à ce jour, douze volumes. La troisième série, consacrée à la décennie 1990–1999, est actuellement en cours de publication.

cherche et les sources mobilisables. Loin de se limiter à l'histoire diplomatique ou à la politique étrangère *stricto sensu*, l'édition porte une attention particulière aux dynamiques internes de la société suisse, telles que les enjeux sociaux, culturels, financiers ou humanitaires, en les recontextualisant dans les rapports multiformes qu'entretient le pays avec son environnement international¹⁶⁸. En ce sens, le projet a mis en évidence que l'histoire des relations extérieures de la Suisse ne saurait être comprise sans prendre en compte la complexité des acteurs impliqués et l'entrelacement des influences internes et externes¹⁶⁹.

Au-delà de cet enrichissement thématique, la mise en œuvre du programme DDS a fortement structuré le paysage de la recherche historique en Suisse. Fondée sur la collaboration entre les instituts d'histoire des différentes universités suisses et le soutien du Fonds national de la recherche scientifique (FNRS), le projet a engendré une dynamique de coopération interinstitutionnelle inédite, tout en se distinguant par son indépendance vis-à-vis de l'État et de l'administration fédérale. Les retombées scientifiques sont notables et durables : la collection a donné lieu à une production académique abondante, alimentant des articles, des communications lors de colloques et de nombreuses thèses de doctorat. Elle a en outre bénéficié d'une reconnaissance internationale, saluée par des spécialistes étrangers, confirmant ainsi son rôle structurant dans le renouvellement des études historiques, tant en Suisse qu'à l'étranger¹⁷⁰. Plus récemment, la production historiographique autour du projet DDS s'est enrichie avec la création des *Quaderni di Dodis* en 2012, puis de la revue numérique *Saggi di Dodis* en 2019¹⁷¹.

Le travail pionnier du centre s'est également affirmé dans le domaine technologique. Dès 1997, la mise en ligne d'une base de données relationnelle* via une interface librement accessible a permis au centre de se positionner très tôt comme une entreprise

168. Parmi ces acteurs, on compte le système de collégialité du gouvernement fédéral, le rôle significatif du parlement, les vastes droits populaires et les instruments de démocratie directe, les compétences importantes des cantons en raison de la constitution fédéraliste, une vie associative et ecclésiastique importante, un paysage médiatique hétérogène, des centres scientifiques connectés internationalement, et les voix très influentes de la place financière et de l'économie d'exportation. BÜRGISSE Thomas, « "Dodis" als Instrument zur Erforschung einer politischen Geschichte der Schweiz », *traverse – Revue d'Histoire – Zeitschrift für Geschichte*, vol. Politikgeschichte in der Schweiz- eine historiografische Skizze, n° 1, 2013, p. 292-293.

169. FLEURY, « Les documents diplomatiques suisses », *art. cit.*, p. 532.

170. FLEURY, « Les documents diplomatiques suisses », *art. cit.*, p. 529-531.

171. Tandis que les *Quaderni* publient des études scientifiques sous forme de monographies, de volumes collectifs ou d'éditions thématiques de sources, les *Saggi* proposent des contributions portant sur l'histoire internationale de la Suisse, les méthodes d'édition critique, l'analyse des sources et les humanités numériques.

éditoriale hybride, combinant production analogique et diffusion numérique des résultats de recherche¹⁷². Notons que Dodis accorde une préoccupation centrale aux critères de la science ouverte. A cet effet, le centre répond aux exigences qui reposent sur les principes FAIR et les recommandations de l'Open Science Policy de l'Académie suisse des sciences humaines et sociales (ASSH)¹⁷³ afin de garantir l'accessibilité, la gratuité, la transparence, la réutilisabilité ainsi que la durabilité de ses données et de ses publications de recherche¹⁷⁴. Par ailleurs, les métadonnées descriptives relatives aux documents - telles que le titre, la date, l'auteur, les sujets traités, les références archivistiques, les institutions contributrices ou encore les conditions de diffusion - sont également mises à disposition en libre accès sous différents formats *opendata.dodis.ch* afin de servir à des recherches ultérieures¹⁷⁵. Conçue comme un complément des volumes imprimés, la base de données permet d'intégrer, initialement sous la forme de fac-similés, des documents non retenus dans l'édition papier - en particulier des pièces longues ou des rapports volumineux -, enrichissant ainsi le base documentaire de l'édition scientifique¹⁷⁶.

Sur le plan des pratiques de recherche, sa base de données s'impose comme un outil de recherche essentiel, dont le caractère instrumental se manifeste dans un système d'indexation numérique approfondi. D'une part, les index fournissent aux chercheur-euse-s des informations critiques sur les sources. D'autre part, et c'est là un apport fondamental, l'indexation des documents, structuré selon les catégories « Personne », « Organisation » et « Nom géographique », permet de mettre en relation les différents contenus de la base de données, offrant une lecture transversale et en dévoilant les connexions entre acteurs, institutions et lieux. Un système de permaliens assure un accès stable aux documents et à leurs entités associées. L'ensemble vise à faciliter la navigation, l'identification des contenus pertinents et leur réutilisation dans un cadre de recherche historique. Pour reprendre les termes de Bürgisser, « [l']indexa-

172. PERRENOUD, « Outils informatiques et documents diplomatiques : L'exemple d'une base de données sur les relations internationales et la politique étrangère de la Suisse », *art. cit.*, p. 51.

173. En tant qu'infrastructure de recherche soutenue par l'ASSH, Dodis s'engage à publier ses contenus sous licences ouvertes, à documenter ses métadonnées selon des standards établis, et à favoriser la diffusion à long terme via des interfaces et identifiants pérennes. IMMENHAUSER Beat, Open Science Policy de l'Académie suisse des sciences humaines et sociales, Zenodo, 02.2019.

174. ZALA Sacha et CLAVADETSCHER, « Geheimdokumente und Open Science », *Stimme – wer wird gehört ? / La Voix : qui écoute-t-on ?*, n° 2, 2024, p. 14-16.

175. FELTEN-KURY Lars VON, « Forschen – Vernetzen – Vermitteln. Die Forschungsstelle "Diplomatische Dokumente der Schweiz" (Dodis) », *traverse – Revue d'Histoire – Zeitschrift für Geschichte*, vol. Zu Fuss, n° 1, 2025, p. 113-121.

176. MEIER Martin, « Die Diplomatischen Dokumente der Schweiz (DDS) und die Datenbank DoDiS », *Politorbis*, vol. 44, n° 1, 2008, p. 42.

tion, en tant qu'outil de travail servant à identifier des documents individuels, a créé [...] une image des réseaux personnels et institutionnels nationaux, internationaux et transnationaux [...] »¹⁷⁷. Cette attention s'est plus récemment traduite dans le cadre du projet *Metagrid* en vue de favoriser la mise en réseau des ressources en sciences humaines. Initié par Dodis avec le soutien de l'Académie suisse des sciences humaines et sociales (ASSH), le projet vise à assurer l'interconnexion de différents sites web et bases de données de manière intégrée - en particulier autour des entités « personne » - afin d'enrichir l'exploration des données historiques dans une interface intégrée¹⁷⁸. L'ensemble des initiatives mentionnées ici par le centre concourt à l'objectif central du projet : délivrer à la communauté académique - et au-delà - un corpus documentaire à haute valeur scientifique, durablement accessible et rigoureusement référencés.

4.2 Définition et modélisation du corpus

Initialement, le centre de recherche a adopté une approche fondée sur la rétro-numérisation d'images d'archives, l'établissement de calendriers de résumé, et la constitution d'une base de données structurée¹⁷⁹. Ce processus s'est progressivement enrichi par l'intégration de transcriptions encodées selon le standard TEI-XML librement accessible depuis son interface. Cet engagement, relativement nouveau, est cité pour la première fois en 2019¹⁸⁰ puis est explicitement mentionné dans le volume 27 des DDS, publié en 2022¹⁸¹. Bien que les notices éditoriales des volumes ultérieurs ne signalent pas de bouleversements techniques notables, leur évolution constitue un indice significatif d'un glissement du métadiscours éditorial vers une convergence progressive avec les standards numériques de la communauté scientifique¹⁸². Alors que le centre fondait jusqu'alors sa procédure de publication sur la matérialité de la source originale¹⁸³, ces notices éditoriales manifestent une adhésion croissante à une logique de réutilisabilité et d'interopérabilité des données. Le travail initial de saisie des métadonnées est désormais complété par une structuration sémantique de son contenu : l'indexation

177. BÜRGISSER, « "Dodis" als Instrument zur Erforschung einer politischen Geschichte der Schweiz », *art. cit.*, p. 295. *trad.*

178. SIBILLE, « Networking Digital Documents », *art. cit.*, p. 202.

179. VOGELER, « The "assertive edition" », *art. cit.*

180. DOCUMENTS DIPLOMATIQUES SUISSES, Dodis 2.5 en ligne!, 2019.

181. ZALA Sacha, *Documents diplomatiques suisses*, Zürich : Chronos Editions Zoé, 2022, XXII.

182. ZALA Sacha, « Diplomatic Documents of Switzerland. Volume 1993 Documenti diplomatici svizzeri. Volume 1994 Documents diplomatiques suisses. Volume 1994 Diplomatische Dokumente der Schweiz. Band 1994 », 2025, XXII.

183. VOGELER, « The "assertive edition" », *art. cit.*

établit des liens explicites vers les fiches des entités référencées, contribuant à la modélisation des données. En ce sens, le type d'interaction avec les documents édités ne relève plus exclusivement d'une logique d'utilisation traditionnelle¹⁸⁴, mais rend au contraire possible une focalisation sur la manière dont le corpus est modélisé. C'est cette approche, explicitement orientée vers la représentation formelle des sources éditées sous la forme de données, qui retient ici notre attention.

La mise en données des documents édités dépend d'une typologie documentaire hiérarchisée, basée sur leur degré de centralité dans les thématiques historiques abordées, et détermine les opérations de traitement applicables. À cet égard, les documents publiés dans les DDS bénéficient d'un degré d'enrichissement accru de leur contenu¹⁸⁵. Couplés à une description avancée des métadonnées, ces documents font en effet l'objet d'un traitement particulier fondé sur une transcription minutieuse, doublée d'une vérification croisée, d'un collationnement et d'une annotation contextualisée avant validation HTML. Cette typologie détermine par ailleurs le corpus dont l'ampleur permet d'envisager des traitements à grande échelle. À cet égard, le rapport annuel de Dodis pour l'année 2023 signale que 9000 documents encodés en TEI-XML sont accessibles via l'interface du projet¹⁸⁶; ce nombre s'élevant à 9700 l'année suivante¹⁸⁷.

Dès lors, le texte édité numériquement nécessite une stratégie cohérente afin d'être adaptée à la réception - et au traitement ultérieur - par un ordinateur. Cela implique, en outre, de construire une structure formelle explicite à l'intérieur de laquelle les textes peuvent être intégrés et rendus traitables informatiquement¹⁸⁸. Sur le plan technique, le recours au langage de balisage *eXtensible Markup Language* (XML) constitue aujourd'hui l'approche privilégiée pour la modélisation de texte. Publié pour la première fois en 1998 par le World Wide Web Consortium, ce format dit semi-structuré repose sur une structuration arborescente des données, conçue pour représenter le texte comme un ensemble hiérarchisé d'unités linguistiques, telles que les pages, les chapitres, les

184. HILTMANN Torsten, « Vom Medienwandel zum Methodenwandel : Die fortschreitende Digitalisierung und ihre Konsequenzen für die Geschichtswissenschaften in historischer Perspektive », in DÖRING Karoline Dominika *et alii* (dir.), *Digital History*, De Gruyter, 2022, p. 31-35.

185. ZALA, « Diplomatic Documents of Switzerland. Volume 1993Documenti diplomatici svizzeri. Volume 1994Documents diplomatiques suisses. Volume 1994Diplomatische Dokumente der Schweiz. Band 1994 », *art. cit.*, XXII-XXIII.

186. DIPLOMATISCHE DOKUMENTE DER SCHWEIZ - DOCUMENTS DIPLOMATIQUES SUISSES - DOCUMENTI DIPLOMATICI SVIZZERI, « Jahresbericht 2023 - Rapport annuel 2023 - Rapporto annuale 2023 », *art. cit.*

187. DIPLOMATISCHE DOKUMENTE DER SCHWEIZ - DOCUMENTS DIPLOMATIQUES SUISSES - DOCUMENTI DIPLOMATICI SVIZZERI, « Jahresbericht 2024 - Rapport annuel 2024 - Rapporto annuale 2024 », 2025.

188. JANNIDIS et FLANDERS, « The Shape of Data in the Digital Humanities », *art. cit.*, p. 27.

paragraphes, les phrases et les différents éléments qui constituent ces dernières¹⁸⁹. En dissociant la structure logique du texte de sa forme, le XML permet de le représenter comme une entité abstraite constituée d'éléments imbriqués lisibles par un humain et par l'ordinateur, sans addition de codes spéciaux ou données binaires¹⁹⁰.

En tant que métalangage, le format XML définit ainsi une syntaxe permettant de représenter la structuration hiérarchique du texte. Cependant, il ne spécifie pas lui-même les types d'éléments autorisés, ceux-ci étant définis par schémas ou des standards spécifiques. Comme le souligne Burnard, « [...] le standard XML ne dit rien sur la façon dont les éléments ou attributs doivent être nommés [...], et moins encore sur ce que leur nom signifie »¹⁹¹. À cet effet, la TEI, et plus particulièrement ses *Guidelines*, définit un large ensemble d'éléments balisés, chacun porteur d'une signification spécifique, à laquelle peuvent être rattachées des règles d'usage. Parce qu'elle est exprimée en XML, la TEI modélise le texte comme une structure hiérarchique de composants formels, sans pour autant le réduire à une suite d'unités linguistiques. Il vise à rendre visible des phénomènes sémantiques et interprétatifs en fournissant un cadre explicite pour décrire les éléments et leurs classes présents dans le texte. Une balise est ainsi destinée à expliciter la signification ou le rôle de l'objet linguistique qu'il encode. Il s'agit à la fois de discerner sa signification en tant qu'élément distinct d'autres éléments de données au sein du même système de données, et son lien référentiel à travers l'intégration d'un identifiant¹⁹².

Dans le cas de Dodis¹⁹³, modéliser implique ici une réflexion sur la structure et l'organisation des documents originaux. Il s'agit de discerner les éléments constitutifs aux documents diplomatiques édités, distinguant, d'une part, les éléments structu-

189. La conception arborescente du texte renvoie à une théorie centrale de la modélisation du texte développée dans les années 1990, connue sous le nom de *Ordered Hierarchy of Content Objects* (OHCO). Dans le cadre de ce travail, nous ne développerons pas davantage cette théorie, ni les critiques qui lui ont été adressées. Pour une présentation détaillée, voir KERVEGAN Paul, « Modélisation, enrichissement sémantique et diffusion d'un corpus textuel semi-structuré : le cas des catalogues de vente de manuscrits », 2022, p. 30-34, 42-44.

190. JANNIDIS et FLANDERS, « The Shape of Data in the Digital Humanities », *art. cit.*, p. 332.

191. BURNARD, *Qu'est-ce que la Text Encoding Initiative ?*, *op. cit.*

192. JANNIDIS et FLANDERS, « The Shape of Data in the Digital Humanities », *art. cit.*, p. 328.

193. Il convient de souligner l'émergence de démarches concertées visant à structurer des pratiques éditoriales communes, en particulier dans le domaine de l'édition numérique de sources diplomatiques. Élaboré par les projets Dodis et le Foreign Relations of the United States (FRUS), et ce, dans le prolongement des travaux menés au sein du Comité international des éditeurs de documents diplomatiques (ICEDD), un guide propose un ensemble de recommandations méthodologiques destinées à restituer les meilleures pratiques en matière de publication numérique, d'annotation, de structuration et de diffusion des documents diplomatiques, en particulier à travers l'usage du TEI. INTERNATIONAL EDITORS OF DIPLOMATIC DOCUMENTS, *Best practices for digital diplomatic documentary editions*, 02.2025.

rels - incluant les métadonnées documentaires et l'organisation textuelle (en-tête, formules liminaires, titres, paragraphes, listes, tableaux, formules de clôture, signatures, annotations manuscrites) - et, d'autre part, les entités référencées dans le contenu, telles que les personnes, les organisations et les noms géographiques. À ce cadre descriptif, nous pouvons associer un répertoire d'éléments TEI pour décrire, avec le degré de granularité souhaitée, chaque composant structurel ou référentiel à encoder. L'exemple suivant, bien qu'il n'intègre pas l'ensemble des éléments mentionnés précédemment, permet néanmoins d'appréhender la logique de modélisation appliquée aux documents édités par Dodis.

```

1 <TEI>
2 <!-- Déclaration des contraintes du modèle de données Dodis -->
3 <teiHeader>
4 <!-- Métadonnées descriptives -->
5 </teiHeader>
6 <text>
7 <body>
8 <div type="doc">
9 <head>
10 <title type="main">Titre principal</title>
11 <title type="sub">Sous-titre</title>
12 </head>
13 <opener>
14 <dateline>
15 <placeName ref="http://dodis.ch/G43">Berne</placeName>,
16 <date when="1993-04-19">19 avril 1993</date>
17 </dateline>
18 </opener>
19 <p>
20 <persName ref="http://dodis.ch/P31966">Adolf Ogi</persName>
21 <orgName ref="http://dodis.ch/R27">DFAE</orgName>.
22 </p>
23 <p>
24 <note>
25 <ref target="https://dodis.ch/61433">dodis.ch/61433</ref>.
26 </note>
27 </p>
28 <p> <note>
29 <!-- Annotations éditoriales -->
30 </note> </p>
31 </div>
32 </body>
33 </text>
34 </TEI>

```

FIGURE 1 – Modélisation simplifiée d'un document TEI-HTML édité par Dodis

La modélisation ci-jointe¹⁹⁴ formalise la structure interne des documents, enrichit leurs métadonnées ainsi que celles des entités mentionnées, et précise les liens sémantiques qui les relient. Le document doit respecter la syntaxe XML, avec balises ouvrantes et fermantes et doit être correctement imbriquées dans l'arborescence du fichier. La balise ouvrante marque le début d'un élément dans la séquence de caractères, tandis que la balise fermante en indique la fin. Quant aux attributs, ils enrichissent les éléments d'informations supplémentaires¹⁹⁵.

Le document TEI-XML s'articule autour de la balise racine <TEI>, qui déclare l'instance de modèle TEI et spécifie le renvoi vers un schéma spécialisé utilisé pour valider la structure et le contenu de l'encodage du document selon les contraintes définies par le projet. Cette déclaration assure que tous les éléments seront validés selon les définitions adoptées par Dodis.

La section <teiHeader> contient l'ensemble des métadonnées décrivant le fichier TEI, décomposé en trois ensembles. Elle comprend la description bibliographique du fichier électronique <fileDesc> qui documente le titre du document encodé dans la base de données, le nom de l'éditeur-riche et la date de publication. Lui est associée une déclaration d'encodage <encodingDesc>, spécifiant l'objectif du projet, son périmètre, l'équipe éditoriale, ainsi que les principes éditoriaux adoptés pour l'encodage. Enfin, un historique des révisions <revisionDesc> permet de suivre les modifications successives apportées au fichier.

Sur le plan structurel, la section <text> renferme l'ensemble du contenu du document diplomatique et organise sa structure interne selon une hiérarchie imbriquée. Elle contient une sous-section <body>, au sein de laquelle chaque document-source est encapsulé dans une unité structurante, balisée avec <div>, identifiée comme un document autonome grâce à l'attribut @type="doc". Cette division structure le document en trois zones principales : l'en-tête <head> - comprend les titres et sous-titres ; les formules liminaires <opener>, inclue l'élément <date line> fournissant une indication du lieu et de la date de production du document original ; enfin, le corps textuel se constitue de paragraphes <p> et, dans une moindre mesure, des éléments tels que

194. L'encodage réalisé en TEI-XML vise principalement à la mise à disposition des contenus au sein d'une interface de consultation en ligne. À cet égard, le format HTML est généralement privilégié. La conversion repose sur l'application de feuille de style XSLT qui établissent les correspondances entre la structure fournie par le XML et les éléments du format de sortie destinés à l'affichage. PIERAZZO, *Digital scholarly editing*, op. cit., p. 125. Pour cette raison, nous privilégions le format HTML pour sa lisibilité.

195. BURNARD, *Qu'est-ce que la Text Encoding Initiative ?*, op. cit.

des listes, des citations ou des tableaux.

Sur le plan référentiel, la modélisation proposée permet d'inscrire chaque entité mentionnée dans un réseau de références stables, pérennes et exploitables dans des environnements de recherche numériques. L'identification des entités repose entièrement sur l'usage d'identifiants uniques, matérialisés sous la forme d'un permalien issu de l'indexation dans la base de données. Cette liaison s'opère par le biais des attributs `@target` pour les documents, ou `@ref`, attachés à des balises sémantiques relatives aux indications géographiques `<placeName>`, aux personnes `<persName>` et aux organisations `<orgName>`. Ainsi, chaque entité est non seulement identifiée dans le contenu du texte, mais aussi située dans son contexte, en renvoyant vers un identifiant unique. Le balisage ne se réduit pas à l'identification formelle des entités ; il fonctionne comme un outil d'annotation critique capable de rendre compte des interprétations éditoriales intégrées dans le texte encodé. En effet, Dodis opte pour une séparation nette entre, d'une part, le repérage nominal des entités, directement issu du texte original, et, d'autre part, l'apport contextuel, biographique ou fonctionnel intégré sous la forme de notes éditoriales via la balise `<note>`. Cette séparation permet de préserver l'intégrité du texte source tout en assurant une interprétation éditoriale du document¹⁹⁶. Ces informations, bien qu'extérieures à la source originale, participent à la compréhension du document et sont intégrées selon une logique d'annotation interprétative.

Le corpus se présente ainsi comme une construction autonome, distincte de l'artefact textuel qu'il vise à représenter, dans laquelle sont modélisés les éléments jugés comme pertinents par le projet d'édition scientifique. La modélisation mise en place par Dodis ne se limite pas à une structuration purement technique des contenus documentaires : elle intègre explicitement une démarche herméneutique, rendant visible l'acte d'interprétation des documents. En définissant un cadre formel précis, Dodis articule l'impératif de fidélité à la source originale et celui de l'exploitation computationnelle fondée sur des standards scientifiques. Cette approche marque une évolution méthodologique significative : la modélisation devient un vecteur central de sa pratique éditoriale, tant sur le plan de la diffusion du savoir que de sa production.

196. Notons que l'ajout de *tags*, visant à référencer un document selon un ou plusieurs axes thématiques, ne sont pas intégrés à la modélisation mais uniquement référencés sur l'interface Web.

4.3 Déterminer les zones de vigilance du corpus

L'ensemble des choix opérés lors de la modélisation contribue à former un maillage structurel et référentiel. Associées aux métadonnées des documents auxquels ils se réfèrent, cette structuration rend possible une exploitation élargie des documents corpus à l'aide d'outils computationnels¹⁹⁷. Comme l'a soutenu Mayaffre, la dématérialisation du texte hors de son support originel permet, parallèlement, de matérialiser le corpus avec plus de rigueur et ouvre en parallèle la voie à des modes de lectures non linéaires du texte¹⁹⁸. En ce sens, la modélisation du corpus constitue une condition préalable à son exploration computationnelle : les entités qu'il contient deviennent traitables par machine, autorisant *a posteriori* leur intégration dans des méthodes de traitement automatique du langage naturel¹⁹⁹. Abordée comme telle, la modélisation tend à correspondre à un standard de référence au sens du TALN : elle offre un cadre normatif dans lequel les entités sont identifiées *a priori*, tandis que leur ancrage référentiel dans le *monde* est assuré par le biais de permaliens. Toutefois, Hodel souligne que toute tentative de traitement automatique implique une compréhension approfondie du volume documentaire et de ses spécificités²⁰⁰. Dans le cadre spécifique du traitement d'entités nommées, Humbel *et alii.* appelle à une prise en compte de la nature intrinsèque du matériau historique ainsi que les interventions éditoriales antérieures, ces deux dimensions conditionnant directement la définition, la détection et l'interprétation des entités²⁰¹.

En nous concentrant sur ces données semi-structurées, il devient possible d'exploiter la logique d'organisation interne des documents selon le standard TEI ainsi que leur métadonnées pour conduire des analyses préliminaires en amont de toute opération algorithmique. En terme de volume, notre corpus se compose de 4 966 documents encodés selon le standard TEI (camembert files used.py), couvrant la période allant de

197. Dans cette perspective, nous avons eu recours à l'outil développé en interne dans le cadre du projet de recherche, nommé *dodo*, qui permet de télécharger automatiquement, via une interface de programmation, l'ensemble des fichiers disponibles sur l'interface Dodis, dans différents formats. Nous avons extrait deux formats de fichiers : d'une part, les fichiers HTML, contenant le texte encodé selon la structure balisée décrite ci-dessus ; d'autre part, les fichiers JSON, qui regroupent les métadonnées associées à chaque document.

198. MAYAFFRE Damon, « Philologie et/ou herméneutique numérique : nouveaux concepts pour de nouvelles pratiques ? », in BALLABRIGA François Rastier et Michel (dir.), *Corpus en Lettres et Sciences sociales. Des documents numériques à l'interprétation*, Albi, France : Presses universitaires de Toulouse, 2006, p. 17-20.

199. PIOTROWSKI Michael, « Historical Models and Serial Sources », *Journal of European Periodical Studies*, vol. 4, n° 1, 2019, p. 12.

200. HODEL, « Die Maschine und die Geschichtswissenschaft », *art. cit.*, p. 70.

201. HUMBEL *et alii.*, « Named-entity recognition for early modern textual documents », *art. cit.*

1848 à 1993²⁰². Il convient de noter qu'il ne représente qu'une fraction des documents disponible dans la base de données qui comprend au total plus de 43 000 documents, selon les informations accessibles sur la version bêta de la plateforme <https://beta.dodis.ch/>. Le degré de couverture limité des documents encodés - soit un peu plus qu'un dixième - a des implications directes sur l'étendue des entités référencées dans l'indexation du projet éditorial.

Catégorie	Mentions totales	Entités uniques	Entités uniques indexées dans la base de données Dodis en 2024
PER	34 577	5 641	66 249
ORG	11 279	982	30 446
LOC	72 078	1 907	12 603
Total	117 934	8 530	109 298

TABLE 1 – Répartition des entités nommées par catégorie dans le contenu du texte encodé, hors notes de bas de pages

S'arrêter à un tel constat occulte néanmoins la nature complexe des données historiques, de même que l'impact des choix éditoriaux sur ces mêmes données. En effet, les subtilités propres aux documents diplomatiques suisses doivent être articulées dans une double perspective : à la fois des artefacts historiques aux catégories hétérogènes et le résultat d'un ensemble de décisions éditoriales prises dans le cadre du processus de modélisation. Parce que le projet de recherche vise la transmission d'un document dans son intégrité, la modélisation contribue à réintégrer dans le texte la complexité historique qui leur est inhérente tout en intégrant la dimension structurante du travail éditoriale dans le contenu, orientée vers des choix méthodologiques et des objectifs scientifiques précis. Cette double dimension - historique et éditoriale - ne peut être dissociée, mais demande à être pensée dans leur interaction. C'est de cette tension que résulte le corpus tel qu'il est mobilisé dans le cadre de notre recherche. Il convient donc d'en saisir les implications.

Le corpus se distingue par une grande diversité typologique, rassemblant une large gamme de documents issus de la pratique diplomatique et politique. Il comprend notamment des lettres, les procès-verbaux du Conseil fédéral, des mémorandums, ainsi

202. En cohérence avec les travaux menés au centre, nous avons restreint notre corpus aux publications édités jusqu'en 2023. Tenant compte du délai légal imposé par les Archives fédérales suisses pour l'ouverture de ses fonds, le corpus s'étend donc jusqu'à l'année 1993.

que divers type de rapports, qui constituent à eux seuls près de 80% de l'ensemble corpus. Parce que chaque genre documentaire présente ses propres spécificités linguistiques, rhétoriques et formelles, l'hétérogénéité qui en ressort a des implications directes sur la nature du langage employé et la manière dont les entités sont exprimées ou dissimulées dans le texte.

À cette diversité générique s'ajoute une complexité linguistique marquée. La fidélité linguistique, à laquelle Dodis attache une attention particulière, se traduit autant dans la conservation de la langue du document que dans l'orthographe d'époque. Le corpus se caractérise par son multilinguisme, mobilisant les langues nationales suisses et l'anglais dans le cadre d'échanges internationaux. La diversité langagière s'accroît davantage dans le cadre des procès-verbaux du Conseil fédéral, largement représenté dans le corpus. Conformément à l'usage institutionnel, chaque intervenant y prend la parole dans sa langue maternelle, ce qui donne lieu à des textes bilingues, voir trilingues, au sein d'un même document. En segmentant les documents étudiés phrase par phrase, notre approche met en lumière le caractère multilingue du corpus : l'allemand y prédomine. L'anglais et le français restent toutefois fréquemment représentés, tandis que l'italien occupe une place restreinte.




FIGURE 2 – Distribution linguistique du corpus, par phrase

Sur le plan orthographique, de nombreuses abréviations, des capitalisations irrégulières et un style parfois elliptique ou fragmentaire sont également préservés, en accord avec le principe d'intégrité documentaire. Par ailleurs, l'usage fréquent de formes

abrégées pour définir certaines entités introduit un niveau supplémentaire d'ambiguïté : les organisations sont largement désignées par des acronymes, tandis que les fonctionnaires fédéraux sont nommés par leurs paraphes respectifs, de même que les pays.

Une difficulté particulièrement significative tient à la nature dynamique et contextuelle des entités. Ces dernières ne sont pas des unités stables : les noms de lieux évoluent dans le temps, tant sur le plan géographique qu'administratif, tandis que les fonctions associées à une personne, qu'elles soit juridiques, politiques, administratives ou diplomatiques, sont elles-mêmes multiples et susceptible de se modifier au fil du temps. Les organisations, quant à elles, peuvent faire l'objet de reconfigurations structurelles modifiant leur désignation.

À cela s'ajoute le fait qu'une même occurrence peut renvoyer à une diversité d'entités. Un exemple particulièrement illustratif de la présence de métonymie est celui de la mention « Washington ». Celle-ci apparaît 931 fois dans le corpus et se prête à des interprétations multiples. En tant que nom propre, elle peut renvoyer à une personne, soit le premier président des États-Unis George Washington. La difficulté ne réside pas uniquement dans l'ambiguïté intercatégorielle, mais également dans les distinctions faites à l'intérieur des catégories elles-mêmes. Au sein des entités géographiques, « Washington » peut renvoyer à l'État américain ou à la capitale fédérale des États-Unis, alors que dans le registre organisationnelle, la mention peut indiquer l'ambassade de Suisse aux États-Unis, ou le gouvernement américain lui-même.

Classe	Lien vers la base de données	Occurrences
PER	dodis.ch/P32817	2
LOC	dodis.ch/G16	921
LOC	dodis.ch/G9865	1
ORG	dodis.ch/R104	4
ORG	dodis.ch/R118	3
Total		931

TABLE 2 – Références associées à « Washington », par type d'entité et lien

Cette diversité de référents, au sein d'une même forme lexicale, est particulièrement fréquente dans les documents diplomatiques, avec un recours à des formes de désignation métonymique ou métaphorique. De cette manière, ces considérations exigent une vigilance accrue.

Ce bref panorama suggère que l'interprétation des entités dans un corpus historique ne peut se limiter à un appariement formel fondé sur la reconnaissance de chaînes de caractères. Ces dernières ne doivent pas être considérées comme des unités fixes, mais comme des objets polysémiques dont le sens varie en fonction du genre discursif, de la langue employée et du contexte de rédaction du document. Elle suppose donc une prise en compte active du contexte d'énonciation et de l'historicité de ses différentes formes. Le projet Dodis, conscient de ces enjeux, s'efforce d'y répondre par une procédure rigoureuse d'édition. Toutefois, ces médiations éditoriales produisent à leur tour des effets pour lesquels il convient de s'interroger de manière critique. Deux dimensions se dégagent à cet égard : la transcription et l'indexation.

Sur la transcription, la standardisation rigoureuse et la vérification systématique des transcriptions, selon des procédures strictement définies, contribuent à une réduction significative des erreurs. En garantissant un haut degré de fidélité aux textes sources et aux entités qu'ils contiennent, cette rigueur permet de pallier en partie aux contraintes bien documentées de l'océrisation de masse, et les problèmes subséquents de « bruits » qui sont susceptibles d'affecter l'ensemble de fonds d'archives²⁰³. Néanmoins, le protocole normatif du travail éditorial fait apparaître des formes textuelles atypiques. L'usage d'éléments typographiques, tels que l'apostrophe typographique, les majuscules accentuées, les tirets demi-cadratin ou encore des espaces insécables introduit une augmentation de la complexité de traitement en aval, dans la mesure où il s'écarter des pratiques standardisées. Si ces dernières sont justifiées dans une logique philologique ou éditoriale, elles produisent paradoxalement une augmentation de la complexité de traitement computationnelle du texte en aval. Ajoutons à cela que l'histoire du corpus met également en évidence des disparités structurelles. Les documents antérieurs au volume 27 n'ont pas été initialement encodés en TEI, mais convertis *a posteriori* à partir de fichiers .docx. Les différences de parcours dans le traitement éditorial laissent entendre que des décalages dans la structuration ou dans l'alignement des balises peuvent apparaître.

Une remarque complémentaire s'impose concernant l'indexation. En effet, cette dernière repose davantage sur une logique de pertinence contextuelle que sur un principe d'exhaustivité : seules les entités jugées comme historiquement significatives sont intégrées à la base de données. Cette orientation implique la mise en pratique des

203. EHRMANN *et alii*, « Named Entity Recognition and Classification in Historical Documents », *art. cit.*

principes suivants : Berne n'est pas indexée quant elle se réfère à la capitale administrative ; la Confédération helvétique est exclue ; les gouvernements nationaux ne sont généralement pas considérés comme des entités à indexer. Ces choix reflètent une lecture implicite du corpus qui détermine ce qui mérite d'être rendu visible.

Par ailleurs, l'indexation se voit être étroitement liée aux modalités de transcription. Les documents modélisés sont parfois publiés sous forme d'extraits de sources, signalés par des points de suspension entre crochets, accompagnés d'une note de bas de page précisant que seul le fac-similé offre l'intégralité du contenu. Ce choix éditorial, motivé par la volonté de ne pas rendre visible les longueurs et les redondances dans le texte modélisé a un impact direct sur l'indexation, réduisant la couverture. En outre, les notes manuscrites en marge ne sont pas intégrées dans le corps du texte transcrit, mais font l'objet de renvois en note de bas de page, qui en indiquent le contenu et renvoie à la cote correspondante aux Archives fédérales suisses. L'exemple de la correspondance est particulièrement éclairant à cet égard. Bien que les métadonnées capturent la structure discursive du document - en indexant l'auteur, destinataire, signataire, ou encore mentionné - le texte modélisé ne réfère pas systématiquement toutes les entités. En effet, les entités autrices et destinataires sont exclues de l'encodage. En ce sens, les transcriptions ne peuvent être considérées comme exhaustives sur le plan référentiel.

Catégorie	Entités uniques dans le contenu	Entités uniques dans les métadonnées
PER	5 641	8 583
ORG	982	2 907
LOC	1 907	2 500
Total	8 530	13 990

TABLE 3 – Nombre d'entités nommées uniques par catégories, extraites du contenu principal et des métadonnées

Ces données mettent en évidence un décalage significatif entre les informations rendues visibles dans le texte balisé et celles présentes dans le champ des métadonnées, ces dernières offrant une extension référentielle importante. Selon le mode de représentation de la source, qu'elle soit issue d'une rétro-numérisation ou d'une modélisation, les informations indexées peuvent ainsi connaître un déséquilibre important. En ce sens, l'indexation apparaît comme une opération distribuée entre les différentes

strates de représentation du document.

Ainsi, les choix de transcription, d'encodage et d'indexation opèrent un effet structurant sur l'utilisation computationnelle des données textuelles. La sélection opérée lors de la mise en données des documents analogiques délimite le territoire d'exploration du corpus : ce qui est indexé devient traitable pour l'outil numérique ; ce qui ne l'est pas reste à l'extérieur de son champ. De cette manière, le modèle conditionne radicalement les questions que l'on pourra poser sur les données elles-mêmes. La forme actuelle du corpus n'est pas la simple émanation des sources historiques, mais doit être appréhendée comme le produit d'un travail structurant opéré par les objectifs méthodologiques et scientifiques du centre de recherche. La reconfiguration du texte historique en données implique une représentation spécifique de l'information selon des critères techniques et interprétatifs²⁰⁴. Toute tentative d'exploitation algorithmique doit tenir compte de la densité historique du matériel-source et des effets structurants du travail éditorial. Il s'agit donc moins de rectifier les choix éditoriaux que de les rendre visibles et traitables dans une chaîne de traitement automatisé, en assumant pleinement leur rôle dans la constitution initiale des données.

204. DRUCKER Johanna, « Humanities Approaches to Graphical Display », *Digital Humanities Quarterly*, vol. 5, n° 1, 2011.

5 Implémenter une lecture algorithmique : conception et déploiement d'une chaîne de traitement pour les entités nommées

En prenant comme point de départ le corpus documentaire préalablement encodé, ce chapitre s'attache à décrire notre chaîne de traitement d'entités nommées. Adoptant une démarche exploratoire, notre objectif est d'enrichir automatiquement le corpus documentaire en le soumettant à un traitement computationnel. À cette fin, nous présenterons la bibliothèque retenue, ainsi que la chaîne logicielle qui guidera notre travail. Le recours à une architecture de réseaux neuronaux sera ensuite discuté et mis en contexte. Sur cette base, nous distinguerons deux volets : d'une part, le repérage et la classification des entités ; d'autre part, leur mise en relation à un identifiant unique via une base de connaissance dérivée du corpus. Tout au long de ce processus, nous veillerons à documenter nos choix, de même que les transformations opérées successivement sur les données seront documentés, ainsi que les limites inhérentes à l'emploi de modèles computationnelles.

5.1 Une chaîne de traitement à partir de l'outil spaCy

Dans le cadre du présent travail, nous avons utilisé l'outil spaCy, choix motivé par la continuité avec les travaux préalablement menés par le centre de recherche. SpaCy est une bibliothèque logicielle ouverte dédiée au TALN, conçue pour être intégrée dans l'écosystème Python. Assortie d'une documentation systématique, il fournit un ensemble de codes réutilisables permettant de mobiliser différentes composantes logicielles, notamment dans le cas du traitement d'entités nommées.

Dès sa création en 2014 et sa publication officielle en février 2015, spaCy se distingue par son orientation résolument tournée vers une utilisation en production. L'accent est mis sur l'efficacité et la robustesse dans des contextes d'applications réelles, plutôt que sur un usage académique ou pédagogique. À noter que spaCy s'écarte du modèle communautaire des projets *open-source*, en adoptant une logique résolument commerciale²⁰⁵. SpaCy entend fournir un outil *clé en main* à destination du domaine

205. Le blog de spaCy, maintenu par ses cofondateurs Matt Honnibal et Ines Montani, est à cet égard particulièrement éclairant sur la logique de commercialisation que sous-tend l'outil. Voir en particulier HONNIBAL Matthew et MONTANI Ines, *Introducing spaCy*, 02.2015.

de l'industrie. Cette orientation vers les besoins applicatifs concrets se manifeste notamment dans la publication de multiples guides pratiques d'utilisation. En raison de son orientation résolument applicative, spaCy demeure sous-documenté dans la littérature scientifique actuelle. À notre connaissance, aucune publication située dans le champ de la critique des outils numériques n'a, à ce jour, été consacrée à spaCy. Par ailleurs, bien que le projet soit publié sous licence open-source, il reste à relever que les possibilités de contribution communautaire apparaissent limitées : le développement de l'outil conserve une structure fortement centralisée et étroitement contrôlée par l'équipe de maintenance qui en assume l'essentiel des responsabilités. Ce degré de gouvernance implique, de la part des utilisateurs, une délégation de confiance envers l'outil lui-même.

À cette étape, il importe de mentionner que spaCy ne propose pas nativement de système intégrée pour les tâches de reconnaissance et de liaison d'entités nommées. Du fait de cette contrainte architecturale, nous les décomposerons en deux tâches distinctes, tout en apportant une vue analytique respective.




FIGURE 3 – Chaîne de traitement d'une entité nommée à partir du texte d'entrée

La figure 3 illustre la chaîne de traitement d'une entité nommée à partir d'un texte au format HTML en distinguant clairement deux processus complémentaires. La branche supérieure réalise d'abord la reconnaissance des entités présentes dans le texte, puis

les catégorisent dans le type sémantique adéquat. Les variantes textuelles présentes dans le contenu - telles que (« M. Petitpierre », « Max », « Petitpierre ») - sont ainsi identifiées et regroupées au sein de la catégorie "Personne". Cette étape fournit un ancrage référentiel dans le texte brut en délimitant et en étiquetant les mentions textuelles, tout en fournissant des unités fiables pour des tâches en aval.

La branche inférieure détaille la liaison des entités. Dans un premier temps, la détection de la mention vise le repérage de chaque forme textuelle dans le texte. Cette étape s'appuie alors sur la tâche de reconnaissance préalablement effectuée. La sélection des candidats lui succède, opération qui consiste à identifier les candidats possibles correspondant aux mentions préalablement détectées. Ces candidats sont enregistrés dans un module dédié, la base de connaissance, intégrant des caractéristiques qui leur sont propres. Le module de désambiguïsation vient ensuite interroger cette même base de connaissance afin de lever les ambivalences susceptibles de se présenter dans la recherche de l'identifiant. À l'issue du processus, un identifiant canonique se voit être attribué à la mention, ici <https://dodis.ch/P5>.

À terme, les sorties des deux branches convergent, de sorte à renvoyer la catégorie de l'entité issue de la branche supérieure, ainsi que son identifiant résultant de la branche inférieure, dans le cas présent référencé dans la base de données Dodis.

5.2 Les réseaux neuronaux face au texte : entre performance computationnelle et lisibilité interprétative

La propriété logicielle de spaCy a récemment permis de chaîner l'outil à différents modèles de langage dit *pré-entraînés*²⁰⁶. Pour mesurer l'intérêt de cette approche, il convient d'évoquer brièvement les avancées récentes en apprentissage profond²⁰⁷. Les modèles de réseaux de neurones modernes permettent de générer une représentation de chaque unité lexicale, en fonction de son contexte d'apparition : l'objectif est de modéliser les dépendances entre les mots et les phrases afin de capter leurs relations syntaxiques et sémantiques, même lorsque les unités lexicales sont éloignées

206. spaCy, Release v3.0.0 : Transformer-based pipelines, new training system, project templates, custom models, improved component API, type hints & lots more · explosion/spaCy, 2021.

207. Nous ne reviendrons pas en détail sur le développement historique des modèles de réseaux de neurones. Pour un compte rendu synthétique voir ROBERGE Jonathan et LEBRUN Tom, « BERT, GPT-3, Timnit Gebru et nous : L'intelligence artificielle à la conquête du langage », *Sociologie et sociétés*, vol. 53, n° 1-2, 2023, p. 237-243. Pour une approche centrée sur les documents historiques, nous renvoyons à EHRMANN *et alii*, « Named Entity Recognition and Classification in Historical Documents », *art. cit.*

dans le texte²⁰⁸. De cette manière, l'entité se voit être déterminée par sa dépendance situationnelle.

En raison des performances supérieures qu'il offre, l'apprentissage neuronale s'est ajouté aux approches computationnelles antécédentes, à savoir les approches symboliques et les méthodes d'apprentissage automatique. Tandis que les premières reposent sur des règles explicites ou sur des typologies expertes, les secondes sont fondées sur une ingénierie de caractéristiques*, exigeant dans les deux cas une adaptation manuelle des systèmes computationnels aux spécificités du corpus traité. Si elles demeurent utiles - les premières pour leur interprétabilité, les secondes pour leur capacité à ajuster successivement les modèles aux corpus traités - leur portabilité reste limitée, en particulier lorsqu'elles sont appliquées à un matériel historique. Ces dernières nécessitent en effet une révision constante des ressources, dans la mesure où les indices mobilisées par le modèle doivent être définis manuellement, et ce, en amont de la phase d'entraînement, qu'il s'agisse de la variation orthographique, de la diachronie linguistique ou encore de la structure des sources²⁰⁹. À l'inverse, les modèles neuronaux possèdent une capacité d'adaptation autonome.

Introduit dans un article désormais séminal, le modèle *Bidirectional Encoder Representations from Transformer* (BERT) illustre cette progression²¹⁰. Ce dernier repose sur un mécanisme d'*auto-attention*, visant à accomplir deux objectifs complémentaires : prédire certains mots en les masquant, et déterminer si deux phrases sont consécutives dans le corpus. En démasquant le mot manquant ou en déterminant la phrase suivante, la modèle agit par comparaison de sa sortie aux données réelles d'entrée, de sorte à ajuster progressivement sa prédiction de manière autonome. La sortie de la couche de neurones ainsi produite est transmise à la couche supérieur, où la valeur de sortie devient alors celle d'entrée²¹¹. Le modèle BERT disposant de douze couches de neurones, l'opération est ainsi exécutée à douze reprises²¹². C'est sur la base de

208. Hu Zhentao *et alii*, « Deep learning for named entity recognition : a survey », *Neural Computing and Applications*, vol. 36, n° 16, 2024, p. 9003.

209. VAJJALA Sowmya *et alii*, *Practical Natural Language Processing : A Comprehensive Guide to Building Real-World NLP Systems*, Beijing Boston Farnham Sebastopol Tokyo : O'Reilly, 2020, p. 149-151.

210. DEVLIN Jacob *et alii*, « BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding », in *Proceedings of the 2019 Conference of the North, Minneapolis, Minnesota : Association for Computational Linguistics*, 2019, p. 4171-4186.

211. GASTALDI Juan Luis, « Why Can Computers Understand Natural Language ? : The Structuralist Image of Language Behind Word Embeddings », *Philosophy & Technology*, vol. 34, n° 1, 2021, p. 152.

212. DEVLIN *et alii*, « BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding », *art. cit.*, p. 4173.

cet exercice *à trou*, que le modèle déduit la validité de sa réponse. Cet apprentissage *auto-supervisé* vise ainsi à déléguer au modèle la capacité de déterminer les caractéristiques pertinentes des éléments à modéliser dans le texte²¹³. Le pré-apprentissage obtenu produit des représentations réutilisables, adaptées à chaque énoncé textuel, qui peuvent être transférées vers des tâches spécifiques, comme le traitement des entités nommées²¹⁴. Ce processus permet dès lors un passage à l'échelle : déduire des données non-labellisées à partir d'un modèle préalablement entraîné sur des données labellisées²¹⁵.

L'approche développée dans ce travail s'inscrit précisément dans cette logique de transfert. Parce qu'un modèle pré-entraîné de type BERT repose sur l'acquisition de caractéristiques propres à une langue donnée²¹⁶, il est essentiel de déterminer en amont la langue qui servira de base à l'apprentissage des représentations. À cette fin, une analyse préalable de la distribution linguistique du corpus a été réalisée pour détecter la langue majoritaire dans laquelle s'insère les entités nommées.



FIGURE 4 – Distribution des entités nommées selon la langue du paragraphe et leur type

Si, comme nous l'avons évoqué, le corpus présente déjà une prévalence de l'allemand, la détection du contexte d'apparition des entités révèle une prédominance encore plus

213. VAJJALA *et alii*, *Practical natural language processing*, *op. cit.*, p. 152.

214. HU *et alii*, « Deep learning for named entity recognition », *art. cit.*, p. 9010-9012.

215. EHRMANN *et alii*, « Named Entity Recognition and Classification in Historical Documents », *art. cit.*, p. 5.

216. Notons qu'il existe aujourd'hui des modèles multilingues pré-entraînés à partir de large quantité de données textuelles de différentes langues. Nous ne suivons toutefois pas cette approche dans le cadre de notre recherche.

massive. Pris au niveau du paragraphe où elles se situent, l'analyse du contexte linguistique des entités nommées²¹⁷ indique une prévalence pour l'allemand. Pour cette raison, la variante germanique du modèle BERT a été privilégiée dans le cadre de ce travail²¹⁸. Ce choix, guidé par la réalité empirique des données, n'est cependant pas sans limite. D'une part, 41.25% des paragraphes sont exclus de l'analyse, dans la mesure où ils ne comportent aucune entité nommée. D'autre part, il implique nécessairement que la reconnaissance et la liaison des entités nommées resteront perfectibles et partielle pour les autres langues.

La décision de faire reposer le traitement de nos données sur une architecture neuronale se justifie par la publication en accès libre de ces modèles, ainsi que par les améliorations significatives de leurs performances sur les tâches de reconnaissance et de liaison d'entités nommées modernes. Cette tendance qui s'est également reflétée dans le cas des documents historiques, où il a été soutenu que les représentations générées dans la phase pré-apprentissage permettent de capturer avec finesse les idiosyncrasies du langage historiques, notamment en ce qui concerne les variations orthographiques et l'évolution des conventions de dénomination des entités²¹⁹. Notons toutefois que l'argument de la performance à son revers. Le recours à une telle architecture n'est pas anodin, mais constitue un choix fondamental dans la modélisation des entités nommées, en ce qu'il engage une conception particulière du traitement automatisé de ces dernières. En confiant au modèle la capacité d'ajuster de manière autonome ses représentations en rapport à la tâche à accomplir, cette approche tend à reléguer l'intervention humaine à des phases périphériques - prétraitement et post-traitement - réduisant ainsi la part heuristique et la lisibilité des choix opérés. La phase d'entraînement d'un modèle pour le traitement d'entités nommées cristallise ces enjeux : cette dernière repose sur une constellation de paramètres qui permettent directement d'influencer sur la forme, la cohérence et la granularité des entités, sans que ces effets soient rendus pleinement intelligibles. Si nous adhérons pleinement au propos de Hodel, selon lequel le moment de l'entraînement constitue un point névralgique de la création et de l'optimisation d'un modèle²²⁰, cette centralité s'accompagne d'une perte de contrôle interprétatif. Le modèle ainsi généré n'est au mieux que partiel-

217. Voir la table 11 située en annexes p. 124.

218. DEEPSET, Google-bert/bert-base-german-cased, 07.2025.

219. EHRMANN *et alii*, « Named Entity Recognition and Classification in Historical Documents », *art. cit.*, p. 26-27.

220. HODEL, « Die Maschine und die Geschichtswissenschaft », *art. cit.*, p. 67.

lement compréhensible, sa validation ne pouvant être reporté qu'*a posteriori* par le biais de procédures de test. Dans cette optique, le comportement interne des réseaux neuronaux reste pour l'heure difficilement traçable. D'autre part, les supports d'entraînement sur lesquels reposent ces modèles demeurent insuffisamment documentés, ce qui restreint les possibilités d'une évaluation approfondie²²¹.

Une dernière remarque s'impose au sujet des représentations générées par le système neuronal. Telles qu'esquissées ci-dessus, ces représentations sont conçues à partir du contexte linguistique dans lequel les unités lexicales apparaissent. Elles mobilisent les informations environnantes à différents niveaux de granularité - qu'ils s'agissent des caractères, des mots, des phrases ou du document dans son ensemble. Cependant, ces unités linguistiques ne sont pas traitées en tant que telles par le réseau de neurones : leur traitement suppose, en amont, une conversion en valeurs numériques exploitable par machine. Chaque mot présent dans une séquence devient une série de nombres réels - pour ainsi dire de vecteurs - où chaque valeur reflète une dimension latente de son sens²²². Dans le cas de BERT, une entité se voit alors attribuer 768 valeurs numériques²²³, qui, ensemble, constituent sa modélisation. Si ces dernières ne sont pas interprétables individuellement, elles contribuent collectivement à encoder certains aspects de son usage²²⁴. BERT fonctionne en ce sens comme une interface entre langage naturel d'entrée et langage de sortie, dont la nature de ce dernier reste cependant purement informatique et calculatoire. Si cette représentation vectorielle de mots offre une flexibilité considérable, en particulier dans la capacité des modèles neuronaux à transférer les projections générées vers d'autres tâches, une telle modélisation vectorielle du sens semble problématique d'un point de vue herméneutique ; nous y reviendrons²²⁵.

5.3 Reconnaître et catégoriser les entités d'intérêt dans le texte

En tant que tâches d'étiquetage de séquences textuelles, le traitement des entités nommées nécessite un apprentissage supervisé. Au préalable de toutes opérations algorith-

221. *Ibid.*, p. 74.

222. Lenci Alessandro et Sahlgren Magnus, *Distributional Semantics*, Cambridge University Press, 2023¹, p. 22.

223. Devlin et alii, « BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding », *art. cit.*, p. 4173.

224. Mitkov Ruslan (dir.), *The Oxford Handbook of Computational Linguistics*, Oxford : Oxford University Press, 2022, p. 1290.

225. Voir la section 7.1 p. 89.

miques, il s'agit d'annoter manuellement un corpus de référence sur la base duquel l'entraînement et l'évaluation d'un modèle pour le traitement automatique du langage naturel seront effectués. En ce sens, l'apprentissage supervisé repose sur l'hypothèse de la disponibilité de données annotées de haute qualité. Ici, les documents édités par le centre de recherche apparaissent comme un matériel idéal.

Pour être soumis à un processus de traitement du langage, le texte doit être converti sous forme de structures linéaires, à partir desquelles ils peuvent être segmentés en unités élémentaires²²⁶. Cette transformation implique un nécessaire pré-traitement du texte, déstructurant de la forme originale du texte, désormais réduite à une séquence d'unités lexicales - ou *tokens* -, de signes de ponctuation, de chiffres ou de caractères alphanumériques²²⁷. Cette opération, dite de *tokenisation*, constitue une étape préalable des systèmes de traitement linguistique automatisé²²⁸. Ce processus peut être expliqué à partir d'un court exemple extrait du document `dodis.ch/31459`, soit l'exemple : « la démocratie, c'est la discussion ».




FIGURE 5 – Représentation de la phrase « la démocratie, c'est la discussion » sous la forme de *tokens*

La tokenisation, telle qu'implémentée dans spaCy, se déploie en plusieurs passes : dans un premier temps, une segmentation de la phrase en tokens se réalise sur la base des espaces ; s'ensuit un processus itératif dans lequel le module de tokenisation opère jusqu'à ce qu'aucune exception ne l'interrompe. Ces exceptions résultent de l'application de règles spécifiques de détection de préfixes, de suffixes ou d'infices de l'unité lexicale initiale²²⁹. Appliquée aux documents diplomatiques, la tokenisation s'est heurtée aux

226. EHRMANN *et alii*, « Named Entity Recognition and Classification in Historical Documents », *art. cit.*, p. 5.

227. MITKOV (dir.), *The Oxford handbook of computational linguistics*, *op. cit.*, p. 1286.

228. HUMBEL *et alii*, « Named-entity recognition for early modern textual documents », *art. cit.*

229. SPACY, Linguistic Features · spaCy Usage Documentation.

limites précédemment identifiées en matière de spécificités rédactionnelles : césures héritées de la conversion de format, espaces insécables imposés, ligatures typographiques, distinction fine entre différents types de tirets et d'apostrophes. En pratique, il en résulte des recouvrements lexicaux qui peuvent conduire, selon les cas, soit à une exclusion silencieuse, soit à un blocage complet de l'exécution du processus. Afin de préserver l'intégrité informationnelle des entités, nous adoptons une stratégie de contournement visant, d'une part, à privilégier sur la priorité accordée aux segments d'entités les plus longs, sous l'hypothèse qu'elles contiennent des informations plus complètes, et, d'autre part, à insérer un réglage spécifique dans le but de dissocier les espaces insécables entre entités concaténées.

La modélisation linéaire et séquentielle du texte permet de définir deux sous-tâches interdépendantes : d'une part la reconnaissance des entités nommées, qui consiste à délimiter avec précision le ou les segments textuels correspondant à une unité ; d'autre part, la catégorisation de ces dernières, qui vise à attribuer à chacun de ces segments la catégorie sémantique appropriée. Il s'agit de passer du découpage en segments vers l'examen des unités qui les compose, et ce, à deux niveaux de granularité : les caractères qui composent un token ou les tokens eux-mêmes, concaténés pour former une séquence²³⁰. Cette distinction est opératoire dans la mesure où elle conditionne les types d'indices exploitables - notamment morphologique, lexical ou contextuel - que les systèmes peuvent mobiliser pour détecter les entités nommées. Ici, l'annotation définie dans la TEI est particulièrement opérante à ces deux niveaux. Nous l'avons vu, le standard fournit un ancrage sémantique en spécifiant les personnes, les lieux et les organisations au travers des annotations `persName`, `placeName`, `orgName`, ainsi que leur identifiant dans la base de données. En parallèle, la position de l'entité dans le texte peut être extraite. De cette manière, les fichiers TEI alignent préalablement l'identification de l'entité et son positionnement.

Exemple d'annotations issues de l'encodage TEI

```
<placeName ref="http://dodis.ch/G4">Schweiz</placeName>
<orgName ref="http://dodis.ch/R6">Bundesrat</orgName>
<persName ref="http://dodis.ch/P31966">Adolf Ogi</persName>
```

230. NOUVEL, *Named entities for computational linguistics*, op. cit., p. 78-79.

À l'issue du processus de prétraitement, les fichiers TEI annotés sont convertis en jeux de données exploitables par spaCy. Cette transformation implique leur sérialisation dans le format natif de l'outil : les données y sont binarisées et encapsulées dans deux conteneurs .spaCy, permettant de préserver et réutiliser certaines caractéristiques linguistiques qui leur sont associées pour une exploitation ultérieure. Cette structuration s'inscrit plus concrètement dans une logique standard d'apprentissage supervisé : l'un est destiné à l'apprentissage des données ; l'autre est réservé à la phase d'évaluation. Avant de procéder à la phase d'entraînement à proprement dit²³¹, quelques remarques méthodologiques méritent d'être formulées à l'égard de la constitution des données.

Du fait de leur structuration binaire, l'accès aux contenus encapsulés se voit désormais être médié par l'outil lui-même. Par conséquent, leur inspection suppose l'écriture de scripts de programmation qui s'inscrivent dans l'écosystème technique de spaCy. Dans le but de documenter les principales transformations opérées lors du prétraitement, un export complémentaire au format JSON a été généré avant la mise en conteneur des données, afin d'en interroger l'intégrité, l'exactitude, l'exhaustivité et la cohérence des données ainsi générée. Cette étape vise à atténuer, du moins partiellement, les restrictions d'interprétation imposées par les formats spécifiques aux outils numériques qui tendent à opacifier les opérations de transformation²³². Nous en proposons ci-dessous une illustration des transformations opérées, accompagnée d'une première analyse statistique.

À partir des documents encodés, chaque paragraphe est extrait du document d'origine et débarrassé de ses balises pour en conserver le contenu brut. Les entités annotées sont désormais externalisées du texte sous la forme d'un repérage positionnel - représentés sous la forme d'indices de début et de fin dans la séquence textuelle - et accompagnées de leurs étiquettes de type. De cette manière, les conteneurs .spaCy attestent d'une structure de données particulières, conçue pour organiser et contenir les annotations linguistiques. L'outil opère par déconstruction du schéma TEI pour en extraire uniquement le langage naturel, réduit à des indications positionnelles et

231. Voir la section 6 p. 73.

232. FICKERS Andreas, « Authenticity : Historical Data Integrity and the Layered Materiality of Digital Objects », in BALBI Gabriele *et alii* (dir.), *Digital Roots*, De Gruyter, 2021, p. 306. DOBSON James, « Interpretable Outputs : Criteria for Machine Learning in the Humanities. », *DHQ : Digital Humanities Quarterly*, vol. 15, n° 2, 2021.

TEI-HTML annoté	JSON extrait
<pre> <h1 class="tei-title4 tei-title-sub"> Offizieller Arbeitsbesuch in der Schweiz des ungarischen Präsidenten Arpad Göncz am 30. April 1991 </h1> </pre>	<pre> [["Offizieller Arbeitsbesuch in der Schweiz des ungarischen Pr\u00e4sidenten Arpad G\u00f6ncz am 30. April 1991" [[45, 56, "LOC", "https://dodis.ch/G20"], [69, 80, "PER", "https://dodis.ch/P59122"], [33, 40, "LOC", "https://dodis.ch/G4"]]]] </pre>

FIGURE 6 – Extrait du document `dodis.ch/57905` : comparaison entre le balisage TEI-HTML et le fichier JSON prétraité

catégorielles. En ce sens, le processus impose une mise à plat du balisage initialement imposé par l’encodage TEI au profit d’une modélisation orientée vers l’optimisation du traitement automatique du langage. La décomposition du texte-source va plus loin : segmentés en paragraphe et distribué entre les jeux d’apprentissage et de validation, le contenu initial est déstructuré et l’intégrité documentaire de l’objet éditoriale n’est plus considérée. Ainsi, le passage d’un encodage riche et structuré à une représentation normalisée et orientée vers la performance algorithmique illustre la manière dont les contraintes du TALN redéfinissent les contours du document éditorial. Sa cohérence est dissoute au profit d’un formatage fonctionnel destiné à l’apprentissage machine.

Outre les reconfigurations structurelles exposées ci-dessus, une évaluation quantitative des opérations de prétraitement s’impose afin d’en apprécier la capacité à minimiser la perte d’information. Si la structuration élevée des fichiers TEI offre un cadre propice à une extraction ciblée des entités nommées, elle ne garantit pas une capture exhaustive de leurs occurrences. Plus concrètement, il s’agit d’évaluer ce que le prétraitement a conservé ou exclu des fichiers initiaux et de mesurer les effets de cette sélection sur la représentativité du corpus.

Nombre d'entités distinctes par type			Nombre total de mentions par type		
Type	HTML	JSON	Type	HTML	JSON
PER	5 641	5 641	PER	34 577	34 278
ORG	982	980	ORG	11 279	11 099
LOC	1 907	1 907	LOC	72 078	71 280
Total	8 530	8 528	Total	117 934	116 657

FIGURE 7 – Évolution du nombre d'entités nommées uniques et de leur mentions par catégorie entre les fichiers HTML initiaux et le corpus prétraité au format JSON

La comparaison des fichiers HTML d'origine et JSON issu du prétraitement reflète une stabilité notable de repérage des entités uniques : le nombre d'entités référencées par catégorie reste globalement constant. Notons toutefois que deux entités organisationnelles n'ont pu être retenues dans la version finale, ce qui a pour conséquence d'être exclues d'emblée de toute la chaîne d'annotation, et, *a fortiori*, de tout traitement ultérieur. En revanche, la perte la plus significative se situe du côté du nombre total de mentions retenus. En rapport aux données initiales, ce sont 1 277 mentions qui ne sont pas conservées dans le corpus pré-traité. Ainsi, même si une entité est bien conservée dans le répertoire des entités uniques, la diversité des contextes dans laquelle elle apparaît sous une forme lexicale variable tend à être réduite. Il convient en outre de souligner que l'exclusion des mentions n'affecte pas uniformément les catégories. En effet, les entités toponymiques semblent particulièrement affectées par le prétraitement : sa catégorie représente plus de 60% de la baisse totale observée.

En définitive, le prétraitement n'a rien de trivial : il dépasse la simple opération de filtrage en agissant directement sur la matière textuelle. La structure documentaire initiale se voit être reconfigurée et décomposée, tout en excluant, parfois discrètement, certaines mentions qui, à terme, circonscrivent les contours du corpus qui sera soumis à la phase d'entraînement. Par conséquent, tout prétraitement implique des arbitrages méthodologiques - qu'il s'agisse de la résolution des chevauchements, du découpage de certaines entités concaténées ou encore d'éventuels échec d'alignement - ont les effets sont mesurables sur la diversité contextuelle des entités nommées conservées.

5.4 Réconcilier les ambivalences pour enrichir le texte

Reconnaître des entités dans un texte ne suffit pas à établir une correspondance avec une personne, un lieu ou une organisation existants dans le monde réel. En effet, les entités identifiées et catégorisées restent des formes linguistiques de surface, ou, pour le dire autrement, des segments textuels, dont la signification est explicite uniquement au niveau de la langue ²³³. À cette fin, il s'agit d'« [...] affecter automatiquement la bonne référence, l'identifiant de la ressource correspondante dans une base de connaissances [...] à une entité nommée préalablement identifiée dans un texte et étiquetée » ²³⁴. En d'autres termes, la procédure vise à déterminer l'appariement le plus probable entre les mentions de textes issues du corpus et les entités candidates référencées dans la base de connaissance. Dans ce travail, nous suivons Nouvel *et alii.* qui identifient les bases de connaissances comme « [...] des listes d'unités référentielles, accompagnées d'informations qui leur sont associées, en particulier des chaînes de texte pouvant constituer des mentions » ²³⁵. La relation entre un ensemble de mentions et un ensemble de références peut être examinée formellement d'un point de vue général.




FIGURE 8 – Entités dans un texte et références provenant d'une base de connaissances, basé ici sur l'indexation de Dodis

233. MCGILLIVRAY Barbara, « Computational Methods for Semantic Analysis of Historical Texts », in, Routledge, 2020.

234. ABADIE Nathalie *et alii.*, « Evaluation de la qualité des sources du Web de Données pour la résolution d'entités nommées », *Revue des Sciences et Technologies de l'Information - Série ISI : Ingénierie des Systèmes d'Information*, vol. 21, n° 5-6, 2017, p. 32.

235. NOUVEL, *Named entities for computational linguistics*, op. cit., p. 100. trad.

Comme suggéré ci-dessus, le processus de liaison d'une entité à un identifiant unique s'accompagne d'une génération de candidats potentiels, indépendamment de sa catégorisation préalable. La sélection des candidats apparaît en ce sens comme une tâche indépendante, dissociée de la tâche de reconnaissance. À la différence de la tâche de reconnaissance et de catégorisation, la tâche de liaison exige un degré de souplesse méthodologique supérieur : il s'agit de résoudre l'ambiguïté inhérente au contenu textuel, de tenir compte de la variabilité contextuelle et de gérer les cas limites. À cette fin, les entités nommées doivent être dotées d'informations afin d'être appariées à un référent identifié.

À cette fin, la tâche de liaison des entités est abordée selon deux paradigmes principaux, à savoir les méthodes basées sur des graphes et celles basées sur la similarité contextuelle²³⁶. Bien que ces stratégies partagent le même objectif — à savoir lever l'ambiguïté des entités — elles mobilisent des principes algorithmiques distincts : l'une capitalise sur la cohérence structurale d'un graphe, l'autre sur la proximité distributionnelle captée par les modèles de langage. L'existence de ces deux approches a mené à des investigations particulières dans le cadre de ce travail. Les premières exploitent directement la topologie d'un graphe de connaissance, où les entités et leur relation sont représentées sous forme de nœuds et d'arêtes. D'un point de vue opérationnel, les approches basées sur les graphes mobilisent tout particulièrement les données ouvertes liées (ou *linked open data*) conçues pour rendre l'information contenue dans les données réutilisables à grande échelle²³⁷. Diffusées sous forme de triplets (sujet, prédicat, objet), ces données reposent sur des identifiants uniques, reconnus au moyen d'URI, et sur des ontologies, une sémantique formalisée et partagées qui en explicite le sens. Parce qu'elles s'appuient une structure normalisée et interopérable, ces données offrent un socle formel permettant la mise en réseau de différents gisements d'informations dispersés relatif à une même entité, dans le but de fusionner les liens d'équivalence et ainsi enrichir sa représentation²³⁸. L'agrégation des triplets forme ainsi un graphe de connaissances : chaque nœud, *ou* entité, se trouve reliée à d'autres nœuds issus de sources web distincte, de manière à corréler une entité équivalente au

236. ARMASELU Florentina *et alii*, « LL(O)D and NLP perspectives on semantic change for humanities research », *Semantic Web*, vol. 13, n° 6, 2022, p. 1064.

237. BRANDO Carmen *et alii*, « REDEN : Named Entity Linking in Digital Literary Editions Using Linked Data Sets », *Complex Systems Informatics and Modeling Quarterly*, n° 7, 2016, p. 60-80.

238. BERETTA Francesco, « Données ouvertes liées et recherche historique : un changement de paradigme », *Humanités numériques*, n° 7, 2023.

sein de différents contextes informationnels ²³⁹.

Bien que ces approches aient suscitées un intérêt marqué durant ces dernières années ²⁴⁰, leur apport demeure limité dans le cadre du notre travail. En pratique, la récupération des identifiants qui relient les entités de notre corpus à d'autres ressources ²⁴¹ s'avère peu exhaustive. Or, le critère de couverture est central pour désambiguïser et apparier correctement chaque entité à une référence stable ²⁴². La sélection des candidats reste donc restreinte, car la qualité des ressources Web associées aux identifiants Dodis est encore parcellaire, et ce, malgré la contribution apportée par le projet Metagrid à la mise en relation de ressources de données.

Type	Total	lien(s) d'équivalence (≥1)	% Couverture
LOC	1905	1296	68.0%
PER	5638	2934	52.0%
ORG	958	287	29.9%
Total	8501	4517	53.1%

TABLE 4 – Résumé des entités nommées totales dédoublées, disposant d'au moins un lien d'équivalence à des ressources externes

Le fait que seules environ 50% des entités disposent d'une référence externe dans le système d'indexation Dodis introduit un biais structurel : il en résulte un déséquilibre dans la structuration de données relatives aux entités, certaines bénéficiant d'un enrichissement informationnel plus complet que d'autres. Soulignons par ailleurs que le rattachement d'une entité à une référence identifiable n'induit pas systématiquement une valeur de validité ; elle peut également résulter d'un appariement à une référence erronée, notamment en raison de la présence d'homonymes fréquents ²⁴³. Établir des liens entre une ou plusieurs mentions d'entités nommées et une référence individuelle et unique provenant d'une base de connaissance externe reste donc un exercice com-

239. SCHWEIZERISCHE FÜR GESCHICHTE *et alii*, « Datenstandards für die historische Forschung – Ein White-Paper der Schweizerischen Gesellschaft für Geschichte », 2023, p. 19.

240. Voir en particulier MEROÑO-PEÑUELA *et alii*, « Semantic technologies for historical research », *art. cit.* Notons par ailleurs que le groupe de travail « Pérennisation des données » du Département « Recherche fondamentale » de la Société suisse d'histoire (SSH) a souligné la plus-value du des données liées : « Le Linked Open Data permet la mise en réseau avec des données déjà existantes et se trouvant ailleurs, autorisant ainsi l'utilisation d'un savoir déjà constitué. » SCHWEIZERISCHE FÜR GESCHICHTE *et alii*, « Datenstandards für die historische Forschung – Ein White-Paper der Schweizerischen Gesellschaft für Geschichte », *art. cit.*, p. 19.

241. Les bases de données et référentiels externes mobilisés dans le cadre de notre investigation sont les suivantes : Wikidata, DHS, Lonsea, GND, Elites Suisses, Helveticat, VIAF, Huygens, BHS, La bibliothèque de l'ETH, parl.ch, Geonames et TGN. Pour une consultation de ces derniers, nous renvoyons au site Metagrid : <https://metagrid.ch/>

242. BRANDO *et alii*, « REDEN », *art. cit.*

243. NOUVEL, *Named entities for computational linguistics*, *op. cit.*

plexe en raison des limites d'interopérabilité imposées aux données historiques.

Pour ces raisons, nous avons opté pour la seconde approche identifiée par Armaseu *et alii.*, à savoir celle de la similarité contextuelle. Il s'agit de comparer les représentations textuelles des mentions pour identifier l'entité correcte²⁴⁴. Parce ce qu'un accès élargi aux bases de connaissances externes s'avère pour l'heure insatisfaisant, notre travail méthodologique s'est exclusivement fondé sur les annotations présentes dans le corpus - désormais sous la forme de conteneur .spaCy - dans lequel chaque mention est préalablement associée à un identifiant référencé dans l'indexation de Dodis. Afin de générer une liste de candidats potentiels, nous recensons, pour chaque mention identifiée, l'ensemble des identifiants qui lui ont été associés au cours de l'annotation en enregistrant systématiquement la fréquence d'appariement de chaque couple alias*-entité. Ce procédé permet de constituer une liste restreinte d'entités candidates, basée sur la proportion de chaque entité parmi les associations possibles pour la mention considérée.

La phase de désambiguïsation exploite cette liste de candidats pour affiner la sélection de l'entité cible la plus probable. Elle est complétée par des caractéristiques du contexte d'apparition obtenues automatiquement à l'aide d'un modèle BERT. Les phrases intégrant les mentions sont ici considérées comme contexte : ces dernières sont converties en vecteurs à l'aide du modèle BERT, puis moyennées, de sorte à obtenir une représentation numérique stable qui caractérise l'entité. Pour le dire autrement, il s'agit de doter chaque entité d'une signature exploitable par le modèle pour effectuer l'opération de désambiguïsation. En ce sens, la base de connaissance constitue l'inventaire empirique des formes attestées du corpus, intégrant ainsi les variations orthographiques et la collection de phrases typiques par entités. Ce faisant, lors de l'inférence, la base de connaissance s'appuie sur des scores de priorité pour chaque couple alias-entité et sur la moyenne des vecteurs associés. En somme, notre approche vise à combiner la collecte de variantes des entités, leur représentation vectorielle des contextes ainsi qu'une indexation probabiliste : la base formalise un « index » où chaque entité est représentée par ses formes, sa fréquence et un profil sémantique moyen.

À ce stade, quelques remarques méritent d'être faites. En premier lieu, la base de

244. ARMASELU *et alii.*, « LL(O)D and NLP perspectives on semantic change for humanities research », *art. cit.*, p. 1064.

connaissance reflète uniquement le périmètre du matériel de départ. En effet, notre méthode ancre la génération des candidats dans les relations attestées entre mention et entité. De cette manière, l’enrichissement sémantique se voit être restreint au cadre fermé de l’indexation produite par Dodis. Toute nouvelle mention inconnue ou entité absente ne pourra ainsi être désambiguïsée. Si une telle approche convient à l’effectuation de la tâche dans le cadre précis de notre étude, elle suggère toutefois un profond manque d’interopérabilité et de portabilité, notamment en raison l’inaccessibilité à des ressources informationnelles externes. Par ailleurs, les opérations effectuées pour la génération de la base de connaissance peuvent s’avérer faillibles, et ce, à différents niveaux. En privilégiant des probabilités basées sur la fréquence brute, nous tendons à favoriser les entités davantage documentées au détriment des entités rarissimes. En moyennant les contextes, nous stabilisons les résultats, mais nous gommons des nuances : une entité polyvalente risque d’obtenir un vecteur *tiède*, ce qui la rend moins distinguable de ses réels contextes où elle apparaît. Plus encore, les représentations de contextes reposent uniquement sur le contenu linguistique du corpus et non pas sur sa composante diachronique. À présent, la prise en compte de l’enchevêtrement des références temporelles et *a fortiori* le contexte historique où elles apparaissent constitue l’un des principaux défis en TALN²⁴⁵. La capacité à prendre en considération l’évolution des dénominations au fil du temps et leurs significations subséquentes, qu’il s’agisse d’une seule et même entité ou d’entités distinctes, reste pour l’heure un enjeu central auquel nous n’avons pas su répondre.

245. LINHARES PONTES Elvys *et alii*, « Entity Linking for Historical Documents : Challenges and Solutions », in ISHITA EMI *et alii* (dir.), *Digital Libraries at Times of Massive Societal Transition*, Cham : Springer International Publishing, 2020, vol. 12504, p. 216.

6 Observer les effets d'un traitement automatique

Qu'il s'agisse de reconnaître des entités ou de les lier à des référentiels externes, un algorithme d'apprentissage vise directement l'objectif de prédiction qui implique une logique d'évaluation fondée sur la comparaison entre les prédictions de modèle et les sorties attendues²⁴⁶. Le jeu de données est usuellement divisé en deux ensembles : le premier transmis à l'algorithme pour en apprendre les caractéristiques à partir des données étiquetées ; le second correspond à l'ensemble de test, qui contient l'échantillon que l'algorithme n'observera pas avant l'évaluation. La prédiction se trouve être une déclaration concernant des données inédites du modèle, c'est-à-dire celles qui n'ont pas été utilisées pour former le modèle.

Adoptant une démarche à la fois empirique et réflexive, ce chapitre propose une lecture croisée - distanciée et rapprochée - afin de juger de la fiabilité des résultats issus d'un traitement automatique. Dans un premier temps, nous présentons d'abord les résultats de reconnaissance et de liaison d'entités nommées à l'aune du cadre d'évaluation classique du TALN. Eu égard aux limites qu'une telle grille de lecture laisse subsister, nous confrontons, dans un second temps, les prédictions du modèle aux annotations éditoriales dans le but de fournir une lecture qualitative plus fine. Nous concluons sur une réflexion élargie, confrontant les exigences méthodologiques propres aux champs de recherche mobilisés dans le cadre de ce mémoire.

6.1 Évaluer un modèle à partir de ses métriques

Dans le domaine du TALN, la logique d'évaluation de résultats prend la forme de métriques standardisées. La génération de ces dernières repose sur les catégories issues de la matrice de confusion. Il s'agit d'y distinguer les cas de correspondance ou de divergences entre les annotations prédites par le modèle et celles issues de l'annotation de référence. La matrice de confusion distingue ainsi quatre catégories fondamentales. Le vrai positif désigne l'entité correctement reconnue par le modèle, c'est-à-dire présente à la fois dans la prédiction et dans l'annotation de référence. Le faux positif correspond à l'entité identifiée par le modèle, mais absente de l'annotation. Le vrai négatif reflète la capacité du modèle à attribuer à tort une entité à un segment textuel

246. UNDERWOOD Ted, « Algorithmic Modeling : Or, Modeling Data We Do Not Yet Understand », in FLANDERS Julia et FOTIS JANNIDIS (dir.), *The shape of data in the digital humanities*, London : Routledge, 2019, p. 251.

qui n'en contient pas. Enfin, le faux négatif présente l'entité annotée dans le standard de référence, mais reste non identifié par le modèle ²⁴⁷.

		Annotation prédite	
		Positif	Négatif
Annotation de référence	Positif	Vrai positif (<i>vp</i>)	Faux négatif (<i>fn</i>)
	Négatif	Faux positif (<i>fp</i>)	Vrai négatif (<i>vn</i>)

TABLE 5 – Matrice de confusion

À partir de cette matrice, nous pouvons définir les trois métriques de base utilisées par l'évaluation des performances d'un modèle, qu'il s'agisse de la reconnaissance ou de la liaison d'entités nommées, à savoir la précision, le rappel et le F1-Score. Pour la tâche de reconnaissance, la précision représente la proportion d'entités nommées correctement identifiées parmi l'ensemble des entités reconnues par le modèle. Quant au rappel, il correspond à la proportion d'entités annotées dans le standard de référence qui ont été correctement reconnues par le modèle. Quant au F1-Score, il fournit la mesure synthétique de performance, en combinant les mesures de précision et de rappel sous la forme d'une moyenne harmonique. Ces mesures d'évaluation varient entre 0 et 1 : une valeur proche de 1 indique que le modèle parvient à reconnaître correctement les données annotées du jeu de validation, c'est-à-dire qu'il génère principalement des vrais positifs. ²⁴⁸. Pour ce qui est de la tâche de liaison, la précision correspond à la fraction d'entités correctement liées parmi celles générées par le système : l'évaluation considère toutes les mentions d'entités liées par le système et détermine dans quelle mesure ces liens sont corrects. Le rappel prend en compte toutes les mentions d'entités devant être liées et évalue dans quelle mesure le système a correctement établi ces liens ²⁴⁹. La mesure synthétique du F1-Score est générée de manière analogue à celle de la tâche de reconnaissance des entités nommées. Alors que les métriques sont calculées pour chaque type d'entités dans le cas de la reconnaissance et la catégorisation d'entités nommées, celles fournies par la liaison donne une mesure unique, dans la mesure où l'évaluation porte sur la capacité du modèle à relier correctement les mentions, indépendamment de leur catégorie.

247. MUNNANGI, A Brief History of Named Entity Recognition, *cit.*

248. WETTLAUER, « Methoden der Digital History/Digitalen Geschichtswissenschaft », *art. cit.*, p. 9.

249. SHEN Wei *et alii*, « Entity Linking with a Knowledge Base : Issues, Techniques, and Solutions », *IEEE Transactions on Knowledge and Data Engineering*, vol. 27, n° 2, 2015, p. 458-459.

Précision	$P = \frac{vp}{vp + fp}$
Rappel	$R = \frac{vp}{vp + fn}$
F1-Score	$F = 2 * \frac{P * R}{P + R}$

TABLE 6 – Mesures d’évaluation classiques pour la classification binaire


Ces considérations posées, l’évaluation d’un modèle à travers ses seules métriques circonscrit les possibilités interprétatives, en cantonnant l’analyse à une posture d’observateur. Les mesures de sortie produites par le modèle entraîné aux tâches de catégorisation traduit cet état de fait.

Type d’entité	Précision	Rappel	F1-score
LOC	0.882	0.932	0.906
PER	0.849	0.892	0.870
ORG	0.896	0.701	0.786


TABLE 7 – Scores des tâches de reconnaissance et de catégorisation d’entités par type

À partir de la table 7, nous pouvons observer que le modèle atteint une bonne tenue globale. Un score très élevé pour les lieux se complète par un équilibre correct pour les personnes. En comparaison avec ces types, les métriques du modèle donne à voir performance inférieure observée pour la catégorie organisation. Ce constat s’explique en majeure partie par la présence d’un rappel plus faible. En se concentrant sur les entités annotées dans le standard de référence, mais non reconnues par le modèle, le rappel se révèle particulièrement sensible aux faux négatifs.


La faiblesse observée dans la détection des entités organisationnelles semble être structurellement liée aux caractéristiques intrinsèques du corpus. Cet argument peut être éclairé à travers une analyse statistique des jeux d’entraînement - *train* dans la figure - et d’évaluation - *dev* dans la figure - sur lesquels reposent l’apprentissage et la validation du modèle. La figure 9 permet d’en tirer les constats suivants. D’une part, il est significatif d’observer que les entités de type ORG sont nettement moins représentées dans les données d’apprentissage que les autres catégories : tandis que le corpus cumule 7 879 occurrences d’organisation dans le jeu d’entraînement, contre 23 736 pour les personnes et 49 633 pour les lieux. Ce déséquilibre se voit être accen-




(a) Occurrences par type d'entité



(b) Entités uniques par type



(c) Taux de recouvrement *train/dev*



(d) Proportion d'entités uniques

FIGURE 9 – Statistiques comparatives des entités nommées selon (a) les occurrences par type d'entité, (b) le nombre d'entités uniques, (c) le taux de recouvrement entre jeux d'entraînement (*train*) et de validation (*dev*), (d) la proportion d'entités n'apparaissant qu'une seule fois.

tué par la diversité moindre des ces entités organisationnelles, qui restent nettement inférieurs aux autres catégories. De cette manière, la capacité du modèle à capitaliser sur des occurrences multiples se voit être largement réduite.

D'autre part, nous retrouvons un faible taux de recouvrement entre les jeux d'entraînement et de validations pour la catégorie ORG : seules 47% des entités présentes dans le jeu de validation sont également recensées dans le jeu d'entraînement. À titre de comparaison, cette proportion s'élève à 58% pour les entités de type PER et 59% pour celles de type LOC. Autrement dit, la probabilité pour le modèle de rencontrer à la phase d'évaluation une organisation qu'il a déjà aperçue lors de son entraînement est réduite. Un faible taux de recouvrement implique par la même occasion que les vrais positifs seront mécaniquement plus rares, faute de redondance entre les jeux de données : la détection d'entités correctement détectée baisse et fait parallèlement augmenter la fréquence des entités manquées. Cette dynamique se voit accentuer par la forte proportion d'entités uniques dans l'ensemble du corpus : 68% des entités ORG n'apparaissent qu'une seule fois, tandis qu'elles représentent respectivement 56% et 60% pour les catégories de type PER et LOC.

Pris ensemble, ces facteurs semblent interagir négativement, ce qui se traduit par une chute du rappel des entités organisationnelles, et, par extension, dans la baisse de son F1-Score. En cela, nous pourrions admettre que c'est la sous-représentation des organisations dans les données d'entraînement, de même que leur diversité et leur rareté qui rend délicate la généralisation du modèle à reconnaître ce type d'entité. De manière opposée, les entités de type PER et LOC bénéficient d'un volume d'apprentissage plus important et d'une plus grande régularité linguistique, ce qui en améliore leur reconnaissance. Il semble que la faiblesse du modèle soit indissociable de la ressource - du corpus annoté - qui lui est fournie.

Quant aux résultats de la liaison, le modèle laisse percevoir une performance modérée mais significative : les entités correctement liées sont majoritairement fiables, mais la couverture du corpus reste partielle.

Mesure	Précision	Rappel	F1-Score
Liaison d'entités	0.755	0.624	0.684

TABLE 8 – Scores pour la tâche de liaison des entités nommées

Toutefois, nous pourrions formuler l’hypothèse que la nature même du contenu joue un rôle déterminant dans ces résultats : une large majorité de des entités mentionnées n’apparaissent qu’une seule, ce qui permet leur intégration dans la base de connaissance avec une priorité maximale, sans nécessiter de processus de désambiguïsation. Dans ce contexte, ce sont principalement les 736 cas d’homonymie qui semblent constituer la source majeure de l’ambiguïté.

Type de mention	Nombre d’entités
Unicité par identifiant	10 169
Partage inter-identifiants	736
<i>Total des URIs (avec doublons)</i>	<i>2 005</i>
<i>Total des URIs uniques</i>	<i>1 794</i>

TABLE 9 – Résumé des entités par URI

En somme, un cadrage sur les métriques standards d’évaluation produit une vue partielle et lissée de la performance, en la réduisant à des valeurs numériques. En effet, chaque métrique isole une dimension de la performance du modèle : la mesure de précision ignore les faux négatifs, le rappel néglige les faux positifs, tandis le F1-Score combine les deux précédentes métriques tout en ignorant les vrais négatifs. En faisant dépendre sa mesure des deux résultats précédents, la valeur d’indice synthétique du F1-Score ne reflète ni une probabilité ni une fréquence observable. Par conséquent, un score élevé peut occulter des biais structurels. D’autre part, et c’est là un enjeu essentiel, ces métriques ignorent la nature des erreurs : ces dernières sont traitées de manière équivalente, ce qui rend toutes démarches interprétatives limitées à ce niveau de généralité²⁵⁰. Ainsi, ces scores ne nous renseignent ni sur l’utilité effective, ni sur la signification des prédictions produites.

Cette réduction place cependant l’historien-ne, et plus généralement les disciplines humanistes dans une position interprétative opposée²⁵¹ : en imposant un cadre évaluatif fondé sur des scores probabiliste, les résultats des modèles de reconnaissance et de liaison d’entités nommées ne donne que peu de prise à une démarche herméneutique. Pour dépasser cette impasse, il s’agit de revenir à une échelle d’analyse plus fine, capable de réintroduire l’exigence de réflexivité. Les métriques, dans cette perspec-

250. BLAGEC Kathrin *et alii*, A critical analysis of metrics used for measuring progress in artificial intelligence, arXiv, 2020.

251. DOBSON, « Interpretable Outputs », *art. cit.*

tive, demande moins à être considérés comme des affirmations absolues que comme des instruments heuristiques guidant l'analyse future. Le fait que le modèle donne une première indication de la difficulté à identifier les organisations a guidé la suite de nos analyses sur cette catégorie précise.

6.2 Tension entre prédiction et modèle éditorial : étude de cas à partir des entités organisationnelles

Si différentes approches coexistent aujourd'hui sur la manière de procéder à une lecture qualitative de modèles entraînés²⁵², nous suivons la proposition d'Underwood selon laquelle la dimension interprétative peut se discerner dans les prédictions qu'ils fournissent à partir de cas individuels²⁵³. Plus spécifiquement, nous adoptons l'approche proposée par Rettberg qui propose d'aborder « l'échec algorithmique » (*algorithm failure*) comme une porte d'entrée à une analyse interprétative. Suivant son propos, il s'agit de « prendre en considération les erreurs de prédiction [...] pour identifier des cas dignes d'intérêt pour la recherche qualitative »²⁵⁴. Dans cette optique, nous fournissons une analyse interprétative de la prédiction de faux positifs pour souligner les discordances locales entre annotation humaine et sortie du modèle. Par conséquent, il est davantage question de documenter la projection proposée par le modèle que d'en déterminer son fonctionnement sous-jacent. Le cas des faux positifs prend une portée particulière dans le cas des fonctionnalités de visualisation offertes par spaCy. L'interface graphique proposée par l'outil tend à faire disparaître les erreurs de prédiction, notamment les faux positifs, dans la mesure où le modèle considère ces résultats comme corrects. Cette dimension performative naturalise les sorties du système, au point d'en inhiber toute remise en question. C'est pourquoi nous optons pour une visualisation alternative, développée spécifiquement dans le cadre de notre approche.

Partant de l'observation selon laquelle le modèle peine à reconnaître les formes de surfaces liées aux entités organisationnelles, nous avons filtré toutes les phrases ou paragraphes qui disposent d'au moins une organisation annotée. À partir de cet ensemble limité, les entités étiquetées dans le corpus original sont comparées aux pré-

252. Voir en particulier DOBSON, « On reading and interpreting black box deep neural networks », *art. cit.*

253. UNDERWOOD, « The shape of data in the digital humanities », *art. cit.*, p. 256.

254. RETTBERG Jill Walker, « Algorithmic failure as a humanities methodology : Machine learning's mis-predictions identify rich cases for qualitative analysis », *Big Data & Society*, vol. 9, n° 2, 2022, p. 1. *trad.*

dictions générées par les modèles de reconnaissance et de liaison. Chaque faux positif est normalisé pour regrouper les formes et comptabilisés les familles d'erreurs. Les contextes d'apparition et les identifiants sont stockés afin d'en analyser la fréquence, la diversité et les cas d'homonymie. Enfin, les phrases disposant de plusieurs faux positifs sont extraites, fournissant la base concrète à l'analyse critique. À l'issue de ce traitement, trois cas d'erreur se sont révélés sur lesquels nous revenons, à savoir la segmentation automatisée des acronymes administratif, la confusion entre entités nommées et événementialité, et la hiérarchie emboîtée des entités organisationnelles.

Les acronymes administratifs et l'enchaînement de sigles, caractéristiques de la production documentaire de l'administration fédérale, représente un premier cas limite. En effet, l'extraction automatisée tend à segmenter systématiquement toutes les abréviations en générant artificiellement des entités organisationnelles inexistantes, reflétant le texte et non pas la structure réelle des entités. Un cas particulièrement emblématique est la présence, au sein d'un court extrait, d'une forte densité institutionnelle : les réunions de différents offices fédéraux, qui explicitent, en fin de document, la participation et le vote de ces derniers, représentent un exemple particulièrement illustratif.

Phrase annotée issue de la prédiction du modèle :

An der Sitzung des IKEH vom 9.11.1990, welche die oben erläuterten Prioritätensetzungen und organisatorischen Vorkehren traf, nahmen folgende Bundesämter teil : die **DEH**, die **DIO**, die **DV** (alle **EDA**), das **BUWAL** (**EDI**), das **BAWI** (**EVD**), das **BEW** (**EVED**), das **BAGE** (**EJPD**) sowie die **EFV** (**EFD**). Das **BEW** (**EVED**), das **BAGE** (**EJPD**), das **EPA** (**EFD**) sowie die **EFV** (**EFD**) wurden zum vorliegenden Antrag konsultiert. Die erwähnten Ämter sind mit dem Antrag einverstanden.

Légende :

- **Rouge** : Entité reconnue considérée comme un faux positif, quelle que soit la liaison.
- **Rouge souligné** : Entité reconnue et associée à une entité de la base de connaissances, mais cette liaison est incorrecte.
- **~~Rouge barré~~** : Entité reconnue, mais pour laquelle aucune liaison correcte n'a été trouvée.

Le découpage linéaire ignore l'emboîtement des acronymes, ne distinguant pas une entité de premier niveau et un rattachement administratif. Ce comportement algorithmique produit ainsi une représentation éclatée de la réalité documentaire, créant une mosaïque d'entités qui n'ont de réalité que textuelle et ignorant la structure réelle d'appartenance des entités. Le découpage granulaire semble bien illustrer la tension entre *ce qui est extrait* de *ce qui fait sens* pour le centre de recherche. En multipliant les entités là où l'indexation exige une entrée unique et normalisée, l'automatisation compromet l'interopérabilité et la cohérence du corpus.

Un autre biais apparaît dans la confusion opérée entre entités nommées au sens strict - dans notre cas la catégorie organisation - et des objets discursifs relevant de la dynamique événementielle. La frontière, certes poreuse, qui sépare la mention d'une organisation de celle d'un processus est fréquemment franchie sans discernement par le modèle. L'énoncé d'une stratégie politique ou la description d'un processus de négociation constitue un exemple éclairant ce sujet.

Phrase annotée issue de la prédiction du modèle :

Dem Bundesrat schweben verschiedene Möglichkeiten vor : 1) Unterzeichnung mit gleichzeitigem Beitritts-gesuch, 2) Einschluss einer Beitrittsklausel im EWR-Vertrag, 3) Verzicht auf EWR und direktes Anpeilen der EG-Mitgliedschaft. Die letzte Variante sei insofern gefährlich, als die Verhandlungen wieder ganz von vorne beginnen und als die Bevölkerung nach den schlechten Erfahrungen mit den EWR-Verhandlungen einer Integration skeptisch gegenüberstehe.

Ici, le modèle assimile de manière indifférente toutes les formes nominales. Cette indistinction tend ici à produire du bruit : un événement, à l'instar de l'« adhésion à la Communauté économique européenne », du « traité sur l'Espace économique européen », ou des « négociations sur l'Espace économique européen », est traité comme une entité stable alors qu'il s'agit d'une séquence d'actions évolutives, dont la référence n'est ni univoque ni stable dans le temps. La présence de suffixe dans ces expressions fournit au système un signal formel trompeur, conduisant à un référencement unique d'objets discursifs distincts qui s'ancrent en réalité dans des temporalités successives. L'extraction de telles entités a ainsi pour effet de diluer les organisations à proprement dit, créant une confusion entre entités et dimension événementielle. Plus fondamentalement, cette dérive souligne le caractère incertain et contextuel de la frontière entre entités organisationnelle et son expression dans le discours politique.

Les organisations internationales, leurs sous-structures ou fonctions liées représentent un défi supplémentaire. Aveugle à la dimension hiérarchique des institutions, de même qu'à la présence de cooccurrence, le modèle segmente sans rapporter les extractions produites à l'arborescence de l'indexation.

Phrase annotée issue de la prédiction du modèle :

B[outros-Ghali] erwiderte darauf, dass der grösste Finanzdruck für das UNO-System vom enormen Aufschwung der friedenssichernden Aktivitäten der Organisation ausgehe. [...] So seien etwa UNDP-Büros in den baltischen und GUS-Republiken einzurichten, ohne dass dies aber der Diversion von Entwicklungshilfe nach Osten Vorschub leisten solle.

Les institutions internationales sont rapportées sans reconnaissance de leur dépendance mutuelle à l'instar des Nations unies et de la mention « Organisation ». Plus encore, le « Programme pour le développement », instance intégrée à l'organisation, renvoie une erreur de référencement. Faisons remarquer que le dispositif d'indexation des organisations mis œuvre par Dodis repose précisément sur un principe d'abstraction qui se concrétise dans une structuration hiérarchique. Organisée en plusieurs niveaux emboîtés, cette approche assure la cohérence et l'uniformité du référentiel, tout en tenant compte de la réalité évolutive des infrastructures diplomatiques. La compression des hiérarchies exigées par la base de données dans le texte dénote des limites actuelles du modèle. Cette hiérarchie ne se manifeste pas à la surface du texte : le corpus ne donne à voir qu'une unité lexicale « aplatie » de l'organisation, sans indication explicite de sa position dans la structure administrative. Réduit à des formes linguistiques brutes, il peine à opérer une liaison précise avec la représentation hiérarchisée retenue par le projet éditorial. Autrement dit, lorsque la simple dénomination ne suffit pas, l'abstraction requise pour identifier l'ancrage organisationnel dépasse son champ de compétence. La capacité du modèle se restreint à sa capacité à cerner une dénomination dans son contexte d'usage immédiat. Plus frontalement, il questionne sur la capacité d'un modèle à capter la granularité et la hiérarchie souhaitée par le centre de recherche.

La génération et l'analyse de ces exemples visent à rendre visibles les marges d'erreur et les angles morts de l'automatisation hors de la supervision experte de l'éditeur.rice. Là où le choix de l'annotation exige des choix conceptuels et éditoriaux, le modèle automatique produit de la confusion ou une granularité inutile. Ainsi le texte se voit être restructuré et où certaines informations sont filtrées. En cela, le modèle ne se contente pas de *lire* les sources à notre place : il impose une certaine conception de ce

qui est donné à voir. Dit autrement, il fonctionne comme un artefact normatif : ce n'est pas tant la réalité des sources qui dicte résultats, mais la vision structurée et orientée du modèle.

Cette démarche vise à rendre tangible les zones d'instabilité ou de fragilité de l'automatisation, à savoir les situations où le modèle cesse de réagir de manière cohérente en rapport avec les annotations initiales. Si l'erreur peut être considérée comme un symptôme interprétable de la prédiction - en ce qu'elle incite à s'interroger sur la modélisation implicite des catégories, le niveau de granularité retenue, ainsi que que les tensions entre la diversité lexicale du corpus et les conventions éditoriales - il convient de souligner que notre analyse demeure à un niveau essentiellement descriptif. En effet, l'outil spaCy préconise d'interroger un modèle de traitement des entités nommées à l'échelle de la séquence textuelle. Les opérations de traitement automatique sous-jacentes sont alors reléguées à l'arrière plan, au profit d'une représentation du texte sous une forme brute. Or, les unités lexicales manipulées ne correspondent plus à une reproduction fidèle du texte originale, mais bien à une version remédiée, dans laquelle chaque mot est remplacé par une multiplicité de vecteurs dont l'agencement encode une représentation sémantique particulière. À ce sujet, Dobson a souligné avec pertinence que ces ensembles vectoriels « façonnent à la fois leurs possibilités interprétatives et celles des objets textuels qu'il représentent »²⁵⁵. Dans cette perspective, les transformations effectuées par le flux de traitement computationnel produisent nécessairement une version familiarisée du texte qui le sort de son cadre fermé et appelle à un mode d'interprétation alternative, non plus sur le texte comme objet donné, mais sur des représentations dérivées. Si cette dimension a été prise en compte tout au long de ce travail, il n'en reste pas moins qu'appréhender et maîtriser ces transformations - ainsi que les formes de signification qu'elles génèrent - constitue encore un exercice complexe.

6.3 Les conditions de l'interdisciplinarité *ou* un équilibre qui reste à construire

La nature résolument interdisciplinaire de ce mémoire - à l'intersection de l'histoire et du TALN - soulève des défis méthodologiques spécifiques. Outre la charge de travail

255. DOBSON James E., « Vector hermeneutics : On the interpretation of vector space models of text », *Digital Scholarship in the Humanities*, vol. 37, n° 1, 2022, p. 81.

nécessaire à l'implémentation de techniques de traitement automatique du langage naturel sur un corpus édité, trois tensions majeures se sont dégagées : la dépendance à des outils techniques qui dépasse largement le champ de notre expertise ; la massification des données et les effets de décontextualisation qui en résulte ; le décalage entre les approches quantitatives et les exigences de l'interprétation historique. Malgré la multiplication des initiatives à l'intersection des disciplines humaines, telles que l'histoire, et du TALN, McGillivray *et alii*. a soutenu que les deux communautés semblent encore évoluer en vase clos²⁵⁶. Ce constat s'est largement fait ressentir dans ce travail, ce qui a entraîné de sérieuses limitations méthodologiques quand à leur applicabilité à notre objet de recherche.

Si les efforts visant à éclairer les mécanismes de l'apprentissage profond méritent d'être salués²⁵⁷, la difficulté demeure lorsqu'il s'agit d'apporter un regard interprétatif à leurs sujets. L'accès aux caractéristiques sous-jacentes de ces modèles, aux pondérations et aux paramètres qui composent de tels modèles restent largement restreints. Leur ajustement relève le plus souvent d'un tâtonnement empirique fondé presque exclusivement sur l'évaluation de métriques quantitatives. En outre, la compréhension fine de la signification et de l'impact de ces paramètres échappe largement aux chercheur·euse·s issus des sciences humaines en raison de parcours disciplinaires qui ne présupposent pas une expertise technique des données. Si notre démarche a consisté à expliciter autant que possible notre approche méthodologique, les phases d'entraînement apparaissent comme des points de bascule particulièrement opaques. Zundert avait déjà souligné cette difficulté, constatant que l'acte d'interprétation tend à se déporter *vers l'extérieur*, autrement dit, à se limiter à la phase post-algorithmique²⁵⁸. Dès lors, la question de la stabilité épistémique des résultats produits méritent d'être posée, dans la mesure où ils reposent sur des réglages techniques largement arbitraires.

La deuxième tension tient à la massification des données produites. La mise en œuvre d'une chaîne de traitement conduit à une extraction massive d'entités et à leur structuration sous forme de données exploitables à grande échelle. La nature même des entités, transformées en vecteurs, les rend précisément adaptables à différentes situations linguistiques. Le rapport au corpus se voit ainsi être modifié en profondeur : les

256. MCGILLIVRAY Barbara *et alii*, « Digital Humanities and Natural Language Processing : Je t'aime... Moi non plus », *Digital Humanities Quarterly*, vol. 014, n° 2, 2020.

257. DOBSON, « On reading and interpreting black box deep neural networks », *art. cit.*

258. VAN ZUNDELT, « Screwmeneutics and Hermeneumericals », *art. cit.*, p. 8.

entités deviennent aisément manipulables statistiquement, susceptibles d'être comparées, visualisées, ou corrélées. Cette abstraction induit précisément le risque d'occulter la dimension située, lacunaire et interprétative des sources : le contexte d'apparition, la matérialité, la temporalité qui donnent sens aux entités sont largement perdus au profit d'analyses globalisantes. Ainsi, le traitement automatique tend à décontextualiser les entités, le risque étant de faire disparaître la dimension historique et située de ces dernières.

La troisième tension réside dans le décalage entre les approches quantitatives dominantes en TALN et les attentes interprétatives des historien-ne-s. Le fait que la communauté du TALN vise l'amélioration incrémentale de la performances de ses modèles témoigne de cette dissymétrie. Cette tendance est plus particulièrement favorisée par l'émergence d'une logique dite de l'« état de l'art » (*State of Art*), dans laquelle l'argumentaire repose explicitement sur l'atteinte de performance supérieure à l'aune des indicateurs quantitatifs. Dès lors, des scores élevés sont assimilés à une réussite objective, mesurable et reproductible. Or, fournir une évaluation sur la base d'une comparaison directe et rapide entre différents modèles à l'aide de leurs valeurs synthétiques, telle que le F1-Score, n'offre pas aux historien-ne-s la capacité de juger la qualité de ceux-ci lorsqu'ils sont appliqués à la nature singulière de leur objets d'étude.

Dans le cas particulier du traitement d'entités nommées, cette critique prend une portée spécifique. Si la logique comparatiste des modèles semble être désormais ancrée dans la communauté du TALN, nous pourrions suggérer que les données sur lesquelles ils reposent ont une nature singulière. En effet, le périmètre des entités nommées est intimement lié à son enchevêtrement au sein de multiples contextes : qu'ils s'agissent des conventions méthodologiques d'annotations produits par Dodis, du choix du système du traitement automatique du langage, des objectifs et des besoins applicatifs concrets du projet de recherche, de l'hétérogénéité des ressources historiques, de même que du contexte temporel et linguistique, les entités nommées s'inscrivent dans des strates de significations multiples qui semblent peu s'aligner sur les considérations des talistes. Cette complexité et cette unicité réduisent non seulement la transférabilité des modèles d'un corpus à l'autre, mais aussi la pertinence de la comparaison interprojets. La polysémie constitutive des textes historiques entre en tension avec les exigences de précision et de reproductibilité de la modélisation computationnelle.

Plus fondamentalement, le recours à un standard de référence présuppose l'existence d'une annotation correcte, valable en toutes circonstances, qui autorise l'objectivité supposée des mesures fournies par le modèle. En creux, un standard implique donc une valeur de vérité, ou de vérité de terrain (*ground truth*) pour reprendre le langage technique du TALN. Or, une telle acceptation semble particulièrement problématique au sein d'une démarche herméneutique, dans la mesure où cette valeur repose sur l'hypothèse du monde clos : la diversité des lectures possibles se substitue à un référentiel artificiel figé, qui exclue d'emblée toutes interprétations alternatives²⁵⁹. La stabilisation du sens *a priori* apparaît comme une tension structurelle des projets qui s'inscrivent au croisement des approches de linguistique computationnelle et herméneutique. En effet, l'exigence de modélisation implique la spécification des catégories d'analyses en amont, tandis que, dans une démarche interprétative, ces mêmes catégories tendent à apparaître comme le produit d'un processus inductif au contact du corpus²⁶⁰.

Cette considération s'applique précisément à cette étude : alors les prédictions fournies par notre modèle permettent de formuler des constats interprétatifs, ces dernières suggèrent souvent une posture comparatiste en rapport à l'annotation initiale. En effet, le rapport à ce qui est *vrai* de ce qui ne l'est pas s'avère être modélisé dès la prise en charge initial du corpus : aux entités sont assignées une catégorie et référencées dans l'index de la base de données. Ce propos ne vise nullement à remettre en question la qualité de l'annotation du projet d'édition, mais plutôt d'envisager les limites de l'exploitation computationnelle lorsque que les outils sur lesquels elle repose sont empruntés à d'autres disciplines et ne semble pas répondre aux exigences épistémiques de l'histoire. Le standard, qui structure l'apprentissage supervisé, tend ainsi à réduire la plasticité interprétative propre aux sciences humaines à une opération pseudo-déterministe.

Plutôt que de juxtaposer des approches méthodologiques susceptibles de se contredire, il semble que de nouveaux dispositifs hybrides, articulant rigueur formelle et plasticité interprétative, sont à construire. À cet égard, Vanhoutte reconnaissait déjà en 2010 une distinction entre les méthodes informatiques utilisées « pour et dans les sciences humaines », distinction qui reflète des rapports profondément différents

259. VAN HOOLAND *et alii*, *Introduction aux humanités numériques*, *op. cit.*, p. 143.

260. KUHN Jonas, « Computational text analysis within the Humanities : How to combine working practices from the contributing fields? », *Language Resources and Evaluation*, vol. 53, n° 4, 2019, p. 565-602.

entre les méthodes et les domaines de recherche. Tandis que le *pour* renvoie à l'usage d'instruments externes au domaine en vue de gains d'efficacité, le *dans* implique la co-construction des savoirs, où les objets de recherche sont reconfigurés dans un dialogue interdisciplinaire. À l'issue de ce travail, il apparaît que les pratiques actuelles restent dominées par la logique du *pour*²⁶¹. À cette fin, nous ne pouvons que rejoindre les appels à dépasser les approches superficielles qui dominent actuellement le TALN afin de trouver des moyens pragmatiques de traduire les enjeux propres à la recherche historique. Différentes pistes de recherche méritent d'être approfondies, en particulier sur la prise en charge de la période historique du corpus en question pris dans son cadre conceptuel et culturel²⁶², sur la dimension diachronique²⁶³, ou encore sur la traduction d'indicateurs d'évaluation statistique en énoncés qualitatifs et d'identifier les sources d'erreurs²⁶⁴.

261. SCHWANDT Silke et SCHWANDT Silke (dir.), « Introduction », in *Digital Methods in the Humanities : Challenges, Ideas, Perspectives*, Bielefeld University Press, 2020, p. 7.

262. MCGILLIVRAY, « Computational Methods for Semantic Analysis of Historical Texts », *art. cit.*

263. PIOTROWSKI, « Historical Models and Serial Sources », *art. cit.*, p. 16.

264. WEBER, « On the Historiographic Authority of Machine Learning Systems », *art. cit.*

7 Modélisation, incertitude et factualité : pour une lecture critique des représentations numériques

Les outils numériques s'accompagne d'une illusion de transparence : leurs sorties tendent à être perçue comme des reflets fidèles des textes sur lesquelles elles se fondent. Cette apparente neutralité dissimule cependant des choix et des modélisations implicites qui orientent le sens. À cet égard nous souhaitons esquisser de manière non-exhaustives quelques considérations qui ont traversé ce travail. Trois points de focalisations sont retenus : les soubassements linguistiques que sous-tendent ces modélisations, l'inscription de l'incertitude dans le travail computationnel, et, enfin, une analyse du statut épistémique des entités comme unités d'information.

7.1 Sur la modélisation du sens dans les modèles neuronaux

Les représentations numériques fournies par les dispositifs numériques demeurent épistémiquement situées, même lorsque les mécanismes qui les sous-tendent demeurent invisibles. À cet égard, Flanders et Jannidis rappellent à juste titre que « [t]ous les outils numériques fonctionnent à partir d'une forme ou d'une autre de données modélisées, qu'ils nous exposent ou non entièrement ce modèle »²⁶⁵, le but étant de questionner l'objectif de la modélisation. Dès lors, l'enjeu n'est pas seulement d'évaluer les résultats d'un outil, mais de questionner les présupposés et les objectifs de cette modélisation. En tant que dispositifs épistémiques, les modèles neuronaux reflètent des régimes de connaissance spécifique qui se traduisent dans les opérations qu'ils effectuent. Recontextualiser cet ancrage permet, selon nous, de tirer quelques constats bénéfiques.

Cette exigence critique justifie un détour par la discipline linguistique pour tenter de mieux cerner les fondements théoriques des modèles neuronaux de type BERT. Dans ce cadre, la communauté du TALN fait largement mention de l'hypothèse distributionnaliste du linguiste Zelig Harris, selon laquelle la distribution environnante d'un mot, c'est-à-dire le vocabulaire qui l'entoure, contribue à déduire à lui seul sa signification²⁶⁶. Cette approche trouve un prolongement certain dans l'architecture

265. FLANDERS Julia et JANNIDIS Fotis, « Data modeling in a digital humanities context : An introduction », in FLANDERS Julia et JANNIDIS (dir.), *The Shape of Data in Digital Humanities*, Routledge, 2018, p. 11. *trad.*

266. WEVERS Melvin et KOOLEN Marijn, « Digital begriffsgeschichte : Tracing semantic change using word embeddings », *Historical Methods : A Journal of Quantitative and Interdisciplinary History*, vol. 53, n° 4, 2020,

BERT, laquelle vise à déduire la signification d'un mot à partir de son environnement lexical. BERT encode chaque segment textuel en plusieurs centaines de valeurs numériques, créant ainsi une représentation alternative du texte fondée sur la dépendance mutuelle entre mots et contextes. Le modèle repose sur l'idée que les régularités internes au langage, captée de manière inductive, peuvent servir à prédire de nouveaux contextes linguistiques. En cela, la structuration interne du langage sert de pivot à la modélisation.

Si le distributionnalisme semble apparaître donc comme la caractérisation fidèle des modèles computationnels neuronaux, du fait que leurs mécanismes sous-jacents sont virtuellement les mêmes, il convient d'aborder brièvement la posture épistémologique du langage chez Harris. L'analyse du langage qu'il suggère doit former un système autonome. Les relations distributionnelles entre les éléments du langage - c'est-à-dire l'occurrence des traits linguistiques les uns par rapport aux autres au sein des énoncés - constituent un système autonome et cohérent de contraintes formelles qui structure le langage de manière interne. Par conséquent, les phénomènes linguistiques ont leur propre poids, caractérisés par leurs propres propriétés, et définis par leurs propres règles, indépendamment des considérations de signification qui se situent à l'extérieur du texte. Harris l'énonce clairement : « la structure du langage ne correspond pas nécessairement à la structure de l'expérience subjective, du monde subjectif des significations »²⁶⁷. Les régularités formelles du langage priment sur l'acte par lequel les mots véhiculent du sens et, par extension, ne sont nullement gouvernées par une source externe de signification²⁶⁸. Il suppose que le sens est stable et accessible si ce dernier est doté de bonnes capacités d'analyses syntaxiques. Le pas franchi paraît d'ordre pragmatique : ce qui était, chez Harris, une stratégie de description devient, chez BERT, une stratégie de prédiction, fondée sur les principes d'auto-apprentissage et de passage à l'échelle.

Nous pourrions ainsi suggérer que rien dans l'organisation formelle des contextes linguistiques ne semble correspondre clairement à une situation extralinguistique concrète, si ce n'est indirectement à travers la distribution des mots dans un cor-

p. 228-229.

267. HARRIS, Zelig, « Distributional structure », in *Papers in Structural and Transformational Linguistics*, 1970, p. 780, cité dans GASTALDI, « Why Can Computers Understand Natural Language ? », *art. cit.*, p. 191. *trad.*

268. *Ibid.*, p. 192.

pus. Or, selon nous, l'historien-ne attache une importance particulière à la valeur de référentialité des mots qu'ils découvrent dans un document. À cet égard, Antoine Prost exprime bien le *modus operandi* historien : « L'histoire prend le texte comme trace de quelque chose qui s'est passé, et qu'il permet de retrouver, de reconstituer. Elle s'intéresse à ce qui est à l'extérieur du texte, indépendamment de lui, à la réalité extra-textuelle qu'il vise. »²⁶⁹. C'est cette vision référentielle du langage, où les mots servent avant tout à désigner des réalités extérieures, qui semble constituer les conditions historiographiques et ses exigences méthodologiques qui lui sont propres : l'établissement de la preuve documentaire, la construction de l'explication, et sa mise en forme²⁷⁰. Ainsi, la réflexivité propre à l'historien-ne, celle de la « pulsion extralinguistique, extra-textuelle, pour tout dire référentielle »²⁷¹ soutient une relation entre le mot et son référent historique.

Ces quelques réflexions, sans doute trop brèves, ne doivent pas être interprétées comme une incompatibilité épistémologique entre les modèles computationnels actuels et la pratique historique. La portée objective, voire performative, associée aux résultats algorithmiques mérite d'être envisagée à la lumière d'un double postulat : d'une part, tout modèle computationnel demeure sémantiquement aveugle ; d'autre part, il ne traite que des données qui lui ont été préalablement fournies²⁷². En ce sens, la compétence de la relation entretenue avec un contenu historique reste le propre de l'historien-ne. Les traitements computationnels peuvent certes faire apparaître des régularités, des écarts ou des anomalies — mais leur signification ne peut émerger que dans le cadre d'un travail herméneutique. De cette manière, les résultats fournis par une chaîne logicielle relèvent uniquement d'un niveau de signification apparent : rien dans le modèle ne résulte d'une compréhension conceptuelle du monde mais uniquement de traitements algorithmiques. Bien que les représentations générées par BERT permettent d'approximer le sens par le biais de son contexte linguistique, la signification réelle n'est jamais acquise.

269. PROST Antoine, « Sociale et culturelle, indissociablement », in RIOUX Jean-Pierre et SIRINELLI Jean-François (dir.), *Pour une histoire culturelle*, Paris : Seuil, 1997, p. 138.

270. RICŒUR Paul, « 3. La représentation historique », in *La Mémoire, l'Histoire, l'Oubli*, Paris : Seuil, 2014, p. 363.

271. *Ibid.*, p. 319-320.

272. SCHWANDT Silke, « Digitale Methoden für die Historische Semantik : Auf den Spuren von Begriffen in digitalen Korpora », *Geschichte und Gesellschaft*, vol. 44, n° 1, 2018, p. 107-134.

7.2 Formaliser l'incertitude ?

L'incertitude ²⁷³ est une composante implicite du raisonnement historique, qui se matérialise par des expressions prudentes telles que « probablement » et « vraisemblablement » ²⁷⁴. Au sein d'un environnement numérique, l'incertitude ne se résume cependant pas à l'absence documentaire ou à la contingence des faits. Loin de disparaître de la chaîne de traitement computationnel, elle se voit être reconfigurée, mais jamais dissoute ²⁷⁵.

Dans le cadre de la numérisation des sources historiques, la rupture de la relation indexicale entre le document et l'historien-ne ²⁷⁶ place ainsi l'incertitude au centre du raisonnement scientifique d'une manière relativement inédite. À l'incertitude inhérente et inévitable des documents historiques succède une chaîne de médiations numériques successives – de l'encodage à l'inférence algorithmique – chacune introduisant sa propre marge d'incertitude. Ainsi, cette contingence apparaît moins comme un simple résidu méthodologique qu'une composante constitutive du travail de l'historien-ne dans un environnement numérique.

En traduisant un document analogique en balises, l'acte de conversion vers un format numérique, telle que la TEI, engage déjà un choix interprétatif sur la pertinence du choix documentaire de même que la structure choisie : les décisions prises à l'endroit des entités retenues, du niveau de granularité, de même que la normalisation effectuée à l'endroit du matériel source mérite d'être pris en compte. L'incertitude ne disparaît pas : elle se déplace dans la grammaire technique du document. Toutefois, la capacité de la TEI à formaliser cette même incertitude reste pour l'heure fragmentaire. En définissant des attributs « Certainty, Precision, and Responsibility », le standard propose de signaler les aspects les plus problématiques en ne définissant pas la manière de les déterminer ²⁷⁷. Comme le suggère Piotrowski, « les Guidelines de la TEI laissent ouverte la manière dont on peut déterminer la « probabilité », la « chance » ou le « degré de certitude » d'une interprétation » ²⁷⁸.

273. En raison de la polyphonie de la notion d'incertitude et de ses synonymes contextuels, tels que « ambiguïté », « contingence », « multivocalité » nous faisons usage de ces termes sans systématiser leur distinction terminologique.

274. PIOTROWSKI Michael, « Incertitude et histoire numérique », in *Humanistica 2023*, Genève, Switzerland : Association francophone des humanités numériques, 2023.

275. MOUZA Cédric Du *et alii*, « De l'histoire numérique à l'histoire données ? », *Les Cahiers de Framespa*, n° 42, 2023.

276. FICKERS, « Authenticity », *art. cit.*

277. TEXT ENCODING INITIATIVE, 21 Certainty, Precision, and Responsibility - The TEI Guidelines, 07.2025.

278. PIOTROWSKI Michael, « Accepting and Modeling Uncertainty », *Die Modellierung des Zweifels* –

L'étape du traitement, en particulier lorsqu'il repose sur des modèles neuronaux, n'abolit pas ce flou : ils le reformulent en probabilités. Le réseau calcule la vraisemblance qu'une séquence appartienne à une catégorie. Chaque entité reconnue se voit être attribué un score de confiance, totalisant une valeur qui tend vers 1, cette dernière étant censé refléter le degré de certitude qu'il représente. La promesse de fournir une prédiction *fiable*, à l'instar du projet Impresso²⁷⁹, tend à naturaliser la confiance en lui conférant une aura de neutralité et d'objectivité au résultat de sortie du modèle. Or, les probabilités produites par le système ne sont pas une réponse directe aux questions herméneutiques. Quantifier le doute présuppose que les problèmes soient « clos » : tous les scénarios ou alternatives possibles à une situation données sont connus. Cependant, la recherche historique demeure, par définition, une question ouverte, où les faits inconnus ou de nouvelles interprétations peuvent modifier rétroactivement l'explication.

L'incertitude ne peut ainsi être reléguée à la quantification des données numériques, qui sous-entend une forme de positivisme numérique²⁸⁰. Si des études récentes argumentent que l'augmentation des données constitue une approche satisfaisante pour rendre des scores de confiance plus fiable²⁸¹, le propos selon lequel l'augmentation exponentielle des données permettrait de limiter l'incertitude inhérente à l'inférence statistique est particulièrement problématique dans le cadre de la production de connaissance en histoire : l'incertitude ne sera pas éliminée mais à nouveau reconfigurée en probabilités, manipulée elle-même par des algorithmes. Le glissement vers l'automatisation de la certitude occulterait ainsi la richesse des interprétations possibles, tout créant une forme de dépendance au score attribué.

La délégation de tâches à l'outil, si elle libère l'historien-e ou l'éditeur-riche d'opérations fastidieuses, exige donc une vigilance accrue. La réponse à ces enjeux n'est pas simple. Néanmoins, elle suggère d'éviter les postures extrêmes : déléguer la confiance aux algorithmes ou inversement disqualifier toutes approches computationnelles en arguant de l'incommensurabilité de l'incertitude. Les cadres de modélisation compu-

Schlüsseliideen und -konzepte zur graphbasierten Modellierung von Unsicherheiten. [Ausgewählte Beiträge der Tagung 19.-20.01.2018 an der Akademie der Wissenschaften und der Literatur, vol. Mainz] Hg. von Andreas Kuczera / Thorsten Wübbena / Thomas Kollatz. Wolfenbüttel 2019. (= Zeitschrift für digitale Geisteswissenschaften / Sonderbände, 2019, p. 4).

279. IMPRESSO, Natural Language Processing, 06.2025.

280. PIOTROWSKI, « Incertitude et histoire numérique », *art. cit.*, p. 3.

281. HU Mengting *et alii*, Uncertainty in Natural Language Processing : Sources, Quantification, and Applications, arXiv, 2023.

tationnelle actuels ne semblent néanmoins pas adaptés pour gérer l'incertitude rencontrée dans la recherche historique. Dans cet entre-deux, une collaboration entre les humanités numériques et la communauté historique est susceptible d'apporter une contribution notable à cet état de fait. À cet égard, l'incertitude doit plutôt être reconnue et acceptée, et autant que possible être qualifiée pour tenter d'approcher les multiples strates où elle s'insère²⁸². Il s'agit d'explicitier les implicites qui se situent au niveau des données mais aussi des connaissances historiques²⁸³. Cette ouverture n'abolit pas l'incertitude ; elle la rend visible et donc négociable.

7.3 Les entités nommées comme factoides

Ce travail s'ouvrait sur les potentialités offertes par la reconnaissance et la liaison des entités nommées dans les processus d'extraction d'informations, entendus comme les procédures d'identification automatique d'entités sélectionnées au sein d'un contenu textuel. Il est révélateur que le terme même d'« information » demeure rarement explicitée dans le domaine du TALN, au profit d'une focalisation sur les méthodes techniques et les outils mobilisés pour son extraction. Dans ce contexte, les récentes réflexions sur la nature de l'information historique à l'ère numérique offre un cadre pertinent pour recontextualiser la notion d'entité nommée, structurant des dispositifs automatisés d'extraction du *qui* et du *où*.

En particulier, le raisonnement proposé par Beretta sur les modalités de production de savoir historique s'avèrent particulièrement éclairante. S'appuyant sur les apports des sciences de l'information, il modélise sous forme pyramidale trois différentes strates épistémiques qui concernent les données, l'information et le savoir. Les données en constituent la base, comprise au sens étymologique du terme, en tant que traces matérielles de l'activité humaine²⁸⁴, indépendante de la position de l'historien-ne. Le niveau intermédiaire, celui de l'information, correspond aux représentations numériques de l'original, construites et stockées sous divers formats. Dans cette perspective, il reconnaît que « les données numériques n'appartiennent pas à la strate épistémique des données, mais à celle de l'information dont elles constituent le support informa-

282. PIOTROWSKI, « Accepting and Modeling Uncertainty », *art. cit.*

283. SCHWANDT, « OPENING THE BLACK BOX OF INTERPRETATION : DIGITAL HISTORY PRACTICES AS MODELS OF KNOWLEDGE », *art. cit.*, p. 82.

284. Bien que le propos puisse être entendu sources nativement numériques, nous les écartons ici en raison de la spécificité de notre corpus

tique »²⁸⁵. En ce sens, l'information se voit toujours être construite, située et médiée. Le sommet de la pyramide renvoie au savoir scientifique, entendu comme la synthèse interprétative des informations qui excèdent la simple représentation factuelle de la réalité passée. La distinction la plus opérante émerge au sein même de la strate épistémique de l'information, laquelle articule deux niveaux susceptibles de s'inscrire dans une dynamique de passage de l'un à l'autre. L'information peut ainsi se traduire, à un degré inférieur à la reproduction de contenu, ou tendre vers l'approximation de la factualité par le biais de la critique historique. Ce qui les différencie réside dans la relation épistémique avec le document et les faits auxquels ils se réfèrent²⁸⁶.

C'est précisément dans cet espace épistémique que s'inscrit la notion de « factioïde ». Définie comme une unité élémentaire d'information extraite d'un texte, elle ne présume ni sur la véracité ou sur l'exactitude de son contenu qu'elle modélise. Comme le soutiennent Pasin et Bradley, « l'approche par factioïde donne la priorité aux sources plutôt qu'à la lecture qu'en font les historiens »²⁸⁷. En d'autres termes, le factioïde rend compte du contenu des sources *stricto sensu*, sans déterminer la factualité de l'information qu'elle représente. Il permet de relier les personnes, ou d'autre type, aux assertions contextuelles les concernant en conservant la pluralité et la contradiction des voix documentaires.

L'intérêt heuristique et épistémologique des factioïdes réside dans sa capacité à maintenir une distinction entre un ensemble d'affirmations historiques de bas niveau – soit la strate inférieure de l'information –, et le niveau d'interprétation plus élevé produit par l'historien-ne ou l'éditeur-riche scientifique. Plutôt que de déterminer le degré de fiabilité de véracité propre à chaque affirmation pour ensuite les agréger en informations factuelles, les factioïdes permettent de cartographier un ensemble d'énoncés documentaires sans en gommer la contingence ou l'ambiguïté.

Transposée au champ de l'extraction de l'information, cette grille d'analyse conduit à reconnaître que les unités extraites – telles que les entités nommées – relèvent d'un régime de factualité analogue à celui des factioïdes. D'une part, la nature instable des entités nommées présentes dans les textes historiques complexifie leur identification de manière univoque ; d'autre part, les entités reconnues et les relations ne reflètent

285. BERETTA, « Données ouvertes liées et recherche historique », *art. cit.*

286. *Ibid.*

287. PASIN Michele et BRADLEY John, « Factoid-based prosopography and computer ontologies : towards an integrated approach », *Digital Scholarship in the Humanities*, vol. 30, n° 1, 2015, p. 90.

pas un état de fait, mais le contenu du point de vue corpus. Autrement dit, les résultats issus de l'extraction d'informations méritent d'être interprétés comme des artefacts de bas niveau, indicatifs des représentations historiques portées sur les textes eux-mêmes. En cela, les entités extraites sont le produit d'un acte de modélisation computationnelle appliqué à un matériel textuel, et non à des référents historiques.

En définitive, une conception critique de l'extraction des entités nommées doit, selon nous, reconnaître leur statut épistémique de *factoïde* : des unités certes interprétables, mais fondamentalement contingentes et contextualisées. Ce déplacement de perspective permet une prise de distance avec la dimension performative qui sous-tend les dispositifs numériques, tout en recentrant l'attention sur les conditions de production et de médiations techniques impliquées dans leur traitement.

8 Conclusion : ce que les traitements automatisés font aux documents édités

Ce travail s'est construit sur une double tension, à la fois méthodologique et épistémologique, qui traverse plus fondamentalement les humanités numériques. D'un côté, la discipline histoire, fondée sur l'interprétation et la critique ; de l'autre, l'informatique, ancrée dans la précision numérique et la prédiction algorithmique. Cette tension, loin d'être évitée, a été activement mobilisée comme vecteur d'expérimentation.

L'herméneutique numérique a constitué l'assise théorique de ce travail. En insistant sur la matérialité des dispositifs de transmission du sens, elle nous a incités à élargir notre perspective afin d'intégrer les effets de l'environnement technologique sur notre corpus, ainsi que les cadres interprétatifs qu'il contribue à façonner. L'orientation résolument expérimentale de ce travail a confirmé que seuls les essais empiriques permettent de saisir pleinement les défis méthodologiques et épistémologiques propres aux pratiques de l'herméneutique numérique, en particulier dans l'interaction entre les outils utilisés et les données analysées. Le cadre méthodologique du data scope s'est révélé, à cet égard, particulièrement fécond : conçu comme un dispositif réflexif et intégré à la pratique de recherche, il a permis de structurer l'analyse computationnelle des Documents diplomatiques suisses, et, d'autre part, d'explicitier les médiations techniques, les décisions méthodologiques, ainsi que les transformations successives opérées sur les données.

Une attention particulière portée à la modélisation formelle des documents édités a permis d'identifier, en amont du traitement algorithmique, les unités d'intérêt présentes au sein des contenus. Le modèle ainsi défini a permis de circonscrire le corpus du travail, tout en reconnaissant la nature composite des documents édités au format TEI-XML : à la fois traces historiques aux catégories hétérogènes et résultats d'un ensemble de décisions éditoriales prises dans le cadre du processus de modélisation.

La chaîne de traitement déployée dans ce projet a participé à la structuration et au questionnement de ce mémoire. Loin d'être une composante extérieure à l'enquête, elle a activement organisé le texte et sa lecture, tout en filtrant certaines informations et en excluant d'autres. Dans cette perspective, elle ne se contente pas de lire les documents à notre place, mais impose une certaine manière de traiter les données. En ce

sens, la chaîne de traitement fonctionne comme un artefact d'exploration et de normativité : ce n'est pas tant la réalité documentaire qui dicte sa structure, mais bien la chaîne de traitement qui projette une vision structurée — et donc orientée — des données. Ainsi, la configuration logicielle s'est présentée comme agencement technique fondamentalement normé qui détermine ce qui est visible et interrogeable. Cette approche suggère une critique située : elle invite à considérer les outils et les données qu'ils produisent, non pas comme des solutions toutes faites, mais comme des objets épistémiques à part entière, pris dans leur contexte d'utilisation.

L'expérimentation conduite sur les Documents diplomatiques suisses illustre cette dynamique : le traitement computationnel des entités nommées dépend étroitement des formats imposés par l'outil, de même que du cadre disciplinaire dans lequel il s'inscrit. Si l'automatisation de l'annotation au travers des entités promet de traiter de vastes volumes de données du fait de leur précision formelle, elle ne rendent par conséquent pas apte à représenter de la pluralité interprétative de ses équivalents manuels. De cette manière, l'annotation automatisée se heurte à plusieurs limites critiques : elle repose sur des catégories stables, susceptibles d'être inadaptées à la complexité des textes historiques, tout en tendant à rigidifier leur sens. Si l'idéal d'une annotation sans ambiguïté est pragmatiquement justifié par les exigences de validation et de performance des modèles algorithmiques, les raisonnements interprétatifs auxquels elle peut être soumise se voient être condensés par la formalisation des annotations initiales. Afin de dépasser ces apories, nous avons fourni une analyse interprétative des prédictions des modèles. Cette dernière a permis d'observer que certaines classes d'annotation, bien que techniquement définies, ne trouvent pas toujours d'équivalents clairs dans les pratiques éditoriales adoptées par Dodis et sont susceptibles de se placer en contradiction avec ces dernières.

Dans une perspective de dépassement critique de la performativité algorithmique, nous avons proposé, en conclusion, des réflexions d'ordre épistémologique. Toutes les dimensions soulevées pointent vers l'établissement de cadres de modélisation plus sensibles aux spécificités de la discipline historique. Cette conclusion ne vise pas à souligner une incompatibilité épistémologique des données et des outils numériques avec la démarche historique et éditoriale, mais appeler à une appropriation critique et contextualisée, en tant que leviers de transformations des pratiques interprétatives.

9 Lexique

Alias	Terme utilisé pour désigné le nom attribué à une entité après avoir mentionné son nom réel, par exemple un pronom ou une expression nominale générique.
Algorithme	Ensemble d'étapes computationnelles précisément spécifiées qui produisent un résultat.
Apprentissage supervisé	Procédé d'apprentissage automatique dans lequel un algorithme est entraîné à partir de données annotées par un humain. L'objectif est d'aligner les prédictions de l'algorithme sur l'annotation humaine.
Base de données relationnelle	Système de stockage de données qui organise les informations en tableaux interconnectés. Les données représentées sont structurées à l'aide de tables : chaque table est composée de lignes, appelées enregistrements, identifiables de manière unique grâce à une clé. Les colonnes définissent les attributs et chaque enregistrement contient en principe une valeur pour chacun de ces attributs, ce qui offre la possibilité d'établir des liens logiques entre les données.
Corpus	Ensemble de données d'expérimentation spécifique à cette recherche
Données semi-structurées	Type de données qui disposent d'une organisation interne permettant de les identifier, les hiérarchiser les classer dans des champs prédéfinis. Les textes codés en XML ou les données au format JSON en sont des exemples typiques.
Ingénierie de caractéristiques	Approche d'apprentissage machine consistant à sélectionner ou créer des caractéristiques significatives à partir de données brutes. Ces dernières peuvent ensuite être transmises au modèle pour en améliorer la performance.
Pipeline	Séquence d'étapes interconnectées qui transforment systématiquement des données textuelles brutes en un résultat souhaité, adapté à une analyse ou une application ultérieure.

Principes FAIR	Principe élaboré dans l'objectif d'améliorer la réutilisation des données, tant par des machines que par des individus.
Système d'information	Combinaison organisée de personnes, de matériels, de logiciels, de réseaux de communication, de ressources de données et de procédures qui stocke, récupère, transforme et diffuse des informations.

10 Bibliographie

A ILEMOBAYO Justus *et alii*, « Hyperparameter Tuning in Machine Learning : A Comprehensive Review », *Journal of Engineering Research and Reports*, vol. 26, n° 6, 2024, p. 388-395, DOI : 10.9734/jerr/2024/v26i61188.

ABADIE Nathalie *et alii*, « Evaluation de la qualité des sources du Web de Données pour la résolution d'entités nommées », *Revue des Sciences et Technologies de l'Information - Série ISI : Ingénierie des Systèmes d'Information*, vol. 21, n° 5-6, 2017, p. 31-54, <https://hal.science/hal-01462256>.

ALLAIN Jean-Claude, « Les sources de l'historien », in *Pour l'histoire des relations internationales*, Presses Universitaires de France, 2012, p. 83-101, DOI : 10.3917/puf.frank.2012.01.0083.

ALTHAGE Melanie *et alii*, « 2.2. Algorithmenkritik », in, Zenodo, 2024, DOI : 10.5281/ZENODO.12648832.

ALTHAGE Melanie *et alii*, Digitale Methoden in der geschichtswissenschaftlichen Praxis : Fachliche Transformationen und ihre epistemologischen Konsequenzen. Proceedings der Digital History 2023, Berlin, 23.-26.5.2023, Zenodo, 09.2023, DOI : 10.5281/ZENODO.8319631.

ANANIEVA Anna *et alii*, « The Study of Historical Travelogues from a Digital Humanities Perspective : Experiences and New Approaches », *Comparative Southeast European Studies*, vol. 72, n° 3, 2024, p. 370-385, DOI : 10.1515/soeu-2024-0023.

ANDENMATTEN Bernard et CROUSAZ Karine, L'utilisation et la réalisation des éditions de sources dans l'enseignement académique à l'époque du numérique, Serval, Lausanne, 2015, https://serval.unil.ch/fr/notice/serval:BIB_5951EBB9395B.

ANDREWS Tara, « Where are the Tools ? The Landscape of Semi-Automated Text Edition », in BLEIER Roman et KLUG Helmut W. (dir.), *Digitale Edition in österreich*, Köln : Universitäts- und Stadtbibliothek Köln, 2023, p. 3-18.

ARMASELU Florentina *et alii*, « LL(O)D and NLP perspectives on semantic change for humanities research », *Semantic Web*, vol. 13, n° 6, 2022, p. 1051-1080, DOI : 10.3233/SW-222848.

BAGNALL Kate et SHERRATT Tim, « Missing Links : Data Stories from the Archive of British Settler Colonial Citizenship », *Journal of World History*, vol. 32, n° 2, 2021, p. 281-300, DOI : 10.1353/jwh.2021.0025.

BERETTA Francesco, « Données ouvertes liées et recherche historique : un changement de paradigme », *Humanités numériques*, n° 7, 2023, DOI : 10.4000/revuehn.3349.

BERT COMMUNITY, Google-bert, 07.2025, <https://huggingface.co/google-bert>.

BLAGEC Kathrin *et alii*, A critical analysis of metrics used for measuring progress in artificial intelligence, arXiv, 2020, DOI : 10.48550/ARXIV.2008.02577.

BOELL Sebastian K. et CECEZ-KECMANOVIC Dubravka, « What is an Information System? », in *2015 48th Hawaii International Conference on System Sciences*, HI, USA : IEEE, 2015, p. 4959-4968, DOI : 10.1109/HICSS.2015.587.

BOONSTRA Onno *et alii*, *Past, Present and Future of Historical Information Science*, s.l. : DANS, 2006.

BRANDO Carmen *et alii*, « REDEN : Named Entity Linking in Digital Literary Editions Using Linked Data Sets », *Complex Systems Informatics and Modeling Quarterly*, n° 7, 2016, p. 60-80, DOI : 10.7250/csimq.2016-7.04.

BRUNDAGE Anthony, *Going to the sources : a guide to historical research and writing*, Hoboken, NJ : Wiley Blackwell, 2018.

BÜRGISSER Thomas, « “Dodis” als Instrument zur Erforschung einer politischen Geschichte der Schweiz », *traverse – Revue d’Histoire – Zeitschrift für Geschichte*, vol. Politikgeschichte in der Schweiz- eine historiografische Skizze, n° 1, 2013, p. 293-298, DOI : 10.5169/SEALS-391077.

BURNARD Lou, « How modeling standards evolve : The case of the TEI », in *The Shape of Data in Digital Humanities*, Routledge, 2018.

BURNARD Lou, *Qu’est-ce que la Text Encoding Initiative ?*, BURGHART Marjorie (trad.), Marseille : OpenEdition Press, 2015, DOI : 10.4000/books.oep.1237.

CAUVIN Thomas, « Editing Historical Texts », in *Public History. A Textbook of Practice*, New York : Routledge, Taylor & Francis Group, 2016, p. 127-139.

CLAVERT Frédéric, « Une histoire par les données ? Le futur très proche de l'histoire des relations internationales », *Bulletin de l'Institut Pierre Renouvin*, vol. N° 44, n° 2, 2016, p. 119-130, DOI : 10.3917/bipr1.044.0119.

CLAVERT Frédéric et MULLER Caroline, « L'histoire au temps des algorithmes : Une réflexion prospective sur l'introduction de l'intelligence artificielle en histoire au 21e siècle », *20 & 21. Revue d'histoire*, vol. N° 162, n° 2, 2024, p. 13-26, DOI : 10.3917/vin.162.0013.

COBURN Jon, « Defending the digital : Awareness of digital selectivity in historical research practice », *Journal of Librarianship and Information Science*, vol. 53, n° 3, 2021, p. 398-410, DOI : 10.1177/0961000620918647.

COLAVIZZA Giovanni *et alii*, « Archives and AI : An Overview of Current Debates and Future Perspectives », *Journal on Computing and Cultural Heritage*, vol. 15, n° 1, 2022, p. 1-15, DOI : 10.1145/3479010.

COLAVIZZA Giovanni *et alii*, « Index-Driven Digitization and Indexation of Historical Archives », *Frontiers in Digital Humanities*, vol. 6, 2019, p. 4, DOI : 10.3389/f-digh.2019.00004.

CORTADA James W., « Information infrastructures and historical research : A framework useful for professional and amateur historians », *The Information Society*, vol. 39, n° 5, 2023, p. 306-321, DOI : 10.1080/01972243.2023.2237012.

CRYMBLE Adam, *Technology and the Historian : Transformations in the Digital Age*, University of Illinois Press, 2021, DOI : 10.5406/j.ctv1k03s73.

CUGLIANA Elisa *et alii*, « Computational approaches and the epistemology of scholarly editing », *International Journal of Digital Humanities*, 2024, DOI : 10.1007/s42803-024-00088-z.

CUMMINGS J, « The Present and Future of Encoding Text(s) », in O'SULLIVAN James (dir.), *The Bloomsbury Handbook to the Digital Humanities*, Bloomsbury Publishing, 2022, p. 147-157, <https://eprints.ncl.ac.uk/288895>.

DEEPSET, Google-bert/bert-base-german-cased, 07.2025, <https://huggingface.co/google-bert/bert-base-german-cased>.

DEVLIN Jacob *et alii*, « BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding », in *Proceedings of the 2019 Conference of the North*, Minneapolis, Minnesota : Association for Computational Linguistics, 2019, p. 4171-4186, DOI : 10.18653/v1/N19-1423.

DIPLOMATISCHE DOKUMENTE DER SCHWEIZ - DOCUMENTS DIPLOMATIQUES SUISSES - DOCUMENTI DIPLOMATICI SVIZZERI, « Jahresbericht 2024 - Rapport annuel 2024 - Rapporto annuale 2024 », 2025, DOI : 10.5907/REPORT24.

DIPLOMATISCHE DOKUMENTE DER SCHWEIZ - DOCUMENTS DIPLOMATIQUES SUISSES - DOCUMENTI DIPLOMATICI SVIZZERI, « Jahresbericht 2023 - Rapport annuel 2023 - Rapporto annuale 2023 », 2024, DOI : 10.5907/REPORT23.

DOBSON James, « Interpretable Outputs : Criteria for Machine Learning in the Humanities. », *DHQ : Digital Humanities Quarterly*, vol. 15, n° 2, 2021, <https://search.ebscohost.com/login.aspx?direct=true&profile=ehost&scope=site&authtype=crawler&jrnl=19384122&asa=N&AN=152185006&h=rsJnB6I3dPbH2cMtRBfNO7Xvlwd8AscRS8qT%2FQn%2BJoEuBn2FsSyxORIJbmMzp2JAPXoP%2F2a8%2FJ1ToYq5Di7AnQ%3D%3D&crl=c>.

DOBSON James E, « Vector hermeneutics : On the interpretation of vector space models of text », *Digital Scholarship in the Humanities*, vol. 37, n° 1, 2022, p. 81-93, DOI : 10.1093/llc/fqab079.

DOBSON James E., « On reading and interpreting black box deep neural networks », *International Journal of Digital Humanities*, vol. 5, n° 2-3, 2023, p. 431-449, DOI : 10.1007/s42803-023-00075-w.

DOCUMENTS DIPLOMATIQUES SUISSES, Dodis goes AI, 01.2025, <https://www.dodis.ch/de/dodis-goes-ai>.

DOCUMENTS DIPLOMATIQUES SUISSES, Dodis 2.5 en ligne!, 2019, <https://www.dodis.ch/fr/dodis-25-en-ligne>.

DODIS, Best practices for digital diplomatic documentary editions, 05.2025, <https://diplomatic-documents.org/>.

DRUCKER Johanna, « Humanistic Theory and Digital Scholarship », in GOLD Matthew K. (dir.), *Debates in the Digital Humanities*, University of Minnesota Press, 2012, p. 85-95, DOI : 10.5749/minnesota/9780816677948.003.0011.

DRUCKER Johanna, « Humanities Approaches to Graphical Display », *Digital Humanities Quarterly*, vol. 5, n° 1, 2011, <https://digitalhumanities.org/dhq/vol/5/1/000091/000091.html>.

DÜRING Marten *et alii*, « Transparent generosity. Introducing the *impresso* interface for the exploration of semantically enriched historical newspapers », *Historical Methods : A Journal of Quantitative and Interdisciplinary History*, vol. 57, n° 1, 2024, p. 20-40, DOI : 10.1080/01615440.2024.2344004.

EHRMANN Maud, « Explorer la presse numérisée : le projet Impresso », *Revue Historique Vaudoise*, vol. 129, 2021, p. 159-173, <https://infoscience.epfl.ch/handle/20.500.14299/185588>.

EHRMANN Maud, *Les Entités Nommées, de la linguistique au TAL : Statut théorique et méthodes de désambiguïsation*, phdthesis, Paris Diderot University, 2008, <https://hal.science/tel-01639190>.

EHRMANN Maud *et alii*, « Digitised Historical Newspapers : A Changing Research Landscape », in BUNOUT Estelle *et alii* (dir.), *Digitised Newspapers – A New Eldorado for Historians ?*, De Gruyter, 2022, p. 1-22, DOI : 10.1515/9783110729214-001.

EHRMANN Maud *et alii*, « Historical Newspaper Content Mining : Revisiting the impresso Project's Challenges in Text and Image Processing, Design and Historical Scholarship », 2020, DOI : 10.5167/UZH-191271.

EHRMANN Maud *et alii*, « Historical Newspaper User Interfaces : A Review », *IFLA WLIC 2019 - Athens, Greece - Libraries : dialogue for change*, vol. 85, 2019, p. 1-24, <https://library.ifla.org/id/eprint/2578>.

EHRMANN Maud *et alii*, *Impresso - Media Monitoring of the Past II. Beyond Borders : Connecting Historical Newspapers and Radio.*, 2023, <https://data.snf.ch/grants/grant/213585>.

EHRMANN Maud *et alii*, « Named Entity Recognition and Classification in Historical Documents : A Survey », *ACM Computing Surveys*, vol. 56, n° 2, 2024, p. 1-47, DOI : 10.1145/3604931.

EHRMANN Maud *et alii*, « Overview of CLEF HIPE 2020 : Named Entity Recognition and Linking on Historical Newspapers », in ARAMPATZIS Avi *et alii* (dir.), *Experimental IR Meets Multilinguality, Multimodality, and Interaction*, Cham : Springer International Publishing, 2020, vol. 12260, p. 288-310, DOI : 10.1007/978-3-030-58219-7_21.

Es Karin Van *et alii*, « Tool Criticism and the Computational Turn. A “Methodological Moment” in Media and Communication Studies », *Medien & Kommunikationswissenschaft*, vol. 69, n° 1, 2021, p. 46-64, DOI : 10.5771/1615-634X-2021-1-46.

Es Karin van, « Unpacking tool criticism as practice, in practice », *Digital Humanities Quarterly*, vol. 17, n° 2, 2023, <https://www.digitalhumanities.org/dhq/vol/17/2/000692/000692.html>.

EUROPEAN PARLIAMENT, Ask the Archives : The EP Archives Unit Launches its first Generative AI tool, 02.2025, <https://historicalarchives.europarl.europa.eu/en/sites/historicalarchive/home/cultural-heritage-collections/news/ai-dashboard.html>.

FEICHTINGER Moritz *et alii*, « 2.1. Theoretische Grundlagen einer digitalen Quellenkritik », in, Zenodo, 2024, DOI : 10.5281/ZENODO.12647879.

FELTEN-KURY Lars VON, « Forschen – Vernetzen – Vermitteln. Die Forschungsstelle “Diplomatische Dokumente der Schweiz” (Dodis) », *traverse – Revue d’Histoire – Zeitschrift für Geschichte*, vol. Zu Fuss, n° 1, 2025, p. 113-121, <https://revue-traverse.ch/article/forschen-ernetzen-vermitteln-die-forschungsstelle-diplomatische-dokumente-der-schweiz-dodis/>.

FICKERS Andreas, « What the D does to history : Das digitale Zeitalter als neues historisches Zeitregime ? », in *Digital History*, De Gruyter Oldenbourg, 2022, p. 45-64, <https://www.degruyterbrill.com/document/doi/10.1515/9783110757101-003/html>.

FICKERS Andreas, « Authenticity : Historical Data Integrity and the Layered Materiality of Digital Objects », in BALBI Gabriele *et alii* (dir.), *Digital Roots*, De Gruyter, 2021, p. 299-312, DOI : 10.1515/9783110740202-017.

FICKERS Andreas, « Update für die Hermeneutik. Geschichtswissenschaft auf dem Weg zur digitalen Forensik ? », 2020, DOI : 10.14765/ZZF.DOK-1765.

FICKERS Andreas, « Veins filled with the Diluted Sap of Rationality : A Critical Reply to Rens Bod », *BMGN - Low Countries Historical Review*, vol. 128, n° 4, 2013, p. 155-163, DOI : 10.18352/bmgn-lchr.9347.

FICKERS Andreas, « Towards a New Digital Historicism?: Doing History in the Age of Abundance », *VIEW Journal of European Television History and Culture*, vol. 1, n° 1, 2012, p. 19, DOI : 10.18146/2213-0969.2012.jethc004.

FICKERS Andreas et ARMASELU Florentina, « Introduction », in *Zoomland*, De Gruyter Oldenbourg, 2023, p. 1-16, <https://www.degruyterbrill.com/document/doi/10.1515/9783111317779-001/html>.

FICKERS Andreas et CLAVERT Frédéric, « On pyramids, prisms, and scalable reading », *Journal of Digital History*, vol. 1, n° 1, 2021, p. 1-13, DOI : 10.1515/jdh-2021-1008.

FICKERS Andreas *et alii*, « Digital history and hermeneutics – between theory and practice : An introduction », in FICKERS Andreas et TATARINOV Juliane (dir.), *Digital History and Hermeneutics*, De Gruyter, 2022, p. 1-20, DOI : 10.1515/9783110723991-001.

FLANDERS Julia et JANNIDIS Fotis, « Data modeling in a digital humanities context : An introduction », in FLANDERS Julia et JANNIDIS (dir.), *The Shape of Data in Digital Humanities*, Routledge, 2018, p. 3-25.

FLEURY Antoine, *Documents Diplomatiques Suisses*, Zürich Locarno Genève : Chronos A. Dadò Genève, 1997.

FLEURY Antoine, « Les documents diplomatiques suisses : histoire d'une publication majeure des historiens suisses », 1991, DOI : 10.5169/SEALS-81072.

FLEURY Antoine, *Les Documents diplomatiques suisses*, <https://www.diplomatie.gouv.fr/IMG/pdf/ECsuisse.pdf>.

FÖHR Pascal, *Historische Quellenkritik im Digitalen Zeitalter*, Basel : Universität Basel, 2017, <https://edoc.unibas.ch/64111/>.

FRIDLUND Mats, « Digital History 1.5 : A Middle Way between Normal and Paradigmatic Digital Historical Research », in FRIDLUND Mats *et alii* (dir.), *Digital Histories : Emergent Approaches within the New Digital History*, Helsinki University Press, 2020, p. 69-87, DOI : 10.33134/HUP-5-4.

GASTALDI Juan Luis, « Why Can Computers Understand Natural Language?: The Structuralist Image of Language Behind Word Embeddings », *Philosophy & Technology*, vol. 34, n° 1, 2021, p. 149-214, DOI : 10.1007/s13347-020-00393-9.

GIUS Evelyn, « Digitale Hermeneutik. Computergestütztes Close Reading als literaturwissenschaftliches Forschungsparadigma? », in JANNIDIS Fotis (dir.), *Digitale Literaturwissenschaft*, Stuttgart : J.B. Metzler, 2022, p. 385-417, DOI : 10.1007/978-3-476-05886-7_16.

GÖRMAR Maximilian, « La reconnaissance d'entités nommées dans les éditions numériques à l'exemple du récit de voyage du pharmacien Wagener », GÖBEL Angela (trad.), *Théia*, n° 1, 2024, DOI : 10.35562/theia.53.

GRAHAM Shawn *et alii*, « The Joys of Big Data for Historians », in *Exploring Big Historical Data*, WORLD SCIENTIFIC, 2022, p. 1-34, DOI : 10.1142/9789811243042_0001.

GREETHAM D. C. (dir.), *Scholarly editing : a guide to research*, New York : Modern Language Association of America, 1995.

GULDI Jo, « The Revolution in Text Mining for Historical Analysis is Here », *The American Historical Review*, vol. 129, n° 2, 2024, p. 519-543, DOI : 10.1093/ahr/rhae163.

GULDI Jo, *The Dangerous Art of Text Mining : A Methodology for Digital History*, Cambridge University Press, 2023¹, DOI : 10.1017/9781009263016.

GULDI Jo, « Parliament's Debates about Infrastructure : An Exercise in Using Dynamic Topic Models to Synthesize Historical Change », *Technology and Culture*, vol. 60, n° 1, 2019, p. 1-33, DOI : 10.1353/tech.2019.0000.

GUO Jiafeng *et alii*, « Named entity recognition in query », in *Proceedings of the 32nd international ACM SIGIR conference on Research and development in information retrieval*, Boston MA USA : ACM, 2009, p. 267-274, DOI : 10.1145/1571941.1571989.

HEGEL Philipp *et alii*, « Die interoperable Edition ‚sub specie durationis‘ », *editio*, vol. 38, n° 1, 2024, p. 135-146, DOI : 10.1515/editio-2024-0008.

HENGCHEN Simon *et alii*, « L'extraction d'entités nommées : une opportunité pour le secteur culturel? »:, *I2D - Information, données & documents*, vol. Volume 52, n° 2, 2015, p. 70-79, DOI : 10.3917/i2d.152.0070.

HESS Jan, « Von OCR und HTR bis NER und LLM : Zur (Teil-)Automatisierung digitaler Editions- und Transformationsprozesse », *editio*, vol. 38, n° 1, 2024, p. 147-162, DOI : 10.1515/editio-2024-0009.

HILTMANN Torsten, « Hermeneutik in Zeiten der KI : Large Language Models als hermeneutische Instrumente in den Geschichtswissenschaften », in *KI:Text*, De Gruyter, 2024, p. 201-232, <https://www.degruyterbrill.com/document/doi/10.1515/9783111351490-014/html>.

HILTMANN Torsten, « Vom Medienwandel zum Methodenwandel : Die fortschreitende Digitalisierung und ihre Konsequenzen für die Geschichtswissenschaften in historischer Perspektive », in DÖRING Karoline Dominika *et alii* (dir.), *Digital History*, De Gruyter, 2022, p. 13-44, DOI : 10.1515/9783110757101-002.

HILTMANN Torsten *et alii*, *NER4all or Context is All You Need : Using LLMs for low-effort, high-performance NER on historical texts. A humanities informed approach*, arXiv, 2025, DOI : 10.48550/ARXIV.2502.04351.

HITCHCOCK Tim, « Confronting the Digital : Or How Academic History Writing Lost the Plot », *Cultural and Social History*, vol. 10, n° 1, 2013, p. 9-23, DOI : 10.2752/147800413X13515292098070.

HODEL Tobias, « Die Maschine und die Geschichtswissenschaft : Der Einfluss von deep learning auf eine Disziplin », in DÖRING Karoline Dominika *et alii* (dir.), *Digital History*, De Gruyter, 2022, p. 65-80, DOI : 10.1515/9783110757101-004.

HODEL Tobias, « Eine Zunft im digitalen Wandel : die Editionswissenschaften 2.0 in der Schweiz », 2021, DOI : 10.5281/ZENODO.5590079.

HODEL Tobias Mathias, « Das Ende der Edition? Ein Blick auf geschichtswissenschaftliche Editionen mit Fokus auf die Frühe Neuzeit – eine Provokation », in, University of Bern, 2024, DOI : 10.48350/196422.

HOEKSTRA Rik et KOOLEN Marijn, « Data scopes for digital history research », *Historical Methods : A Journal of Quantitative and Interdisciplinary History*, vol. 52, n° 2, 2019, p. 79-94, DOI : 10.1080/01615440.2018.1484676.

HONNIBAL Matthew et MONTANI Ines, Introducing spaCy, 02.2015, <https://explosion.ai/blog/explosion.ai>.

HOOLAND Seth van et COECKELBERGS Mathias, « Exploring Large-Scale Digital Archives – Opportunities and Limits to Use Unsupervised Machine Learning for the Extraction of Semantics », in *Handbook of Digital Public History*, De Gruyter Oldenbourg, 2022, p. 517-530, <https://www.degruyterbrill.com/document/doi/10.1515/9783110430295-046/html>.

HU Mengting *et alii*, Uncertainty in Natural Language Processing : Sources, Quantification, and Applications, arXiv, 2023, DOI : 10.48550/ARXIV.2306.04459.

HU Zhentao *et alii*, « Deep learning for named entity recognition : a survey », *Neural Computing and Applications*, vol. 36, n° 16, 2024, p. 8995-9022, DOI : 10.1007/s00521-024-09646-6.

HUMBEL Marco *et alii*, « Named-entity recognition for early modern textual documents : a review of capabilities and challenges with strategies for the future », *Journal of Documentation*, vol. 77, n° 6, 2021, p. 1223-1247, DOI : 10.1108/JD-02-2021-0032.

IBEKWE Onyekachi Henry, « Tractable Tensions : A Review of Digital Humanities : Knowledge and Critique in a Digital Age by David M. Berry and Anders Fagerjord », *Digital Humanities Quarterly*, vol. 18, n° 1, 2024, <https://www.digitalhumanities.org/dhq/vol/18/1/000488/000488.html>.

IDE Nancy, « Introduction : The Handbook of Linguistic Annotation », in IDE Nancy et PUSTEJOVSKY James (dir.), *Handbook of Linguistic Annotation*, Dordrecht : Springer Netherlands, 2017, p. 1-18, DOI : 10.1007/978-94-024-0881-2_1.

IMMENHAUSER Beat, Open Science Policy de l'Académie suisse des sciences humaines et sociales, Zenodo, 02.2019, DOI : 10.5281/ZENODO.2634213.

IMPRESSO, Natural Language Processing, 06.2025, <https://impresso-project.ch/project/linguistics/>.

INTERNATIONAL EDITORS OF DIPLOMATIC DOCUMENTS, Best practices for digital diplomatic documentary editions, 02.2025, <https://diplomatic-documents.org/best-practices/digital-editions/>.

JÄNICKE Stefan *et alii*, On Close and Distant Reading in Digital Humanities : A Survey and Future Challenges, The Eurographics Association, 2015, DOI : 10.2312/EUROVISSTAR.20151113.

JANNIDIS Fotis, « Computational Literary Studies and Scholarly Editing », in COHEN Matt *et alii* (dir.), *Futures of Digital Scholarly Editing*, Minneapolis : University of Minnesota Press, 2025, <https://manifold.umn.edu/read/futures-of-digital-scholarly-editing/section/358fca98-29db-4896-91be-5a914cfcec4a#ch05>.

JANNIDIS Fotis, « Grundlagen der Datenmodellierung », in JANNIDIS Fotis *et alii* (dir.), *Digital Humanities*, Stuttgart : J.B. Metzler, 2017, p. 99-108, DOI : 10.1007/978-3-476-05446-3_7.

JANNIDIS Fotis et FLANDERS Julia, « Glossary », in JANNIDIS Fotis et FLANDERS Julia (dir.), *The Shape of Data in the Digital Humanities : Modeling Texts and Text-based Resources*, Abingdon, Oxon ; New York, NY : Routledge, 2019. | Series : Digital research in the arts and humanities : Routledge, 2018¹, p. 313-333, DOI : 10.4324/9781315552941.

JANNIDIS Fotis et FLANDERS Julia, « A gentle introduction to data modeling », in JANNIDIS Fotis et FLANDERS Julia (dir.), *The Shape of Data in the Digital Humanities : Modeling Texts and Text-based Resources*, Abingdon, Oxon ; New York, NY : Routledge, 2019. | Series : Digital research in the arts and humanities : Routledge, 2018¹, p. 26-96, DOI : 10.4324/9781315552941.

JENSEN Helle Strandgaard, « Digital Archival Literacy for (All) Historians », *Media History*, vol. 27, n° 2, 2021, p. 251-265, DOI : 10.1080/13688804.2020.1779047.

JURAFSKY Dan *et alii*, *Speech and Language Processing : An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition*, Upper Saddle River, NJ : Prentice Hall, 2025.

KERVEGAN Paul, « Modélisation, enrichissement sémantique et diffusion d'un corpus textuel semi-structuré : le cas des catalogues de vente de manuscrits », 2022, p. iv, <https://dumas.ccsd.cnrs.fr/dumas-04541009>.

KIMMO Elo, « Big Data, Bad Metadata : A Methodological Note on the Importance of Good Metadata in the Age of Digital History », in FRIDLUND Mats *et alii* (dir.), *Digital Histories : Emergent Approaches within the New Digital History*, Helsinki : Helsinki University Press, 2020, p. 103-111, DOI : 10.2307/j.ctv1c9hpt8.

KÖNIG Mareike, « Geschichte digital : Zehn Herausforderungen », in *Geschichtswissenschaft im 21. Jahrhundert*, De Gruyter, 2020, p. 67-76, DOI : 10.1515/9783110689143-008.

KÖNIG Mareike, « Digitale Methoden in der Geschichtswissenschaft : Definitionen, Anwendungen, Herausforderungen », *BIOS – Zeitschrift für Biographieforschung, Oral History und Lebensverlaufsanalysen*, vol. 30, 1-2/2017, 2019, p. 7-21, DOI : 10.3224/bios.v30i1-2.02.

KOOLEN Marijn *et alii*, « The Value of Preexisting Structures for Digital Access : Modelling the Resolutions of the Dutch States General », *Journal on Computing and Cultural Heritage*, vol. 16, n° 1, 2023, p. 1-24, DOI : 10.1145/3575864.

KOOLEN Marijn *et alii*, « Toward a model for digital tool criticism : Reflection as integrative practice », *Digital Scholarship in the Humanities*, vol. 34, n° 2, 2019, p. 368-385, DOI : 10.1093/llc/fqy048.

KORKEAMÄKI Laura *et* KUMPULAINEN Sanna, « Interacting with Digital Documents : A Real Life Study of Historians' Task Processes, Actions and Goals », in *Proceedings of the 2019 Conference on Human Information Interaction and Retrieval*, Glasgow Scotland UK : ACM, 2019, p. 35-43, DOI : 10.1145/3295750.3298931.

KUHN Jonas, « Computational text analysis within the Humanities : How to combine working practices from the contributing fields? », *Language Resources and Evaluation*, vol. 53, n° 4, 2019, p. 565-602, DOI : 10.1007/s10579-019-09459-3.

KURZ Stephan, « Transkription und Annotation. Die Eingabeseite digitaler Editionen », in *Digital Humanities in den Geschichtswissenschaften*, Böhlau Verlag Wien : Verlag, 2023, p. 333-347.

LENCI Alessandro et SAHLGREN Magnus, *Distributional Semantics*, Cambridge University Press, 2023¹, DOI : 10.1017/9780511783692.

LINHARES PONTES Elvys *et alii*, « Entity Linking for Historical Documents : Challenges and Solutions », in ISHITA Emi *et alii* (dir.), *Digital Libraries at Times of Massive Societal Transition*, Cham : Springer International Publishing, 2020, vol. 12504, p. 215-231, DOI : 10.1007/978-3-030-64452-9_19.

LORENZ Chris, « History : Theories and Methods », in *International Encyclopedia of the Social & Behavioral Sciences*, Elsevier, 2015, p. 131-137, DOI : 10.1016/B978-0-08-097086-8.62142-6.

LOWRIE Ian, « Algorithmic rationality : Epistemology and efficiency in the data sciences », *Big Data & Society*, vol. 4, n° 1, 2017, p. 2053951717700925, DOI : 10.1177/2053951717700925.

MADDEN Amanda, « Menocchio Mapped : Italian Microhistory and the Digital Spatial Turn », in *Zoomland*, De Gruyter Oldenbourg, 2023, p. 77-96, <https://www.degruyterbrill.com/document/doi/10.1515/9783111317779-004/html>.

MANNING Christopher D. *et alii*, *Introduction to Information Retrieval*, Cambridge University Press, 2008¹, DOI : 10.1017/CBO9780511809071.

MAYAFFRE Damon, « Philologie et/ou herméneutique numérique : nouveaux concepts pour de nouvelles pratiques? », in BALLABRIGA François Rastier et Michel (dir.), *Corpus en Lettres et Sciences sociales. Des documents numériques à l'interprétation*, Albi, France : Presses universitaires de Toulouse, 2006, p. 15-25, <https://hal.science/hal-00551477>.

McGILLIVRAY Barbara, « Computational Methods for Semantic Analysis of Historical Texts », in, Routledge, 2020, DOI : 10.17863/CAM.84178.

McGILLIVRAY Barbara *et alii*, « Why does digital history need diachronic semantic search? », in *Computational Humanities*, 2023, <https://dhdebates.gc.cuny.edu/>

read/computational-humanities-5c64bbab-d7ca-41be-8f87-f26117a9a20f/section/e36d5f05-57ab-436c-90e2-2ec9f87683a8.

MCGILLIVRAY Barbara *et alii*, « Digital Humanities and Natural Language Processing : Je t'aime... Moi non plus », *Digital Humanities Quarterly*, vol. 014, n° 2, 2020.

MEIER Martin, « Die Diplomatischen Dokumente der Schweiz (DDS) und die Datenbank DoDiS », *Politorbis*, vol. 44, n° 1, 2008, p. 41-47, <https://www.eda.admin.ch/eda/fr/dfae/dfae/publikationen/alle-publikationen.html/content/publikationen/fr/eda/schweizer-aussenpolitik/reihe-politorbis/archiv-politorbis/politoribs-44>.

MEISTER Jan Christoph, « Annotation als Markup avant la lettre », in JANNIDIS Fotis (dir.), *Digitale Literaturwissenschaft*, Stuttgart : J.B. Metzler, 2022, p. 353-383, DOI : 10.1007/978-3-476-05886-7_15.

MEROÑO-PENUELA Albert *et alii*, « Semantic technologies for historical research : A survey », *Semantic Web*, vol. 6, n° 6, 2014, p. 539-564, DOI : 10.3233/SW-140158.

MILLIGAN Ian, *The Transformation of Historical Research in the Digital Age*, Cambridge : Cambridge University Press, 2022¹, DOI : 10.1017/9781009026055.

MITKOV Ruslan (dir.), *The Oxford Handbook of Computational Linguistics*, Oxford : Oxford University Press, 2022.

MORETTI Franco, *Distant Reading*, London : Verso, 2013.

MOUZA Cédric Du *et alii*, « De l'histoire numérique à l'histoire données ? », *Les Cahiers de Framespa*, n° 42, 2023, DOI : 10.4000/framespa.14374.

MULLER Caroline et CLAVERT Frédéric, « De la poussière à la lumière bleue : Émotions, récits, gestes de l'archive à l'ère numérique », *Signata*, n° 12, 2021, DOI : 10.4000/signata.3136.

MUNNANGI Monica, A Brief History of Named Entity Recognition, arXiv, 2024, DOI : 10.48550/ARXIV.2411.05057.

NADEAU David et SEKINE Satoshi, « A survey of named entity recognition and classification », *Lingvisticae Investigationes*, vol. 30, n° 1, 2007, p. 1-20, DOI : 10.1075/li.30.1.03nad.

NANTKE Julia et SCHLUPKOTHEN Frederik, « Introduction », in *Annotations in Scholarly Editions and Research*, De Gruyter, 2020, p. 1-18, <https://www.degruyterbrill.com/document/doi/10.1515/9783110689112-001/html>.

NATALE Enrico, « Le Digital Humanities in Svizzera : uno sguardo d'insieme », *MEMORIA E RICERCA*, n° 40, 2012, p. 183-194, DOI : 10.3280/MER2012-040011.

NATALE Enrico et KURMANN Eliane, « L'Édition Historique à l'Ère Du Numérique. Un État Des Lieux Du Débat En Suisse. », *traverse. Revue d'histoire / traverse - Zeitschrift für Geschichte*, vol. 3, 2014, p. 135-146.

NEWS EYE, NewsEye : A Digital Investigator for Historical Newspapers, 12.2023, 10.3030/770299.

NOUVEL Damien, *Named Entities for Computational Linguistics*, London : ISTE, 2016.

OBERBICHLER Sarah *et alii*, « Integrated interdisciplinary workflows for research on historical newspapers : Perspectives from humanities scholars, computer scientists, and librarians », *Journal of the Association for Information Science and Technology*, vol. 73, n° 2, 2022, p. 225-239, DOI : 10.1002/asi.24565.

OHRVIK Ane, « What is close reading? An exploration of a methodology », *Rethinking History*, vol. 28, n° 2, 2024, p. 238-260, DOI : 10.1080/13642529.2024.2345001.

OLTMANN Elias *et alii*, « Different Preservation Levels : The Case of Scholarly Digital Editions », *Data Science Journal*, vol. 18, 2019, p. 51, DOI : 10.5334/dsj-2019-051.

OXYGEN XML EDITOR, TEI ODD Document Type (Framework), [https://www.oxygenxml.com/doc/versions/27.1/ug-editor/topics/author-tei-odd-doc-type.html#:text=The%20TEI%20ODD%20\(Text%20Encoding,xml/tei/css/..](https://www.oxygenxml.com/doc/versions/27.1/ug-editor/topics/author-tei-odd-doc-type.html#:text=The%20TEI%20ODD%20(Text%20Encoding,xml/tei/css/..)

PASIN Michele et BRADLEY John, « Factoid-based prosopography and computer ontologies : towards an integrated approach », *Digital Scholarship in the Humanities*, vol. 30, n° 1, 2015, p. 86-97, DOI : 10.1093/llc/fqt037.

PERRENOUD Marc, « Outils informatiques et documents diplomatiques : L'exemple d'une base de données sur les relations internationales et la politique étrangère de la Suisse », in *Diplomatic sources and international crises*, Rome, 1996, p. 51-68, <https://>

www.academia.edu/44777811/Outils_informatiques_et_documents_diplomatiques_l_exemple_d_une_base_de_donn%C3%A9es_sur_les_relations_internationales_et_la_politique_%C3%A9trang%C3%A8re_de_la_Suisse_In_Diplomatic_sources_and_international_crises_.

PETZ Cindarella Sarah Maria, *On Combining Network Research and Computational Methods on Historical Research Questions and its Implications for the Digital Humanities*, Technische Universität München, 2022, <https://mediatum.ub.tum.de/1624881>.

PFANZELTER Eva *et alii*, « Digital interfaces of historical newspapers : opportunities, restrictions and recommendations », *Journal of Data Mining and Digital Humanities*, vol. HistoInformatics, 2021, DOI : 10.46298/jdmdh.6121.

PIERAZZO Elena, « Distant Editing. The Challenges of Computational Methods to the Theory and Practice of Textual Scholarship », in COHEN Matt *et alii* (dir.), *Futures of Digital Scholarly Editing*, Minneapolis : University of Minnesota Press, 2025, <https://manifold.umn.edu/read/futures-of-digital-scholarly-editing/section/bbfcca54-75ca-4f3e-b2ea-8d99d90a20eb#ch01>.

PIERAZZO Elena, *Digital Scholarly Editing : Theories, Models and Methods*, London New York : Routledge, 2016.

PINCHE Ariane, « Des plumes aux pixels : actualité de l'édition scientifique numérique », *Théia. Revue d'histoire et d'histoire de l'art*, vol. 1, 2024, DOI : 10.35562/theia268.

PIOTROWSKI Michael, « Towards Computational Historiographical Modeling », 2024, DOI : 10.5281/ZENODO.13904530.

PIOTROWSKI Michael, « Incertitude et histoire numérique », in *Humanistica 2023*, Genève, Switzerland : Association francophone des humanités numériques, 2023, <https://hal.science/hal-04108242>.

PIOTROWSKI Michael, « Historical Models and Serial Sources », *Journal of European Periodical Studies*, vol. 4, n° 1, 2019, DOI : 10.21825/jeps.v4i1.10226.

PIOTROWSKI Michael, « Accepting and Modeling Uncertainty », *Die Modellierung des Zweifels – Schlüsselideen und -konzepte zur graphbasierten Modellierung von Unsicherheiten. [Ausgewählte Beiträge der Tagung 19.-20.01.2018 an der Akademie der Wissenschaften und der Literatur, vol. Mainz]* Hg. von Andreas Kuczera / Thorsten Wübbena / Thomas Kollatz. Wolfenbüttel 2019. (= Zeitschrift für digitale Geisteswissenschaften / Sonderbände, 2019, p. 4), DOI : 10.17175/SB004_006A.

PIOTROWSKI Michael et AFINSKI Mateusz, « Nothing New Under the Sun? Computational Humanities and the Methodology of History », in *CHR 2020 : Workshop on Computational Humanities Research*, 2020, p. 171-181.

PIOTROWSKI Michael et XANTHOS Aris, « Décomposer les humanités numériques », *Humanités numériques*, n° 1, 2020, DOI : 10.4000/revuehn.381.

PREVENIER Walter et HOWELL M., *From Reliable Sources. An Introduction to Historical Methods.*, Cornell University Press, Ithaca, 2001, <http://hdl.handle.net/1854/LU-135293>.

PROST Antoine, *Douze leçons sur l'histoire*, Paris : Éd. du Seuil, 2010.

PROST Antoine, « Sociale et culturelle, indissociablement », in RIOUX Jean-Pierre et SIRINELLI Jean-François (dir.), *Pour une histoire culturelle*, Paris : Seuil, 1997, p. 131-146.

PUSTEJOVSKY James et STUBBS Amber, « Chapter 1. The Basics », in *Natural language annotation for machine learning : a guide to corpus-building for applications*, Beijing Köln : O'Reilly, 2013, p. 1-31.

PUTNAM Lara, « The Transnational and the Text-Searchable : Digitized Sources and the Shadows They Cast », *The American Historical Review*, vol. 121, n° 2, 2016, p. 377-402, DOI : 10.1093/ahr/121.2.377.

RAPP Andrea, « Einführung », in JANNIDIS Fotis (dir.), *Digitale Literaturwissenschaft*, Stuttgart : J.B. Metzler, 2022, p. 243-247, DOI : 10.1007/978-3-476-05886-7_10.

RAPP Andrea, « Manuelle und automatische Annotation », in JANNIDIS Fotis et alii (dir.), *Digital Humanities*, Stuttgart : J.B. Metzler, 2017, p. 253-267, DOI : 10.1007/978-3-476-05446-3_18.

REHM Georg, « Observations on Annotations », in *Annotations in Scholarly Editions and Research*, De Gruyter, 2020, p. 299-324, <https://www.degruyterbrill.com/document/doi/10.1515/9783110689112-014/html>.

RETTBERG Jill Walker, « Algorithmic failure as a humanities methodology : Machine learning's mispredictions identify rich cases for qualitative analysis », *Big Data & Society*, vol. 9, n° 2, 2022, p. 20539517221131290, DOI : 10.1177/20539517221131290.

RICŒUR Paul, « 3. La représentation historique », in *La Mémoire, l'Histoire, l'Oubli*, Paris : Seuil, 2014, p. 302-369, <https://shs.cairn.info/la-memoire-l-histoire-l-oubli-9782020349178-page-302>.

ROBERGE Jonathan et LEBRUN Tom, « BERT, GPT-3, Timnit Gebru et nous : L'intelligence artificielle à la conquête du langage », *Sociologie et sociétés*, vol. 53, n° 1-2, 2023, p. 235-257, DOI : 10.7202/1097750ar.

ROBERTSON Stephen et MULLEN Lincoln, « Arguing with Digital History : Patterns of Historical Interpretation », *Journal of Social History*, vol. 54, n° 4, 2021, p. 1005-1022, DOI : 10.1093/jsh/shab015.

ROMEIN C. Annemieke *et alii*, « State of the Field : Digital History », *History*, vol. 105, n° 365, 2020, p. 291-312, DOI : 10.1111/1468-229X.12969.

ROMELE Alberto *et alii*, « Digital hermeneutics : from interpreting with machines to interpretational machines », *AI & SOCIETY*, vol. 35, n° 1, 2020, p. 73-86, DOI : 10.1007/s00146-018-0856-2.

ROSENZWEIG Roy, « Scarcity or Abundance? Preserving the Past in a Digital Era », *The American Historical Review*, 2003, p. 735-762, DOI : 10.1086/ahr/108.3.735.

SAHLE Patrick, « Digitale Edition », in JANNIDIS Fotis *et alii* (dir.), *Digital Humanities*, Stuttgart : J.B. Metzler, 2017, p. 234-249, DOI : 10.1007/978-3-476-05446-3_17.

SAHLE Patrick, « What is a Scholarly Digital Edition ? », in DRISCOLL Matthew James et PIERAZZO Elena (dir.), *Digital Humanities Series*, Cambridge, UK : Open Book Publishers, 2016¹, vol. 4, p. 19-40, DOI : 10.11647/OBP.0095.02.

SAHLE Patrick, « Inhalt und Form : Medienwandel als Transmedialisierung », in *Digitale Editionsformen*, Norderstedt : BoD, 2013, vol. II, p. 157-165.

SAHLE Patrick, « Digitale Editionsformen. Teil 1 : Das typografische Erbe », in, Norderstedt : BoD, 2013.

SAHLE Patrick, « Zwischen Mediengebundenheit und Transmedialisierung », *Editio*, vol. 24, n° 2010, 2010, p. 23-36, DOI : 10.1515/9783110223163.0.23.

SAHLE Patrick et VOGELER Georg, Kriterienkatalog für die Besprechung digitaler Editionen |, 03.2025, <https://www.i-d-e.de/publikationen/weitereschriften/kriterien-version-1-1/>.

SAHLE Patrick et VOGELER Georg, Criteria for Reviewing Scholarly Digital Editions, 06.2014, <https://www.i-d-e.de/publikationen/weitereschriften/kriterien-version-1-1/>.

SCHMIDT Benjamin, « Do Digital Humanists Need to Understand Algorithms ? », in GOLD Matthew K. et KLEIN Lauren F. (dir.), *Debates in the Digital Humanities 2016*, Minneapolis : University of Minnesota Press, 2016, vol. 2, DOI : 10.5749/9781452963761.

SCHÖCH Christof, « Quantitative Semantik. Word Embedding Models für literaturwissenschaftliche Fragestellungen », in JANNIDIS Fotis (dir.), *Digitale Literaturwissenschaft : DFG-Symposion 2017*, Stuttgart : J.B. Metzler, 2022, p. 535-562, DOI : 10.1007/978-3-476-05886-7_22.

SCHWANDT Silke, « OPENING THE BLACK BOX OF INTERPRETATION : DIGITAL HISTORY PRACTICES AS MODELS OF KNOWLEDGE », *History and Theory*, vol. 61, 2022, p. 77-85, DOI : <https://doi.org/10.1111/hith.12281>.

SCHWANDT Silke, « Digitale Methoden für die Historische Semantik : Auf den Spuren von Begriffen in digitalen Korpora », *Geschichte und Gesellschaft*, vol. 44, n° 1, 2018, p. 107-134, DOI : 10.13109/gege.2018.44.1.107.

SCHWANDT Silke et SCHWANDT Silke (dir.), « Introduction », in *Digital Methods in the Humanities : Challenges, Ideas, Perspectives*, Bielefeld University Press, 2020, p. 7-22, DOI : 10.2307/j.ctv2f9xskk.

SCHWEIZERISCHE FÜR GESCHICHTE *et alii*, « Datenstandards für die historische Forschung – Ein White-Paper der Schweizerischen Gesellschaft für Geschichte », 2023, DOI : 10.5281/ZENODO.10101430.

SELINA Galka, Anwendung von NER auf die Memoiren der Gräfin von Schwerin, 06.2024, <https://memoiren.hypotheses.org/609>.

SHEN Wei *et alii*, « Entity Linking with a Knowledge Base : Issues, Techniques, and Solutions », *IEEE Transactions on Knowledge and Data Engineering*, vol. 27, n° 2, 2015, p. 443-460, DOI : 10.1109/TKDE.2014.2327028.

SIBILLE Christiane, « Networking Digital Documents », in *Studies in Historical Documents from Nepal and India*, Heidelberg University Publishing, 2018, DOI : 10.17885/HEIUP.331.C4133.

SOUTOU Georges-Henri, « Méthodes de travail, sources et bibliographie », in *L'Europe de 1815 à nos jours*, Presses Universitaires de France, 2009, p. VII-XLVI, <https://shs.cairn.info/l-europe-de-1815-a-nos-jours-9782130576952-page-VII?lang=fr>.

SPACY, Release v3.0.0 : Transformer-based pipelines, new training system, project templates, custom models, improved component API, type hints & lots more · explosion/spaCy, 2021, <https://github.com/explosion/spaCy/releases/tag/v3.0.0>.

SPACY, Linguistic Features · spaCy Usage Documentation, <https://spacy.io/usage/linguistic-features#tokenization>.

SPADINI Elena, « Producing Scholarly Digital Editions », in *Reassembling the Republic of Letters in the Digital Age. Standards, Systems, Scholarship*, Göttingen University Press, 2019, p. 251-260.

STEINER Elisabeth, Metadaten (allgemein), 2021, <http://www.digitale-edition.at>.

STEINER Tobias, ML bei Dodis, Berne, 02.2024.

TEXT ENCODING INITIATIVE, 21 Certainty, Precision, and Responsibility - The TEI Guidelines, 07.2025, <https://tei-c.org/Vault/P5/4.0.0/doc/tei-p5-doc/en/html/CE.html>.

THOUARD Denis, « 4. Carlo Ginzburg et les indices de l'histoire », *Le Bel Aujourd'hui*, 2020, p. 117-170, <https://shs.cairn.info/hermeneutiques-contemporaines-9791037003966-page-117>.

TILTON Lauren, « Relating to Historical Sources », *The American Historical Review*, vol. 128, n° 3, 2023, p. 1354-1359, DOI : 10.1093/ahr/rhad365.

UNDERWOOD Ted, « Algorithmic Modeling : Or, Modeling Data We Do Not Yet Understand », in FLANDERS Julia et FOTIS JANNIDIS (dir.), *The shape of data in the digital humanities*, London : Routledge, 2019, p. 250-263.

UNDERWOOD Ted, « Theorizing Research Practices We Forgot to Theorize Twenty Years Ago », *Representations*, vol. 127, n° 1, 2014, p. 64-72, DOI : 10.1525/rep.2014.127.1.64.

VADERNA Gábor, « Micro and Macro, Close and Distant : History and Philology After the Digital Revolution », in KELEMEN Pál et PETHES Nicolas (dir.), *Philology in the Making*, transcript Verlag, 2019, p. 269-286, DOI : 10.1515/9783839447703-017.

VAJJALA Sowmya *et alii*, *Practical Natural Language Processing : A Comprehensive Guide to Building Real-World NLP Systems*, Beijing Boston Farnham Sebastopol Tokyo : O'Reilly, 2020.

VAJJALA Sowmya *et alii*, « Chapter 2. NLP Pipeline », in *Practical natural language processing : a comprehensive guide to building real-world NLP systems*, Beijing Boston Farnham Sebastopol Tokyo : O'Reilly, 2020.

VAN ES Karin *et alii*, « Tool Criticism : From Digital Methods to Digital Methodology », in *Proceedings of the 2nd International Conference on Web Studies*, Paris France : ACM, 2018, p. 24-27, DOI : 10.1145/3240431.3240436.

VAN HOOLAND S. *et alii*, « Exploring entity recognition and disambiguation for cultural heritage collections », *Digital Scholarship in the Humanities*, vol. 30, n° 2, 2015, p. 262-279, DOI : 10.1093/llc/fqt067.

VAN HOOLAND Seth *et alii*, *Introduction aux humanités numériques : méthodes et pratiques : Sciences humaines et sociales*, De Boeck Supérieur, 2016, DOI : 10.3917/dbu.dewi.2016.01.

VAN MIERLO Wim, *Scholarly Editing in Perspective*, Cambridge New York Port Melbourne [etc.] : Cambridge University Press, 2025.

VAN ZUNDERT Joris J., « The case of the bold button : Social shaping of technology and the digital scholarly edition », *Digital Scholarship in the Humanities*, vol. 31, n° 4, 2016, p. 898-910, DOI : 10.1093/llc/fqw012.

VAN ZUNDERT Joris J., « Screwmeneutics and Hermenumericals : The Computationality of Hermeneutics », in SCHREIBMAN Susan *et alii* (dir.), *A New Companion to Digital Humanities*, Wiley, 2015¹⁻²⁶, p. 1, DOI : 10.1002/9781118680605.ch23.

VIOLA Lorella, « The Humanities in the digital », in *The Humanities in the Digital : Beyond Critical Digital Humanities*, Cham : Springer International Publishing, 2023, p. 1-35, DOI : 10.1007/978-3-031-16950-2_1.

VITALI-ROSATI Marcello, « Pour une théorie de l'éditorialisation », *Humanités numériques*, n° 1, 2020, DOI : 10.4000/revuehn.371.

VOGELER Georg, « Digitale Editionspraxis. Vom pluralistischen Textbegriff zur pluralistischen Softwarelösung », in BOSSE Anke et FANTA Walter (dir.), *Textgenese in der digitalen Edition*, De Gruyter, 2019, p. 117-136, DOI : 10.1515/9783110575996-008.

VOGELER Georg, « The “assertive edition” : On the consequences of digital methods in scholarly editing for historians », *International Journal of Digital Humanities*, vol. 1, n° 2, 2019, p. 309-322, DOI : 10.1007/s42803-019-00025-5.

VOGELER Georg *et alii*, « „Ich glaube, Fakt ist...“ : Der geschichtswissenschaftliche Zugang zum digitalen Edieren », in DÖRING Karoline Dominika *et alii* (dir.), *Digital History*, De Gruyter, 2022, p. 171-190, DOI : 10.1515/9783110757101-010.

WEBER Dominic, « On the Historiographic Authority of Machine Learning Systems », 2024, DOI : 10.5281/ZENODO.13907672.

WETTLAUER Jörg, « Methoden der Digital History/Digitalen Geschichtswissenschaft », in HAAS Stefan (dir.), *Handbuch Methoden der Geschichtswissenschaft*, Wiesbaden : Springer Fachmedien Wiesbaden, 2023, p. 1-19, DOI : 10.1007/978-3-658-27798-7_21-1.

WEVERS Melvin et KOOLEN Marijn, « Digital begriffsgeschichte : Tracing semantic change using word embeddings », *Historical Methods : A Journal of Quan-*

titative and Interdisciplinary History, vol. 53, n° 4, 2020, p. 226-243, DOI : 10.1080/01615440.2020.1760157.

WILCOCK Graham, *Introduction to Linguistic Annotation and Text Analytics*, Cham : Springer International Publishing, 2009, DOI : 10.1007/978-3-031-02132-9.

WILDE Max de et HENGCHEN Simon, « Semantic Enrichment of a Multilingual Archive with Linked Open Data », *Alliance of Digital Humanities Organizations*, vol. 11, n° 4, 2017, p. 1-16.

ZAAGSMA Gerben, « Digital History and the Politics of Digitization », *Digital Scholarship in the Humanities*, vol. 38, n° 2, 2023, p. 830-851, DOI : 10.1093/llc/fqac050.

ZALA Sacha, « Diplomatic Documents of Switzerland. Volume 1993 Documenti diplomatici svizzeri. Volume 1994 Documents diplomatiques suisses. Volume 1994 Diplomatische Dokumente der Schweiz. Band 1994 », 2025, DOI : 10.5907/DDS-1994.

ZALA Sacha, *Documents diplomatiques suisses*, Zürich : Chronos Editions Zoé, 2022.

ZALA Sacha et CLAVADETSCHER, « Geheimdokumente und Open Science », *Stimme – wer wird gehört ? | La Voix : qui écoute-t-on ?*, n° 2, 2024, p. 14-16, DOI : 10.5281/zenodo.13938592.

ZIMMERMANN Michel *et alii*, « Le commentaire de documents en histoire », 2012, <https://shs.cairn.info/le-commentaire-de-documents-en-histoire-9782200243241>.

ZUNDERT Joris van, « Why the Compact Disc Was Not a Revolution and Cityfish Will Change Textual Scholarship, or What Is a Computational Edition ? », *Ecdotica*, vol. 1, 2018, p. 129-156, DOI : 10.7385/99283.

ZUNDERT Joris van, « 5. Barely Beyond the Book ? », in DRISCOLL Matthew James et PIERAZZO Elena (dir.), *Digital Humanities Series*, Cambridge, UK : Open Book Publishers, 2016¹, vol. 4, p. 83-106, <https://books.openedition.org/obp/3402>.

11 Annexes

11.1 Tables statistiques complémentaires

Langue	Types d'entité	Mentions	Pondération globale
français	PER	5 335	11,5%
français	LOC	7 981	
français	ORG	301	
allemand	PER	29 310	88,0%
allemand	LOC	63 797	
allemand	ORG	10 994	
anglais	PER	49	0,18%
anglais	LOC	150	
anglais	ORG	16	
italien	PER	18	0,09%
italien	LOC	86	
italien	ORG	0	
inconnue	PER	59	0,24%
inconnue	LOC	198	
inconnue	ORG	27	
Total		118 321	100%

Distribution des entités nommées selon la langue du paragraphe, leur type et leur pondération globale

Catégories	ORG	PER	LOC
Total dans <i>train</i>	7 879	23 736	49 633
Total dans <i>dev</i>	3 297	10 148	20 657
Entités uniques (<i>train</i>)	2 332	6 383	4 993
Entités uniques (<i>dev</i>)	1 151	3 704	2 854
Entités uniques communes (<i>train & dev</i>)	545	2 159	1 674
Entités uniquement dans <i>dev</i>	606	1 545	1 180
Entités apparaissant une seule fois (corpus)	1 993	4 458	3 685

Statistiques comparatives des entités nommées dans les jeux d'entraînement et de validation

11.2 Indications méthodologiques concernant le dépôt des scripts de programmation

Afin de répondre aux exigences de l'*Open Science*, les scripts de programmation créés dans le cadre de ce mémoire sont déposés dans le dépôt Github suivant : https://github.com/XavierBaume/Travail_Master.

La structure du dépôt s'organise selon l'arborescence présentée ci-dessus :

- Les scripts destinés à l'analyse des données sont référencés au sein des chapitres et sous-chapitres correspondant à leur utilisation.
- Le répertoire `model` regroupe l'ensemble des scripts liés à la préparation et d'entraînement des modèles, ainsi que le modèles entraînés eux-mêmes, conservés dans la sous-section `trained_model`.
- Enfin, le fichier `requirements.txt` recense l'ensemble des bibliothèques nécessaires à l'exécution des scripts.

```
.
|-- raw_data
|   |-- fichiers JSON
|   `-- fichiers HTML
|-- chapter4
|   `-- 4.3
|-- chapter5
|   |-- 5.2
|   |-- 5.3
|   `-- 5.4
|-- chapter6
|   |-- 6.1
|   `-- 6.2
|-- model
|   |-- cli
|   |-- for_training
|   |-- kb
|   `-- trained_model
`-- requirements.txt
```

Directives de la Direction

Directive de la Direction 0.3 bis.
Formulaire
Code de déontologie en matière d'emprunts,
de citations et d'exploitation de sources diverses

Reconnaisant


- Que le plagiat, la fabrication et la falsification des résultats sont unanimement considérés comme des fautes graves, passibles de sanctions de la part de l'UNIL, indépendamment des possibles poursuites pénales qu'elles peuvent susciter.
- Que leur pratique est incompatible avec la Charte de l'Université de Lausanne et la Directive 3.15 relative au traitement des cas de plagiat dans l'enseignement, Le soussigné déclare avoir pris connaissance du Code de déontologie en matière d'emprunts, de citations et d'exploitation de sources diverses ainsi que de la Charte de l'UNIL et de la Directive 3.15 susmentionnée.

Il a pris conscience :

- qu'une transgression des pratiques édictées dans le Code de déontologie peut entraîner des sanctions de la part de l'UNIL et que dans le cas d'un travail sanctionné d'une note "zéro" pour cause de transgression dudit Code, le Conseil de discipline de l'UNIL sera saisi ;
- du fait qu'un logiciel de détection des similitudes peut être utilisé, comme support, pour l'analyse des documents soumis par des étudiant·e·s, des doctorant·e·s, des assistant·e·s diplômé·e·s et des enseignant·e·s.

Nom et prénom : Baume Xavier Faculté : Faculté des lettres

Lieu / date/ Signature : Neuchâtel, le 4 août 2025



Le présent formulaire doit être rempli et dûment signé par toute personne s'engageant dans la rédaction d'un mémoire ou d'une thèse de doctorat et retourné au Décanat de la faculté d'inscription.

Si la Faculté décide de le soumettre pour signature plus tôt dans le déroulement du cursus des étudiants, il vaut alors pour toute la durée des études.

Une fois signé, ce document doit être versé par le Décanat de la Faculté au dossier de l'étudiant.

MdP/ 27 juin 2005